Università degli Studi di Bergamo

Dipartimento di Ingegneria Gestionale, dell'Informazione e della Produzione

Corso di Laurea Magistrale in Ingegneria Informatica
Classe n. LM-32 – Ingegneria Informatica



Titolo vero della tesi

Relatore:
Chiar.mo Prof. Mirko Mazzoleni

Correlatore:
eventuale correlatore

Tesi di Laurea Magistrale

Federico Panzeri
Matricola n. 123456

Anno Accademico 2025/2026

Sommario

Riassunto di quanto svolto, da fare alla fine

Indice

1 Introduction **1**

1.1 Sezione 1 1

1.2 Struttura della tesi 2

2 Literature Review **3**

2.1 Contesto della tesi 3

2.1.1 Storia e funzionamento dell'AIS 3

2.1.2 Dati trasmessi 3

2.1.3 Limiti e problemi noti 4

2.2 Panoramica degli approcci di anomaly detection 4

2.2.1 Approcci di Machine Learning 5

2.2.2 Approcci Stocastici 6

2.2.3 Approcci Geometrici 7

2.3 Il framework TREAD di Pallotta et al. 7

3 Metodologia **8**

3.1 Introduzione 8

3.2 Obiettivi 8

3.3 Dataset 9

3.3.1 Struttura del dataset 9

3.3.2 Qualità dei dati 11

3.4 Pre-processing dei dati 13

3.4.1 Importazione, filtraggio geografico e rimozione dei duplicati . . 13

3.4.2 Ottimizzazione della memoria 14

3.4.3 Calcolo della velocità media e classificazione degli stati 14

3.5 Implementazione del framework TREAD e differenze rispetto all'originale 17

3.5.1 Architettura generale 17

3.5.2 Identificazione dei waypoint: DBSCAN e H-DBSCAN 17

3.5.3 Costruzione dei waypoint e identificazione delle rotte 19
3.6 Anomaly detection 20
3.6.1 Decomposizione della velocità e preparazione delle feature . . 20
3.6.2 Stima della densità tramite Kernel Density Estimation 21
3.6.3 Classificazione dei trip per lunghezza 21
3.6.4 Calcolo della probabilità di transizione e anomaly scoring . . . 21
3.7 Tecnologie utilizzate 22
3.8 Limiti della metodologia 23
3.9 Sintesi e anticipazione dei risultati 24

4 Risultati **25**
4.1 Dataset 25
4.1.1 Dimensioni e composizione 25
4.1.2 Classificazione degli stati e punti stazionari 26
4.1.3 Waypoint e rotte estratte 26
4.2 Risultati qualitativi 26
4.2.1 Waypoint identificati 26
4.2.2 Rotte estratte 28
4.2.3 Trip sulla rotta selezionata 28
4.3 Risultati quantitativi 28
4.3.1 Parametri del modello Weibull 28
4.3.2 Anomaly scoring e ranking dei trip 28
4.3.3 Metriche di valutazione 29
4.4 Interpretazione dei risultati 29
4.5 Sintesi 29

5 Conclusions **30**
5.1 Sezione 1 - Sintesi dei contributi principali 30
5.2 Sezione 2 - Migliorie ottenute 30
5.3 Sezione 3 - Limititazioni/difetti 30
5.4 Sezione 4 - Sviluppi futuri 30
5.5 Sezione 5 - Conclusione finale 30

Elenco delle figure

3.1 Portale NOAA *AccessAIS* per il download di dati AIS. 11
3.2 Rappresentazione cartesiana di un record AIS. 12
3.3 Estratto del dataset di partenza. 12

4.1 Waypoint identificati con DBSCAN ($\varepsilon = 0.075$, $N_{\min} = 10$). 27
4.2 Waypoint identificati con H-DBSCAN (min_cluster_size = 30, max_cluster_size = 10 000). 27

Elenco delle tabelle

3.1 Struttura del dataset AIS del NOAA. 10
3.2 Ottimizzazione dei tipi di dato. 15

Capitolo 1

Introduction

1.1 Sezione 1

L'Automatic Identification System (AIS) è un sistema di trasmissione e ricezione dati sviluppato da Benny Pettersson agli inizi degli anni '90 che viene utilizzato in maniera diffusa sia da imbarcazioni commerciali che da diporto. Tale dispositivo nasce originariamente con lo scopo di migliorare la sicurezza della navigazione attraverso la riduzione del rischio di collisioni; successivamente, con l'evolversi della tecnologia, assume anche un ruolo legato al tracciamento delle imbarcazioni. Al di là di queste finalità operative, l'AIS rappresenta oggi una fonte ricca di informazioni per lo studio dei comportamenti dei natanti: fornisce dati geolocalizzati (con frequenza temporale variabile ma comunque nell'ordine delle decine di secondi) che descrivono in dettaglio i percorsi seguiti dalle navi, la loro velocità, orientamento, stato di navigazione e altre caratteristiche sia statiche che dinamiche.

Grazie alla larga adozione del sistema AIS, e grazie anche all'elevata frequenza con cui i dati vengono trasmessi, è naturale che negli ultimi anni, anche in aree circoscritte ma sufficientemente trafficate, vengano generate grandi moli di dati AIS. Tuttavia, la vastità, rumorosità e complessità intrinseca di questi dataset rendono necessario l'impiego di diverse tecniche per estrarre informazioni utili. Tutto ciò ha quindi favorito lo sviluppo di diversi studi dedicati all'estrazione automatica di informazioni.

L'obiettivo della presente tesi si inserisce in questo contesto: partendo da un metodo di anomaly detection proposto in letteratura, esso viene analizzato, migliorato e applicato a un dataset AIS di grandi dimensioni. Prima di descrivere il lavoro svolto, è necessario delineare il quadro delle principali categorie di approcci esistenti, con particolare riferimento ai contributi discussi da Wolsing et al. nel loro lavoro di rassegna e al framework introdotto da Pallotta et al., da cui prende avvio il metodo

adottato in questa tesi.

1.2 Struttura della tesi

Struttura della tesi.

- Capitolo 2
- Capitolo 3
- Capitolo 4
- Capitolo 5

Capitolo 2

Literature Review

2.1 Contesto della tesi

L'obiettivo di questa literature review è quello di esplorare lo stato dell'arte delle tecniche di analisi dei dati AIS per il rilevamento di anomalie nel traffico marittimo, cercando di fornire una panoramica generale.

2.1.1 Storia e funzionamento dell'AIS

L'Automatic Identification System (AIS) è un sistema di comunicazione utilizzato nella navigazione marittima. La sua origine viene generalmente attribuita a Benny Pettersson, che sviluppò un primo prototipo nei primi anni '90. Inizialmente concepito per ridurre il rischio di collisioni in mare, il sistema è stato poi progressivamente adottato a livello internazionale, fino a ottenere un riconoscimento formale da parte dell'International Maritime Organization (IMO). Nell'ambito dell'accordo SOLAS, l'installazione dell'AIS è diventata obbligatoria per le navi con stazza lorda superiore a 300 tonnellate impegnate in viaggi internazionali e per tutte le navi passeggeri [1].

Dal punto di vista tecnico, l'AIS opera su due canali radio VHF intorno ai 162 MHz e utilizza il protocollo TDMA (Time-Division Multiple Access), che permette a più imbarcazioni di trasmettere senza interferire tra loro [2]. La copertura, in condizioni standard, arriva fino a circa 50 km (linea di vista), mentre l'uso di ricevitori satellitari (S-AIS) consente di estenderla anche alle acque oceaniche [2]. La frequenza di trasmissione dei messaggi non è costante, ma varia in funzione della velocità e dello stato della nave, passando da pochi secondi a diversi minuti [2].

2.1.2 Dati trasmessi

I messaggi AIS possono essere suddivisi in tre categorie principali [2]:

- **Dati statici**: includono informazioni identificative della nave, come MMSI, nome, tipo e dimensioni.

- **Dati dinamici**: descrivono lo stato corrente della navigazione, tra cui posizione GPS, velocità (SOG), rotta (COG), orientamento della prua (HE), variazione della rotta (ROT) e stato operativo.

- **Dati di viaggio**: comprendono informazioni aggiuntive come pescaggio, tipo di carico, destinazione ed ETA. Essendo inseriti manualmente, risultano generalmente meno affidabili [3].

Ai fini dell'analisi del comportamento delle navi, i dati dinamici sono in genere i più rilevanti, in quanto descrivono in modo continuo l'evoluzione delle traiettorie.

2.1.3 Limiti e problemi noti

Nonostante la ricchezza informativa, i dati AIS presentano diverse criticità che ne complicano l'analisi. Dal punto di vista della qualità, possono verificarsi lacune nella copertura dovute a limiti dei ricevitori terrestri o a interferenze, soprattutto in aree molto trafficate [3].

Inoltre, il protocollo AIS non prevede meccanismi di autenticazione o cifratura, rendendo possibile la manipolazione dei dati, ad esempio tramite spoofing o spegnimento del transponder [2]. Un ulteriore problema è rappresentato dalla diversa frequenza di trasmissione tra le varie classi di imbarcazioni, che introduce una certa eterogeneità nei dataset.

Nel complesso, la dimensione, la rumorosità e la complessità di questi dati rendono necessario l'utilizzo di tecniche automatiche di analisi dei dati.

2.2 Panoramica degli approcci di anomaly detection

La letteratura sull'anomaly detection nei dati AIS è stata raccolta e sistematizzata da [2], che analizza 44 contributi pubblicati tra il 2007 e il 2021. Prima di esplorare i possibili approcci risolutivi, è utile adottare un'opportuna classificazione delle potenziali anomalie da rilevare tramite l'analisi dei dati AIS. Nell'ambito di questo lavoro di tesi tale classificazione viene presa da [4].

Di seguito le 5 tipologie di anomalie:

1. **Deviazione dalla rotta** (*route deviation*): la nave percorre un tragitto insolito rispetto alla rotta tipicamente più breve tra due porti, compatibilmente con i vincoli fisici e normativi. È la tipologia di anomalia più studiata in letteratura [2] e rappresenta il focus principale di questo lavoro.

2. **Attività AIS inaspettata** (*unexpected AIS activity*): comprende l'accensione o lo spegnimento improvviso del transponder AIS (che può indicare il tentativo di nascondere la posizione della nave) nonché la modifica dei dati identificativi trasmessi, come il nome o codice identificativo MMSI.

3. **Arrivo in porto inaspettato** (*unexpected port arrival*): una nave approda in un porto non previsto o incoerente rispetto alla destinazione dichiarata o alla rotta storica. Questo comportamento può essere indicativo di attività illecite quali il contrabbando o l'evasione dei controlli doganali.

4. **Avvicinamento ravvicinato** (*close approach*): due navi si portano a distanza molto ridotta l'una dall'altra al di fuori di contesti giustificati (ad esempio le aree portuali), il che potrebbe indicare un passaggio non dichiarato di merci o persone.

5. **Ingresso in zona** (*zone entry*): una nave entra in un'area geografica soggetta a restrizioni, sorveglianza speciale o nota per attività illegali (ad esempio zone di pesca protette o aree riservate a determinate imbarcazioni).

Per ciascuna di queste categorie, Lane et al. [4] propongono un algoritmo probabilistico, i cui output vengono poi aggregati tramite una rete bayesiana per ottenere una stima complessiva della probabilità che una anomalia sia effettivamente in corso.

Nel resoconto prodotto dall'analisi sistematica condotta da [2] sui vari approcci risolutivi, si evince come la maggior parte dei contributi adotta una struttura in due fasi: prima viene costruito un modello del traffico normale a partire dai dati storici, poi si identificano le traiettorie che si discostano da quel modello come potenziali anomalie.

Infine, i lavori esaminati vengono classificati in tre macro categorie principali, a cui si aggiungono approcci ibridi che combinano più metodologie.

2.2.1 Approcci di Machine Learning

Gli approcci basati su machine learning comprendono principalmente metodi di clustering e reti neurali. Tra i primi, DBSCAN è particolarmente diffuso, in quanto si adatta bene alla natura spaziale dei dati e consente di identificare cluster senza

specificarne a priori il numero. Un esempio rappresentativo è il framework TREAD di Pallotta et al. [3], che applica l'algoritmo DBSCAN in maniera incrementale per individuare i "waypoint" caratteristici del traffico (principalmente porti, piattaforme offshore, punti di ingresso e uscita dall'area monitorata). Le nuove rotte vengono confrontate con il modello appreso e, se la sua probabilità rispetto alle rotte note risulta bassa, viene scartata.

Le reti neurali, invece, permettono di modellare relazioni più complesse e non lineari, e nelle versioni più recenti hanno mostrato buone prestazioni.

Questi approcci risultano scalabili e relativamente semplici da implementare, ma presentano anche alcuni limiti, tra cui la scarsa interpretabilità (soprattutto per le reti neurali) e la difficoltà di generalizzazione a contesti geografici diversi [5].

2.2.2 Approcci Stocastici

Gli approcci stocastici modellano il comportamento delle navi come un processo probabilistico. Tra le tecniche più comuni si trovano GMM, KDE, Gaussian Process e reti bayesiane.

In generale, questi metodi stimano la distribuzione delle traiettorie normali a partire dai dati storici e classificano come anomale quelle con bassa probabilità. Offrono una buona base teorica e permettono di quantificare l'incertezza, ma possono risultare onerosi dal punto di vista computazionale su dataset molto grandi.

Alcuni lavori, come [6], mostrano l'efficacia dei Gaussian Process. In particolare nel loro lavoro Kowalska et al. propongono un modello non parametrico basato su un Gaussian Process per apprendere il comportamento normale delle navi a partire dai dati AIS. Il loro modello assegna a ciascuna trasmissione ricevuta una misura di normalità in funzione della velocità osservata rispetto alla posizione geografica: le navi con comportamento inusuale ottengono uno score elevato e vengono prioritizzate per un'analisi più approfondita. Per rendere il metodo applicabile a dataset di grandi dimensioni, gli autori introducono una strategia di "active learning" che seleziona automaticamente un sottoinsieme informativo dei dati per l'addestramento, riducendo il costo computazionale senza compromettere le prestazioni.

Mascaro et al. [5] mostrano invece come le reti bayesiane possano essere interessanti per la loro maggiore interpretabilità, pur presentando difficoltà di scalabilità. In particolare, nel loro lavoro, apprendono reti bayesiane direttamente dai dati AIS, producendo modelli dinamici (che catturano l'evoluzione della traiettoria passo dopo passo) e modelli statici basati su un riassunto dell'intera rotta. I due approcci mostrano punti di forza complementari: il modello dinamico risulta più efficace nel rilevare anomalie localizzate nel tempo, mentre quello statico cattura meglio pattern

anomali che si manifestano sull'intera traiettoria. La loro combinazione migliora le prestazioni complessive di rilevamento rispetto all'uso di uno solo dei due.

2.2.3 Approcci Geometrici

Gli approcci geometrici si basano sulle proprietà spaziali delle traiettorie, ad esempio tramite il calcolo del convex hull (inviluppo convesso) delle rotte osservate [2]. Si tratta in genere di metodi semplici e interpretabili, ma meno flessibili e meno robusti in presenza di rumore rispetto ad altri approcci.

2.3 Il framework TREAD di Pallotta et al.

Tra gli approcci presenti in letteratura, il metodo adottato in questo lavoro è il framework TREAD (Traffic Route Extraction and Anomaly Detection) proposto da [3], che combina tecniche di clustering e analisi statistica.

Il framework è non supervisionato e incrementale: apprende i pattern di traffico direttamente dai dati AIS senza richiedere informazioni preliminari. Il processo si articola in due fasi principali. Nella prima fase, vengono identificati i waypoint caratteristici (come porti o punti di passaggio) tramite un algoritmo di clustering basato su DBSCAN. Tali waypoint vengono usati per costruire le rotte, definite come il percorso di un nave da un waypoint di partenza a uno di arrivo. Talvolta waypoint di partenza e di arrivo coincidono.

Nella seconda fase, le rotte apprese vengono utilizzate per analizzare nuove traiettorie e individuare eventuali anomalie, sulla base della loro probabilità rispetto al modello.

Tra i principali vantaggi di questo approccio vi sono la possibilità di aggiornare il modello in modo incrementale, la capacità di gestire dati AIS anche non continui e una rappresentazione relativamente compatta del traffico, adatta anche a dataset di grandi dimensioni.

Capitolo 3

Metodologia

3.1 Introduzione

Questo capitolo descrive in dettaglio il lavoro svolto per analizzare, re-implementare ed estendere il framework TREAD di Pallotta et al. [3], applicandolo a un dataset AIS reale relativo all'arcipelago delle Hawaii.

Come anticipato nel Capitolo 2, il framework TREAD è stato scelto come punto di partenza in quanto combina un approccio non supervisionato e incrementale con una rappresentazione compatta del traffico, caratteristiche che lo rendono adatto all'analisi di dataset di grandi dimensioni. Il lavoro non si limita a una replica dell'algoritmo originale, ma ne valuta criticamente l'applicabilità a un contesto più moderno e voluminoso, identificando gli aspetti mantenuti, quelli adattati e le eventuali possibilità di miglioramento.

La pipeline implementata si articola in tre fasi principali: **pre-processing** dei dati grezzi, **Knowledge Discovery** per l'identificazione dei waypoint e l'estrazione delle rotte tramite clustering, e **anomaly detection** basata su un modello probabilistico (KDE e distribuzione di Weibull).

Le sezioni seguenti descrivono ciascuna fase nel dettaglio, a partire dalla descrizione del dataset utilizzato.

3.2 Obiettivi

I quesiti di ricerca su cui è stata sviluppata la metodologia sono i seguenti:

1. Il framework TREAD (che è stato sviluppato agli inizi degli anni 2010), è ancora applicabile ad un dataset moderno e più voluminoso?

2. Quali aspetti e caratteristiche dell'algoritmo sono "riciclabili" e quali hanno richiesto adattamenti o sostituzioni?

3. È possibile ottenere risultati qualitativamente migliori?

4. Quali metriche è opportuno utilizzare per quantificare le prestazioni dell'algoritmo?

3.3 Dataset

I dati utilizzati provengono dal portale pubblico del NOAA[1] (National Oceanic and Atmospheric Administration), un'agenzia scientifica e normativa statunitense con diversi compiti tra cui il monitoraggio oceanico [7]. I file scaricati dalla piattaforma hanno nome nel formato `AIS_YYYY_MM_DD` (dove YYYY rappresenta l'anno, MM il mese e DD il giorno di registrazione dei dati) e contengono tutti i messaggi ricevuti dall'ente in una singola giornata di tutto il territorio nazionale monitorato. Per questa tesi sono stati utilizzati i dati relativi al periodo gennaio-marzo 2019 (estremi inclusi), filtrati sull'area delle Hawaii tramite una bounding box le cui estremità hanno le seguenti coordinate:

- Latitudine: da 18.77°N a 22.63°N,
- Longitudine: da 160.11°W a 154.39°W.

La figura 3.1 mostra un passaggio della fase di scaricamento dei dati dal portale del NOAA. Si può vedere su mappa il rettangolo descritto dalle coordinate di latitudine e longitudine di cui sopra.

3.3.1 Struttura del dataset

Ogni record del dataset corrisponde a un singolo messaggio AIS trasmesso da una nave e contiene diversi campi, riportati nella tabella 3.1. I campi si dividono in due categorie: attributi statici, che descrivono le caratteristiche fisse della nave e normalmente non variano tra un messaggio e l'altro, e attributi dinamici, che riflettono lo stato corrente della nave al momento della trasmissione.

Ogni record del dataset, contenendo una coppia di coordinate geografiche (`LAT`, `LON`), è rappresentabile come un punto su una mappa. A ciascun punto è inoltre

[1] Il NOAA mette a disposizione due modalità di accesso ai dati: tramite il portale `https://marinecadastre.gov/accessais/`, che consente di filtrare per zona geografica e intervallo temporale, oppure tramite `https://hub.marinecadastre.gov/pages/vesseltraffic`, che offre il download in bulk di tutti i dati AIS registrati suddivisi per anno.

Tabella 3.1: Struttura del dataset AIS del NOAA.

Colonna	**Tipo**	**Descrizione**
Attributi statici		
`MMSI`	intero	Maritime Mobile Service Identity: identificativo univoco della nave
`VesselName`	stringa	Nome della nave
`IMO`	stringa	Numero IMO (International Maritime Organization)
`CallSign`	stringa	Nominativo radio della nave
`VesselType`	intero	Codice numerico che indica la tipologia di nave (cargo, tanker, passeggeri, ecc.)
`Length`	intero	Lunghezza della nave in metri
`Width`	intero	Larghezza della nave in metri
`Draft`	decimale	Pescaggio della nave in decimi di metro
`Cargo`	intero	Codice del tipo di carico trasportato
`TransceiverClass`	booleano	Classe del transponder AIS: `A` o `B` (imbarcazioni minori)
Attributi dinamici		
`BaseDateTime`	datetime	Timestamp del messaggio (UTC)
`LAT`	decimale	Latitudine della posizione (gradi decimali)
`LON`	decimale	Longitudine della posizione (gradi decimali)
`SOG`	decimale	Speed Over Ground: velocità rispetto al fondale in nodi
`COG`	decimale	Course Over Ground: direzione di movimento in gradi (0–360°)
`Heading`	decimale	Prua della nave in gradi (0–360°), distinta dal COG
`Status`	intero	Stato di navigazione AIS (es. in navigazione, all'ancora, in manovra)

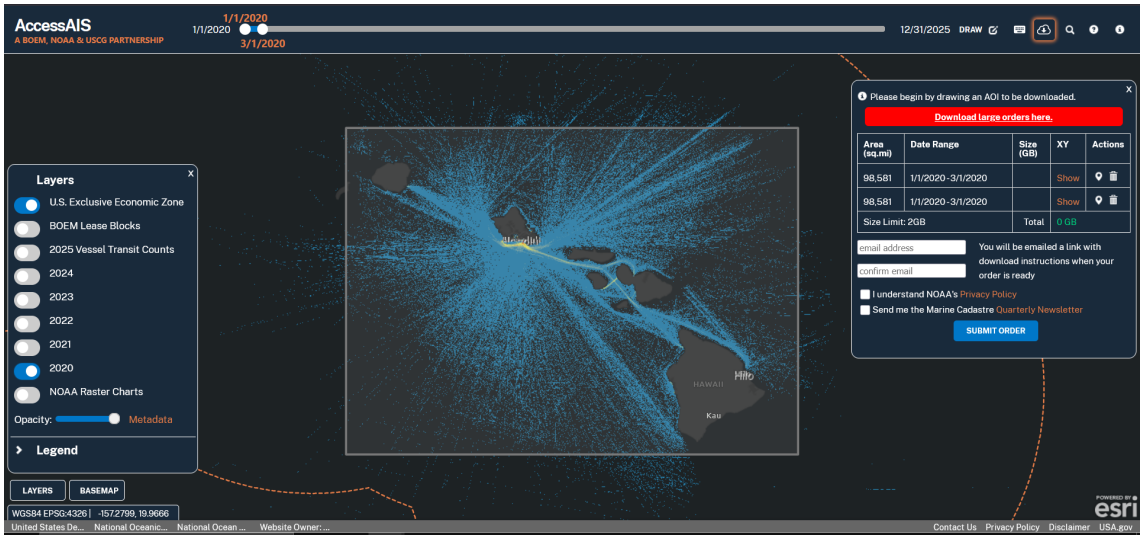


Figura 3.1: Portale NOAA *AccessAIS* per il download di dati AIS.

associato un vettore: il modulo corrisponde alla velocità istantanea della nave (`SOG`), mentre la direzione è determinata dall'angolo `COG`, espresso in gradi rispetto al nord geografico. Questa rappresentazione vettoriale è alla base delle elaborazioni descritte nelle sezioni successive, ed è il motivo per cui nel resto del capitolo i termini *record* e *punto* vengono usati in modo intercambiabile.

In figura 3.2 viene mostrata una visualizzazione grafica dei concetti di LON, LAT, SOG, COG, Heading. Ogni punto è identificato dalla coppia di coordinate (LON, LAT). Il vettore SOG indica la velocità istantanea della nave, con direzione data dall'angolo COG misurato rispetto al nord geografico in senso orario. L'Heading indica l'orientamento della prua, che può differire dal COG a causa di correnti, vento o altre cause

In figura 3.3 è possibile vedere un esempio dei dati contenuti nelle colonne `MMSI, BaseDateTime, LAT, LON, SOG, COG, Heading, VesselName, IMO`

3.3.2 Qualità dei dati

Oltre alla struttura, è opportuno considerare la qualità intrinseca dei dati. Un vantaggio rilevante del dataset NOAA rispetto ad altre fonti pubbliche (in particolare i dati danesi considerati e poi scartati in fase esplorativa) è che i dati sono già stati filtrati dagli errori più grossolani, rendendo l'uso di tecniche di pulizia aggiuntive meno critico. È stata tuttavia mantenuta l'assunzione esplicita che le colonne `MMSI` e `BaseDateTime` siano affidabili e prive di errori, in quanto queste due colonne costituiscono la base di tutte le elaborazioni successive.



Figura 3.2: Rappresentazione cartesiana di un record AIS.

	MMSI	BaseDateTime	LAT	LON	SOG	COG	Heading	VesselName	IMO
0	367060130	2019-01-01T00:00:00	29.68313	-91.1679	5.6	282.4	511.0	Missing value	Missing value
1	368029640	2019-01-01T00:00:00	40.68142	-74.01218	0.0	360.0	511.0	Missing value	Missing value
2	367141210	2019-01-01T00:00:00	39.8976	-75.13971	0.1	198.8	511.0	Missing value	Missing value
3	316038603	2019-01-01T00:00:00	48.65235	-123.4493	0.0	17.2	511.0	Missing value	Missing value
4	366876000	2019-01-01T00:00:00	27.7313	-92.28222	9.1	110.0	109.0	Missing value	Missing value
5	368062270	2019-01-01T00:00:01	29.74715	-95.17277	7.9	264.0	263.0	Missing value	Missing value
6	368063460	2019-01-01T00:00:00	30.06378	-93.26706	6.4	149.3	511.0	Missing value	Missing value
7	316038834	2019-01-01T00:00:00	49.19619	-123.13591	0.0	212.2	511.0	Missing value	Missing value
8	338458000	2019-01-01T00:00:00	30.49525	-88.0443	9.1	123.2	119.0	Missing value	Missing value
9	367528080	2019-01-01T00:00:00	28.76662	-95.62543	4.8	235.7	511.0	MISS MARY JEAN	Missing value
10	368050140	2019-01-01T00:00:01	39.92184	-91.41509	0.0	130.5	511.0	Missing value	Missing value
11	368019930	2019-01-01T00:00:02	33.72979	-118.2756	0.0	248.6	126.0	Missing value	Missing value
12	368007030	2019-01-01T00:00:02	35.36905	-120.85569	0.0	225.5	511.0	IRENE'S WAY	IMO8133279
13	366990580	2019-01-01T00:00:00	47.7901	-122.49089	17.2	298.0	297.0	FINEST	IMO9132076
14	368926258	2019-01-01T00:00:00	39.26699	-76.5795	0.0	228.9	511.0	Missing value	Missing value
15	368015740	2019-01-01T00:00:00	36.84844	-76.31547	0.0	4.1	220.0	Missing value	Missing value
16	368028980	2019-01-01T00:00:00	38.80961	-75.12962	4.3	315.9	511.0	DANIELLE MILLER	Missing value
17	368070320	2019-01-01T00:00:01	40.73076	-74.01356	0.0	276.5	511.0	Missing value	Missing value
18	247293200	2019-01-01T00:00:01	17.07412	-67.67	12.6	155.0	153.0	MARE PICENUM	IMO9449405
19	367728730	2019-01-01T00:00:01	29.8103	-93.9965	6.5	37.5	36.0	CONCHO	Missing value

Figura 3.3: Estratto del dataset di partenza.

3.4 Pre-processing dei dati

L'intera fase di pre-processing, nonchè le successive analisi, sono implementate in Python, utilizzando dei notebook Jupyter. Le tecnologie utilizzate verranno descritte meglio nella Sezione 3.7.

3.4.1 Importazione, filtraggio geografico e rimozione dei duplicati

I file scaricati dalla piattaforma del NOAA sono in formato ".zip". Pertanto vengono automaticamente decompressi e successivamente eliminati dal disco per liberare spazio, mentre i file csv così estratti vengono mantenuti. Il nome di ogni archivio decompresso viene registrato in un apposito file di log, così da non ripetere l'operazione nelle esecuzioni successive. Durante l'importazione, ogni file csv letto viene salvato in memoria sottoforma di `DataFrame`. In questa fase, vengono immediatamente scartati tutti quei messaggi le cui coordinate di latitudine e longitudine ricadono al di fuori del perimetro citato nella sezione 3.3. Tutti i `DataFrame` così creati vengono concatenati in un unico `DataFrame` finale, che viene esportato in un unico file CSV di backup. Le operazioni di importazione e filtraggio avvengono grazie alla libreria **Polars**, che è stata scelta per il fatto che (a differenza di Pandas) supporta il multithreading nativamente.

In una fase successiva, i record esattamente duplicati (identici in ogni attributo) vengono rimossi, lasciandone solo uno per ogni gruppo duplicato.

Viene poi rimosso un ulteriore sottoinsieme di record: quelli generati da navi, la cui somma di record presenti nel database è inferiore al 10% della media calcolata sul totale delle navi presenti. Per identificare l'appartenenza di un record ad una nave o meno, è stato utilizzato il valore di `MMSI`. Come citato in precedenza alla sezione 3.3.2, tale attributo si assume corretto e validato dal NOAA in fase di raccolta dei dati.

La soglia usata per rimuovere le navi meno attive è calcolata dinamicamente (e non come valore fisso) in modo da rendere il codice indipendente dalle dimensioni del dataset che si decide di utilizzare. L'idea dietro la decisione di rimuovere queste navi è che, al di sotto di questa soglia, non contribuiscono in maniera significativa al traffico dell'area e la loro presenza potrebbe distorcere la fase di clustering. Prima dell'applicazione di questa soglia il dataset conteneva 602 imbarcazioni distinte (5.460.800 record). In seguito il numero di navi distinte è passato a 403 (5.415.168 righe), eliminando 199 vascelli (circa un terzo delle imbarcazioni di partenza) che costituivano solo lo 0,84% dei record totali.

3.4.2 Ottimizzazione della memoria

Il dataset pulito viene riletto in Pandas per le elaborazioni successive. Per ridurre il consumo di memoria (il dataset occupa circa 702 MB nella rappresentazione di default) i tipi di dato delle colonne vengono convertiti nelle rappresentazioni più compatte compatibili con i limiti tecnici definiti dalla normativa ITU-R M.1371-6 [8], che specifica la codifica binaria di ciascun campo del messaggio AIS. La Tabella 3.2 riassume le conversioni effettuate con la relativa giustificazione.

Le colonne `VesselName`, `IMO` e `CallSign` vengono convertite da `object` a `Pandas.StringDtype`. Questa operazione non produce un risparmio di memoria significativo, ma garantisce una gestione più corretta dei valori mancanti. Poiché queste tre colonne non vengono utilizzate nelle elaborazioni successive, non sono incluse in tabella. Grazie alle conversioni effettuate, il dataset si riduce da circa 702 MB a circa 465 MB, con un risparmio prossimo al 34%.

3.4.3 Calcolo della velocità media e classificazione degli stati

Una volta completata la fase di importazione e pulizia, l'analisi viene condotta su una nave alla volta utilizzando il valore di `MMSI` per distinguerle tra loro. Per ciascuna nave viene costruito un `DataFrame` separato, ordinato cronologicamente per `BaseDateTime` e contenente tutti messaggi che quell'imbarcazione ha generato nel periodo di analisi all'interno dell'area geografica analizzata. Per ogni coppia di punti consecutivi appartenenti alla stessa nave viene calcolata la velocità media `Avg_Speed`, come rapporto tra la distanza percorsa e l'intervallo di tempo trascorso. La distanza viene calcolata sfruttando la formula della *Great-Circle Distance*, che tiene conto della curvatura terrestre usando come raggio della Terra il raggio equatoriale definito dallo standard WGS-84 e pari a 6 378 137 m. L'intervallo di tempo tra i due punti viene individuato facendo la differenza tra i due timestamp e sfruttando l'ordinamento cronologico applicato in precedenza. La velocità risultante viene convertita in nodi nautici.

Il calcolo viene gestito in modo vettorizzato: ogni traiettoria viene rappresentata come due sequenze di punti sfalsate di un passo, ottenendo le coppie (punto precedente, punto corrente). Nei casi in cui l'intervallo di tempo tra due punti consecutivi supera la soglia `LOST_TIME_THRESHOLD_SECONDS` (impostata a 620 s e corrispondente a circa 10 volte il periodo tipico di trasmissione di un dispositivo AIS di Classe A), la velocità media del secondo punto appena calcolata viene scartata e sostituita con il valore di `SOG`, a condizione che quest'ultimo sia plausibile (inferiore alla soglia `ABSURD_SPEED_THRESHOLD` di 102 nodi). In caso contrario, la velocità viene ricalco-

Tabella 3.2: Ottimizzazione dei tipi di dato.

Colonna	**Tipo originale**	**Nuovo tipo**	**Motivazione**
`MMSI`	`int64`	`int32`	Codificato su 30 bit; valori fino a 999 999 999. Un `int32` ($\approx 2.1 \times 10^9$) è sufficiente.
`LAT`	`float64`	`float64`[(a)]	Tipo invariato. I valori vengono arrotondati a 4 cifre decimali ($\approx$ 10 m di risoluzione) per ridurre il numero di coordinate distinte nelle operazioni di group-by.
`LON`	`float64`	`float64`[(a)]	Stessa giustificazione di `LAT`.
`SOG`	`float64`	`float64`	Tipo invariato.
`COG`	`float64`	`float64`	Tipo invariato.
`Heading`	`float64`	`float64`	Tipo invariato.
`VesselType`	`float64`	`int16`[(b)]	Formalmente 8 bit (0–255), ma il dataset NOAA presenta valori superiori. I `NaN` vengono sostituiti con 0.
`Status`	`float64`	`int8`	Codificato su 4 bit (valori 0–15). I `NaN` vengono sostituiti con 99.
`Length`	`float64`	`int16`	Valore massimo 511 m. I valori frazionari vengono troncati (errore $<$ 1 m). I `NaN` vengono sostituiti con 0.
`Width`	`float64`	`int16`	Stessa giustificazione di `Length`.
`Draft`	`float64`	`float32`	Codificato su 8 bit con risoluzione di 0.1 m, massimo 25.5 m.
`Cargo`	`float64`	`int16`[(b)]	Stessa giustificazione di `VesselType`.
`TransceiverClass`	`object`	`bool`	Assume solo i valori `A` o `B`. Rinominato `IsClassA`.
`BaseDateTime`	`object`	`datetime64[s]`	Conversione da object a tipo temporale nativo di Pandas.

(a) Tipo invariato; l'unica trasformazione è l'arrotondamento a 4 cifre decimali.

(b) Scostamento dalla specifica ITU-R M.1371-6, giustificato dai valori presenti nel dataset NOAA.

lata ancora come rapporto distanza/tempo. Al primo punto di ogni traiettoria, per il quale non esiste un punto precedente, viene assegnato direttamente il valore di `SOG`. I punti con `Avg_Speed` superiore a 102 nodi (e che non fanno scattare la soglia `LOST_TIME_THRESHOLD_SECONDS`) vengono eliminati, in quanto ritenuti il risultato di errori di posizionamento GPS. In totale dal dataset sono stati rimossi 7 record su 5.415.163 che ricadevano in quest'ultima casistica.

A partire da `Avg_Speed`, viene costruita la colonna `EstimatedStatus`, che classifica ogni punto in una delle sei categorie seguenti. Le prime quattro riguardano la gestione dei gap temporali e vengono assegnate durante il calcolo della velocità:

- **lost**: record immediatamente precedente un gap temporale superiore a `LOST_TIME_THRESHOLD_SECONDS`. Indica l'ultimo momento in cui la nave era tracciata prima di scomparire temporaneamente dal sistema.

- **return**: primo record successivo al gap citato al punto precedente. Indica il momento in cui la nave torna visibile dopo una breve interruzione. I punti *lost* e *return* non entrano nella fase di clustering, ma sono utili per la corretta interpretazione delle traiettorie.

- **exit**: record precedente un gap superiore a `EXIT_TIME_THRESHOLD_HOURS` (12 ore). Indica che la nave ha lasciato l'universo di analisi o ha smesso di trasmettere per un periodo prolungato.

- **entry**: primo record successivo al gap citato al punto precedente. Indica il rientro della nave nell'universo di analisi dopo un'assenza significativa.

Gli status *exit* e *entry* vengono assegnati dopo *lost* e *return*, sovrascrivendoli quando il gap supera la soglia più lunga. Le restanti due categorie vengono assegnate in una seconda fase, sui punti che non hanno ancora ricevuto uno status:

- **stationary**: punti con `Avg_Speed` $\leq$ `SPEED_THRESHOLD` (0.5 nodi).

- **sailing**: tutti i punti rimanenti, in navigazione ordinaria.

Al termine, il primo punto di ciascuna traiettoria viene forzato a *entry* e l'ultimo a *exit*, indipendentemente dallo status eventualmente già calcolato. Quando più punti consecutivi risultano tutti *entry* o tutti *exit* (situazione possibile in presenza di gap ravvicinati) viene conservato solo l'ultimo punto *entry* della sequenza e il primo punto *exit*, eliminando i rimanenti.

3.5 Implementazione del framework TREAD e differenze rispetto all'originale

3.5.1 Architettura generale

Il framework TREAD di Pallotta et al. [3] si articola in due macro fasi: *Knowledge Discovery* e *Knowledge Exploitation*. Nella prima fase, il flusso di messaggi AIS viene elaborato per costruire un modello statistico del traffico normale, articolato in tre classi di oggetti: vessel objects (Vs), waypoint objects (WPS) e route objects (Rs). Nella seconda fase, le rotte apprese vengono utilizzate per classificare nuove traiettorie e individuare comportamenti anomali.

La presente implementazione riproduce questa struttura a due fasi. Tuttavia, il processo non è incrementale in senso stretto: anzichè aggiornare il modello messaggio per messaggio come nell'algoritmo originale, l'intero dataset viene caricato in memoria e processato in batch. Questa scelta è stata motivata dai vincoli hardware descritti nella sezione 3.8.

3.5.2 Identificazione dei waypoint: DBSCAN e H-DBSCAN

Il passo centrale della fase di Knowledge Discovery è l'identificazione dei waypoint. In questo contesto, un waypoint viene definito come un'area geografica appartenente all'universo di analisi in cui le navi:

- iniziano a manifestare la propria presenza nell'universo di analisi (entry);
- cessano di manifestare la propria presenza nell'universo di analisi (exit);
- rallentano significativamente, con velocità media inferiore alla soglia `SPEED_THRESHOLD` (0.5 nodi), al di sotto della quale la nave è ritenuta sostanzialmente stazionaria.

A differenza di quanto avviene su terra, in mare è molto difficile per una nave rimanere completamente ferma per via di correnti, vento e onde che spesso causano qualche tipo di movimento. Per questo motivo, anziché cercare punti di velocità nulla, si è deciso di introdurre una soglia (`SPEED_THRESHOLD`) sotto la quale un'imbarcazione è considerata stazionaria. I waypoint non hanno dimensione fissa: ciascuno occupa una porzione dello spazio geografico determinata da come si distribuiscono e da quanti sono i punti che lo compongono. Nella pratica, la maggior parte di essi tende ad occupare un'area molto ridotta rispetto all'universo di analisi. Nell'algoritmo originale l'identificazione dei waypoint viene effettuata tramite un approccio basato su

DBSCAN. La presente implementazione applica prima DBSCAN e poi H-DBSCAN come variante migliorativa (*Hierarchical DBSCAN*).

Preparazione degli input per il clustering

L'input fornito agli algoritmi di clustering è costituito da tutti i punti classificati come *stationary*, *entry* o *exit*, che rappresentano circa il 69,6% del dataset totale.

Per ridurre la dimensione dell'input e superare le limitazioni di memoria dell'implementazione scikit-learn di DBSCAN, il cui costo di memoria è $O(n^2)$, i punti vengono aggregati tramite un'operazione di *group-by* sulle sole coordinate GPS, contando quante volte ogni coppia (`LAT`, `LON`) compare nel dataset. Questa operazione è il motivo per cui si è deciso di arrotondare da 5 a 4 cifre decimali i valori di latitudine e longitudine (vedi Tabella 3.2). Così facendo si riduce il numero di coppie distinte in input all'algoritmo di clustering e allo stesso tempo la perdita di precisione è considerata trascurabile. Infatti, con 5 cifre decimali la risoluzione massima è attorno ad 1 metro; con 4 cifre decimali la risoluzione passa a circa 10 metri. Le somme risultanti dall'operazione di *group-by* vengono utilizzate come *pesi* da associare a ciascuna coordinata, allo scopo di rappresentare la frequenza con cui ogni posizione è stata visitata. Tuttavia si è notato che esistono diversi dispositivi statici (es: boe, stazioni costiere) che, dotati di transponder AIS, restano stazionari in un punto e continuano periodicamente a trasmettere, riempendo il database. Per attenuare lo sbilanciamento tra queste coordinate che all'apparenza sembrano molto visitate e le altre coordinate, i pesi vengono normalizzati applicando il logaritmo base 2 e approssimando il risultato all'intero piu vicino; infine le coordinate con peso zero dopo la trasformazione logaritmica vengono riportate artificialmente a 1. La tabella risultante usata come input per l'applicazione dell'algoritmo di DBSCAN ha circa 52.000 righe, mentre il numero di punti stazionari processati è pari a circa 3.770.000 righe.

DBSCAN

L'algoritmo DBSCAN viene eseguito con i parametri $\varepsilon = 0.075$ e $N_{\min} = 10$, scelti empiricamente in modo da produrre cluster geograficamente coerenti con i porti e i punti di passaggio dell'arcipelago delle Hawaii. Questo passo riproduce l'approccio di Pallotta et al. ed è incluso come riferimento per il confronto con la variante H-DBSCAN.

H-DBSCAN

Il motivo principale per introdurre H-DBSCAN è la sua capacità di identificare cluster di densità variabile, cosa che DBSCAN non riesce a gestire bene. Il traffico nelle Hawaii presenta una densità fortemente eterogenea: i porti principali come Honolulu hanno concentrazioni di punti molto più elevate rispetto a zone di passaggio o porti minori. In questo contesto, i parametri fissi di DBSCAN tendono a sovrasegmentare le aree sparse o a fondere artificialmente cluster distinti nelle aree dense.

Poiché la libreria `hdbscan`[2] non consente di associare i pesi ad ogni punto ma li considera tutti equiponderati, la tabella aggregata viene espansa: ogni coordinata viene replicata un numero di volte pari al suo peso calcolato in precedenza applicando il logaritmo. La tabella espansa conta circa 97.000 righe, ossia poco meno del doppio della tabella utilizzata come input per l'algoritmo DBSCAN. Infine, H-DBSCAN viene eseguito con i parametri min_cluster_size = 30, max_cluster_size = 10 000 e cluster_selection_epsilon = 0.01.

3.5.3 Costruzione dei waypoint e identificazione delle rotte

Una volta determinati i cluster tramite H-DBSCAN, per ciascun cluster viene calcolato il *convex hull* (inviluppo convesso) tramite `scipy.spatial.ConvexHull`. L'inviluppo convesso di ogni cluster definisce il perimetro del waypoint corrispondente, rappresentato come un poligono tramite la libreria Shapely.

Per ogni punto del dataset viene quindi verificato se esso ricade all'interno o sul bordo di uno dei poligoni waypoint, informazione salvata nella colonna `IsInWP`. Il bordo viene incluso perché i vertici dell'inviluppo convesso sono essi stessi punti del dataset: escludendoli, tali punti risulterebbero esterni al waypoint che contribuiscono a definire. Poiché gli inviluppi convessi di cluster diversi possono sovrapporsi, un punto può ricadere in più di un waypoint; in tal caso viene assegnato a quello con indice minore. Per valutare l'impatto di questa scelta, viene inoltre calcolato il numero di punti che ricadono in più di un waypoint. Un waypoint è considerato *significativo* per un dato punto se quest'ultimo soddisfa almeno una delle condizioni seguenti: `Avg_Speed` $\leq$ `SPEED_THRESHOLD`, oppure il suo `EstimatedStatus` è *entry* o *exit*.

L'assegnazione delle rotte avviene una nave alla volta, all'interno di ogni coppia (*entry*, *exit*) identificata nel dataset. A ogni punto viene assegnata un'etichetta secondo la seguente logica:

[2]Libreria esterna `hdbscan` (`https://github.com/scikit-learn-contrib/hdbscan`), distinta dall'implementazione inclusa in scikit-learn.

- se il punto si trova all'interno di un waypoint significativo, l'etichetta corrisponde al nome di quel waypoint;
- se il punto si trova in navigazione tra due waypoint, l'etichetta assume il formato `WP_X -- WP_Y`, dove `WP_X` e `WP_Y` sono rispettivamente il waypoint di provenienza e quello di destinazione; nei casi in cui uno o entrambi non siano identificabili, viene utilizzato il segnaposto `<NA>`.

Con queste ultime operazioni, termina la fase di Knowledge Discovery: ogni punto del dataset ha associata un'etichetta di rotta secondo i criteri appena descritti, e il modello di traffico appreso è pronto per essere utilizzato nella fase di Knowledge Exploitation.

3.6 Anomaly detection

Prima di descrivere la fase di anomaly detection, è opportuno distinguere due concetti fondamentali. Una **rotta** è un'entità astratta che modella il fatto che almeno una volta una nave ha viaggiato dal waypoint di partenza a quello di arrivo (e non il viceversa). Ipotizzando di modellare i waypoint come nodi di un grafo orientato, una rotta sarebbe uno degli archi. Un **trip** indica invece il singolo viaggio compiuto da una specifica nave lungo una rotta. A ogni rotta possono quindi essere associati più trip, tanti quante sono le navi che l'hanno percorsa nel periodo analizzato.

La fase di anomaly detection segue le equazioni del framework TREAD originale [3]. L'analisi si concentra su una singola rotta selezionata (una delle più trafficate tra quelle estratte nella fase precedente) e utilizza i trip associati a tale rotta come unità di analisi.

3.6.1 Decomposizione della velocità e preparazione delle feature

Per ogni punto del dataset vengono calcolate le componenti cartesiane della velocità V_x e V_y a partire da `SOG` e `COG`. Il COG, espresso in gradi rispetto al nord geografico (angolo *bearing*), viene convertito in angolo aritmetico standard tramite la formula $\theta = (450 - \text{COG}) \mod 360$, e poi in radianti. Le componenti risultanti sono:

$$V_x = \text{SOG} \cdot \cos(\theta), \qquad V_y = \text{SOG} \cdot \sin(\theta)$$

Pallotta et al. [3] propongono un approccio alternativo per il calcolo delle stesse componenti, basato sulla funzione arcotangente e sul teorema di Pitagora. Que-

sto approccio presenta alcune criticità. In primo luogo, la funzione arcotangente è definita a meno di un'ambiguità di segno: per ricavare il quadrante corretto della direzione è necessario gestire esplicitamente i casi in cui V_x e V_y assumono segno negativo, introducendo logica condizionale aggiuntiva. In secondo luogo, l'uso combinato di arcotangente e radice quadrata è computazionalmente più oneroso rispetto al calcolo diretto tramite seno e coseno. Infine, l'approccio inverso introduce potenziali errori numerici nelle situazioni limite, come velocità molto prossime a zero, in cui il rapporto tra le componenti diventa instabile. Per questi motivi, nella presente implementazione si è preferito calcolare V_x e V_y direttamente tramite seno e coseno dell'angolo θ, ottenendo un codice più semplice ed efficiente.

3.6.2 Stima della densità tramite Kernel Density Estimation

Per modellare il comportamento normale di una rotta, viene stimata la distribuzione spaziale dei punti tramite *Kernel Density Estimation* (KDE) bivariata sui valori di latitudine e Longitudine (`LON`, `LAT`), usando la funzione `scipy.stats.gaussian_kde`. Viene inoltre calcolata una seconda KDE, pesata per la magnitudine della velocità (`SOG`), che cattura le zone dove le navi transitano tipicamente a velocità elevate. Il prodotto punto per punto delle due KDE (equazione 8 di [3]) fornisce per ogni punto del dataset un valore di densità p_i che combina informazione spaziale e cinematica.

3.6.3 Classificazione dei trip per lunghezza

I trip associati alla rotta selezionata vengono ordinati per lunghezza (numero di punti) in ordine crescente. Questo ordinamento riflette l'assunzione secondo cui i trip più corti sono maggiormente rappresentativi del comportamento normale, mentre i trip più lunghi o devianti hanno una maggiore probabilità di essere anomali; tale assunzione guida l'interpretazione del ranking di anomalia descritto nella sezione successiva, ma l'intero insieme dei trip disponibili viene utilizzato sia per la stima dei parametri del modello sia per il calcolo dello score di anomalia.

3.6.4 Calcolo della probabilità di transizione e anomaly scoring

Il modello di anomaly detection si basa sulla probabilità di transizione tra stati successivi di una traiettoria, modellata tramite una distribuzione di Weibull, seguendo

l'equazione 14 di [3]:

$$p(\Delta p \mid \Delta t) = \exp\left[-\left(\frac{\Delta p}{m \cdot \Delta t}\right)^{\beta}\right]$$

dove Δt è l'intervallo di tempo e Δp è la distanza tra la posizione effettiva e quella predetta tramite il Track Predictor (algoritmo 4 di [3]). Quest'ultimo stima la posizione futura ipotizzando che la nave proceda con la stessa direzione e la stessa velocità dell'ultima osservazione. Lo spostamento viene calcolato a partire dalle componenti della velocità $v_x = \mathrm{SOG}\cos\theta$ (verso est) e $v_y = \mathrm{SOG}\sin\theta$ (verso nord), dove $\theta = (450° - \mathrm{COG}) \bmod 360°$ è la rotta convertita in angolo aritmetico. Lo spostamento, espresso in miglia nautiche, viene convertito in gradi considerando che un miglio nautico corrisponde a 1/60 di grado di latitudine, mentre in longitudine il valore va ulteriormente diviso per cos(lat). La distanza Δp, espressa in metri, è infine calcolata in maniera analoga a quanto descritto nella Sezione 3.4.3. I parametri m e β del modello sono stimati sull'intero insieme di trip disponibili. I parametri vengono stimati calcolando, per un insieme di lag temporali adattativi (da un minimo di 30 s a un massimo di un quinto della durata mediana dei trip), le distribuzioni delle distanze Δp e fittando su ciascuna una distribuzione di Weibull tramite `scipy.stats.weibull_min`. Il parametro di scala $\alpha_k = m \cdot \Delta t$ viene stimato tramite regressione lineare sull'insieme dei valori ottenuti ai diversi lag; il parametro di forma β è preso come media dei valori stimati.

Ad ogni trip viene infine assegnato un punteggio di anomalia come log-somma normalizzata delle probabilità di transizione lungo la traiettoria (equazione 9 di [3]), combinata con la log-probabilità di osservazione derivata dalla KDE (equazione 6) e con la probabilità a priori della rotta (equazione 4). Quest'ultima è stimata, come in [3], come il rapporto tra il numero di navi distinte che percorrono la rotta e il numero totale di navi considerate. Poiché l'analisi è condotta su una sola rotta, la probabilità a priori risulta pari a 1 per tutti i trip e non influisce sul ranking; il termine viene comunque mantenuto nell'implementazione per consentire l'estensione dell'analisi a più rotte. I trip con punteggio più basso sono classificati come potenzialmente anomali.

3.7 Tecnologie utilizzate

L'intera pipeline è implementata in **Python 3**, organizzata in file Jupyter Notebook separati. I parametri di configurazione sono centralizzati in un unico file ".py" a cui hanno accesso tutti i Notebook Jupyter.

Le librerie principali utilizzate sono:

- **Polars**: per sfruttare il multithreading durante l'importazione dei file CSV giornalieri e il filtraggio geografico iniziale;
- **Pandas**: per la manipolazione del dataset nelle fasi successive all'importazione;
- **NumPy**: per i calcoli vettoriali e le operazioni sulle serie temporali;
- **scikit-learn**: per l'implementazione di DBSCAN;
- **hdbscan**: libreria per H-DBSCAN, scelta per le sue prestazioni superiori rispetto all'implementazione scikit-learn nella gestione di cluster di densità variabile;
- **SciPy**: per il calcolo dei convex hull, la Kernel Density Estimation e il fitting della distribuzione di Weibull;
- **Shapely**: per le operazioni geometriche sui poligoni waypoint;
- **GeoPandas**: per la visualizzazione rapida dei poligoni waypoint per verifiche qualitative;
- **Plotly**: per la visualizzazione interattiva dei risultati su mappa geografica.

La scelta di Python è motivata dalla disponibilità di un ecosistema maturo per l'analisi di dati anche geospaziali e la sua relativa facilità di utilizzo.

3.8 Limiti della metodologia

La metodologia presentata in questo capitolo presenta alcuni limiti che è opportuno dichiarare esplicitamente. Un primo limite riguarda la copertura geografica: il dataset del NOAA è limitato alle aree costiere statunitensi, e la tesi si concentra sulle Hawaii, un arcipelago con un traffico relativamente contenuto rispetto ad aree come lo Stretto di Gibilterra o l'Adriatico settentrionale studiate nell'articolo originale di Pallotta et al. [3]. I risultati ottenuti potrebbero quindi non generalizzarsi ad aree con densità di traffico diverse.

Un secondo limite è di natura computazionale: l'implementazione scikit-learn di DBSCAN ha un costo in memoria $O(n^2)$ rispetto al numero di punti in input (si veda il Paragrafo 3.5.2 per i dettagli). La RAM disponibile sulla macchina utilizzata non era sufficiente per eseguire l'algoritmo direttamente sui punti grezzi del dataset, rendendo necessaria una fase di pre-aggregazione per coordinate GPS

e, per H-DBSCAN, un'ulteriore espansione della tabella dei pesi. Questo livello aggiuntivo di elaborazione non comporta una perdita di informazione sul dataset nel suo complesso ma rappresenta comunque un vincolo imposto dall'hardware, che con risorse maggiori non sarebbe stato necessario.

Un ulteriore limite, intrinseco alla tecnologia AIS stessa e già discusso nel Capitolo 2, riguarda la natura dei dati alla fonte. Il sistema AIS traccia esclusivamente le imbarcazioni che montano e utilizzano attivamente il transponder: l'obbligo di installazione, imposto dalla convenzione SOLAS, si applica infatti solo alle navi con stazza lorda superiore a una certa soglia e alle navi passeggeri [1]. Il naviglio minore (imbarcazioni da diporto, pescherecci di piccole dimensioni, mezzi non commerciali) non è quindi soggetto a tale obbligo e risulta nella maggior parte dei casi del tutto assente dal dataset. Ne consegue che il modello di traffico appreso descrive esclusivamente il comportamento delle imbarcazioni di maggiori dimensioni, mentre eventuali pattern di traffico generati dal naviglio minore restano completamente invisibili. A questo si aggiungono i limiti di qualità del dato già discussi nel Capitolo 2, quali le lacune di copertura dei ricevitori terrestri e la possibilità di manipolazione dei messaggi tramite spoofing o spegnimento volontario del transponder [2], fattori che, seppur non specificamente analizzati in questa tesi, contribuiscono al divario tra il traffico realmente presente nell'area e quello effettivamente osservabile tramite AIS.

3.9 Sintesi e anticipazione dei risultati

Il capitolo ha descritto la metodologia adottata per replicare, adattare e estendere il framework TREAD di Pallotta et al. su dati AIS reali relativi alle Hawaii. La pipeline comprende una fase di pre-processing (importazione, pulizia e ottimizzazione, calcolo della velocità media e classificazione degli stati), la fase di Knowledge Discovery con il doppio utilizzo di DBSCAN e H-DBSCAN per l'identificazione dei waypoint e la successiva assegnazione delle rotte, e infine una fase di anomaly detection basata su KDE e distribuzione di Weibull.

Le principali differenze rispetto all'algoritmo originale sono: l'adozione di H-DBSCAN al posto di DBSCAN incrementale, motivata dalla necessità di gestire cluster a densità variabile; l'approccio batch in luogo di quello incrementale, imposto dai vincoli hardware; l'introduzione della normalizzazione per lunghezza del trip nel calcolo del punteggio di anomalia, non presente nell'originale.

Il Capitolo 4 presenterà i risultati ottenuti: i waypoint identificati, le rotte estratte, i parametri del modello Weibull stimati e il ranking di anomalia dei trip sulla rotta selezionata.

Capitolo 4

Risultati

Questo capitolo presenta i risultati ottenuti applicando la pipeline descritta nel Capitolo 3 al dataset AIS delle Hawaii. I risultati sono organizzati in quattro sezioni: la prima descrive il dataset nelle sue dimensioni finali dopo il pre-processing; la seconda mostra i risultati qualitativi prodotti dalla fase di Knowledge Discovery; la terza riporta i risultati quantitativi della fase di anomaly detection; la quarta ne discute l'interpretazione e le implicazioni.

4.1 Dataset

Il dataset utilizzato comprende i messaggi AIS ricevuti dal NOAA nel primo trimestre del 2019 (gennaio-marzo inclusi), filtrati sull'area geografica delle Hawaii tramite la bounding box descritta nella Sezione 3.3.

4.1.1 Dimensioni e composizione

I dati grezzi, dopo il filtraggio geografico, ammontano a 5.462.415 record. A seguito della rimozione dei duplicati esatti il dataset si riduce a 5.460.800 record, generati da 602 imbarcazioni distinte (in media 9.071 record per nave, con un minimo di 1 e un massimo di 82.554).

L'applicazione della soglia dinamica sull'attività delle imbarcazioni (Sezione 3.4), pari al 10% del numero medio di record per nave e quindi a 907 record, ha eliminato 199 imbarcazioni, corrispondenti allo 0,84% dei record totali. Il dataset risultante conta 5.415.168 record relativi a 403 imbarcazioni, sulle quali si osservano le seguenti statistiche sul numero di record per nave: media di 13.437 record, deviazione standard di 16.309, con un massimo di 82.554 e un minimo di 921 record per singola imbarcazione.

Dopo la fase di ottimizzazione della memoria, il dataset è passato da circa 702 MB a circa 465 MB, con un risparmio prossimo al 34%.

4.1.2 Classificazione degli stati e punti stazionari

Nella fase di classificazione degli stati di navigazione, 7 record sono stati rimossi in quanto associati a velocità istantanee non plausibili (superiori a 102 nodi), portando il dataset a 5.415.156 record complessivi. Di questi, 3.766.844 punti sono stati classificati come stazionari (comprendendo gli stati *stationary*, *entry* ed *exit*), e costituiscono l'insieme di partenza per la fase di Knowledge Discovery. L'aggregazione di questi punti per coordinate ha prodotto 51.801 coppie di coordinate distinte.

4.1.3 Waypoint e rotte estratte

Il clustering H-DBSCAN applicato ai punti stazionari aggregati ha identificato 144 waypoint distinti (da `WP_0` a `WP_143`). I punti che ricadono in più di un waypoint, a causa della sovrapposizione degli inviluppi convessi, sono 7.298, pari allo 0,135% del dataset: l'effetto della regola di assegnazione descritta nella Sezione 3.5.3 è quindi trascurabile. A partire da questi waypoint, sono state estratte in tutto 910 rotte distinte e 35.731 trip.

Per la fase di anomaly detection è stata selezionata la rotta `WP_135 - WP_118`, una delle più trafficate tra quelle estratte, percorsa da 40 imbarcazioni distinte per un totale di 184 trip. La lunghezza dei trip (in numero di punti) presenta una media di 110,0, una mediana di 95,5, un minimo di 41 e un massimo di 524 punti.

4.2 Risultati qualitativi

Questa sezione mostra gli output visivi prodotti dalla fase di Knowledge Discovery, con l'obiettivo di verificare che i waypoint e le rotte estratte corrispondano a strutture geograficamente coerenti con il traffico marittimo dell'arcipelago delle Hawaii.

4.2.1 Waypoint identificati

Le Figure 4.1 e 4.2 mostrano i cluster di punti stazionari ottenuti rispettivamente con DBSCAN ($\varepsilon = 0.075$, $N_{\min} = 10$) e con H-DBSCAN (min_cluster_size = 30, max_cluster_size = 10 000), con i parametri descritti nella Sezione 3.5.2. In entrambe le figure i punti in blu sono quelli assegnati a un cluster, i punti bianchi

sono quelli classificati come rumore, e il contorno nero di ogni cluster è il relativo *convex hull*, che definisce l'area del waypoint. Il riquadro rosso è la bounding box dell'area di studio. La scala di colore indica il peso di ciascuna coordinata aggregata, pari al logaritmo in base 2 del numero di messaggi AIS che vi ricadono, arrotondato all'intero più vicino (Sezione 3.5.2); si tratta quindi di una grandezza adimensionale.

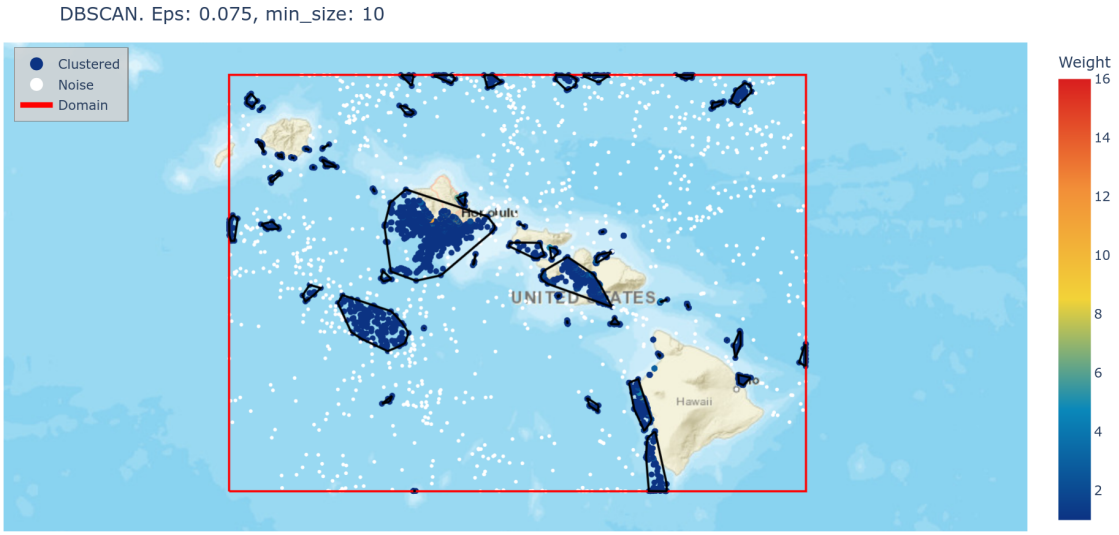


Figura 4.1: Waypoint identificati con DBSCAN ($\varepsilon = 0.075$, $N_{\min} = 10$).

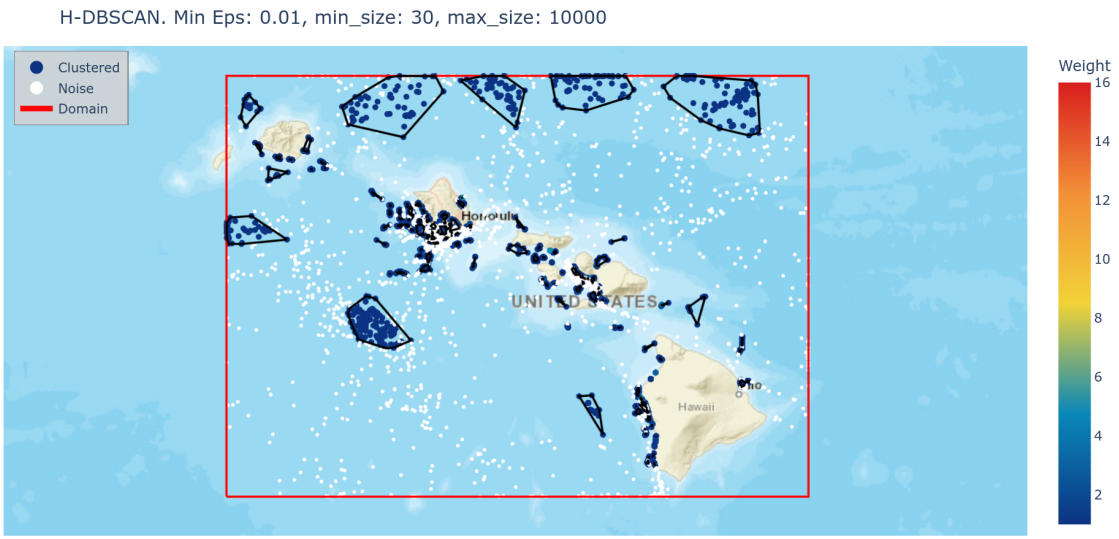


Figura 4.2: Waypoint identificati con H-DBSCAN (min_cluster_size = 30, max_cluster_size = 10 000).

DBSCAN individua 55 cluster e classifica come rumore 1.001 delle 51.801 coordinate aggregate (1,93%); H-DBSCAN, eseguito sulla tabella espansa secondo i pesi (Sezione 3.5.2), individua 144 cluster e ne scarta 2.800 su 96.913 (2,89%). Il confronto mette in evidenza il limite principale di DBSCAN con un raggio ε fisso. Nell'area

del porto di Honolulu e le zone di ancoraggio vicine, la densità di punti stazionari è molto alta, e DBSCAN raggruppa tutta la zona in un unico grande cluster che copre buona parte dell'isola. Lo stesso succede lungo la costa occidentale dell'isola Maui e lungo la costa di Kona sull'isola di Hawaii, dove punti di sosta distinti vengono fusi in poligoni allungati. Un waypoint di queste dimensioni non è utile per l'estrazione delle rotte, perché fa coincidere in un solo nodo del grafo origini e destinazioni che invece sono diverse.

H-DBSCAN, potendo adattarsi a densità locali diverse, scompone le stesse aree in molti cluster più piccoli e compatti, che corrispondono in modo più plausibile a singoli porti, moli e zone di ancoraggio. Nelle zone a bassa densità in mare aperto, invece, entrambi gli algoritmi producono cluster di dimensioni simili (ad esempio il cluster a sud-ovest di Oahu e quelli lungo il bordo settentrionale della bounding box). Per questo motivo H-DBSCAN è stato adottato come approccio principale per le fasi successive della pipeline.

4.2.2 Rotte estratte

4.2.3 Trip sulla rotta selezionata

4.3 Risultati quantitativi

4.3.1 Parametri del modello Weibull

I parametri della distribuzione di Weibull, stimati sull'intero insieme di 184 trip della rotta selezionata (Sezione 3.6), risultano pari a $m = 1{,}3105$ (coefficiente della relazione $\alpha = m \cdot \Delta t$ tra parametro di scala e intervallo temporale) e $\beta = 0{,}9358$ (parametro di forma medio).

4.3.2 Anomaly scoring e ranking dei trip

Applicando il modello ai 184 trip della rotta selezionata, i dieci trip con probabilità combinata più alta (comportamento più regolare) sono, in ordine decrescente: i trip 23184, 24337, 23474, 8857, 11128, 14569, 8374, 15733, 25609 e 11307, con punteggi compresi tra 3134,05 e 2534,98.

I dieci trip con probabilità combinata più bassa (candidati più probabili come anomalie) sono, in ordine crescente di punteggio: il trip 3372 (211,39, il più anomalo), seguito dai trip 3413, 3362, 10288, 30627, 10279, 24701, 7889, 30752 e 28433, con punteggi fino a 1196,21.

4.3.3 Metriche di valutazione

4.4 Interpretazione dei risultati

4.5 Sintesi

Capitolo 5

Conclusions

Conclusioni, in cui indico in che modo il mio lavoro ha portato delle migliorie ed eventualmente quali aspetti possono/devono essere ancora esplorati/approfonditi

5.1 Sezione 1 - Sintesi dei contributi principali

Testo Sezione 1

5.2 Sezione 2 - Migliorie ottenute

Testo sezione 2

5.3 Sezione 3 - Limititazioni/difetti

Testo sezione 3

5.4 Sezione 4 - Sviluppi futuri

Testo Sezione 4

5.5 Sezione 5 - Conclusione finale

Bibliografia

[1] International Maritime Organization. Regulations for carriage of ais, 2000. Disponibile: https://www.imo.org/en/ourwork/safety/pages/ais.aspx. Accessed: 2026-04-12.

[2] Konrad Wolsing, Linus Roepert, Jan Bauer, and Klaus Wehrle. Anomaly detection in maritime ais tracks: A review of recent approaches. *Journal of Marine Science and Engineering*, 10, 01 2022. doi: 10.3390/jmse10010112.

[3] Giuliana Pallotta, Michele Vespe, and Karna Bryan. Vessel pattern knowledge discovery from ais data: A framework for anomaly detection and route prediction. *Entropy*, 15(6):2218–2245, Jun 2013. doi: 10.3390/e15062218.

[4] Richard Lane, David Nevell, Steve Hayward, and T.W. Beaney. Maritime anomaly detection and threat assessment. pages 1 – 8, 08 2010. doi: 10.1109/ICIF.2010.5711998.

[5] Steven Mascaro, Ann E. Nicholso, and Kevin B. Korb. Anomaly detection in vessel tracks using bayesian networks. *International Journal of Approximate Reasoning*, 55:84–98, 2014. doi: 10.1016/j.ijar.2013.03.012. URL https://doi.org/10.1016/j.ijar.2013.03.012.

[6] Kira Kowalska and L. Peel. Maritime anomaly detection using gaussian process active learning. pages 1164–1171, 01 2012. ISBN 978-1-4673-0417-7.

[7] Wikipedia. National oceanic and atmospheric administration. https://it.wikipedia.org/wiki/National_Oceanic_and_Atmospheric_Administration, 2026. Ultimo accesso: 02/06/2026.

[8] International Telecommunication Union. Recommendation ITU-R M.1371-6: Technical characteristics for VHF automatic identification system using time division multiple access in the maritime mobile service. ITU-R Recommendation M.1371-6, ITU Radiocommunication Sector, 2 2026. URL https://www.itu.int/rec/R-REC-M.1371/en.