Università degli Studi di Bergamo

Dipartimento di Ingegneria Gestionale, dell'Informazione e della Produzione

Corso di Laurea Magistrale in Ingegneria Informatica
Classe n. LM-32 – Ingegneria Informatica



Titolo vero della tesi

Relatore:
Chiar.mo Prof. Mirko Mazzoleni

Correlatore:
eventuale correlatore

Tesi di Laurea Magistrale

Federico Panzeri
Matricola n. 123456

Anno Accademico 2025/2026

Sommario

Riassunto di quanto svolto, da fare alla fine

Indice

1 Introduzione **1**

1.1 Il sistema AIS 1

1.2 Il problema dei comportamenti anomali 1

1.3 L'approccio: il framework TREAD 2

1.4 Obiettivi e quesiti di ricerca 2

1.5 Caso di studio e contributi 3

1.6 Struttura della tesi 4

2 Stato dell'arte **5**

2.1 Contesto della tesi 5

2.1.1 Storia e funzionamento dell'AIS 5

2.1.2 Dati trasmessi 6

2.1.3 Limiti e problemi noti 6

2.2 Panoramica degli approcci di anomaly detection 6

2.2.1 Approcci di Machine Learning 7

2.2.2 Approcci Stocastici 8

2.2.3 Approcci Geometrici 9

2.3 Il framework TREAD di Pallotta et al. 9

3 Metodologia **10**

3.1 Introduzione 10

3.2 Dataset 10

3.2.1 Struttura del dataset 11

3.2.2 Qualità dei dati 14

3.3 Pre-processing dei dati 14

3.3.1 Importazione, filtraggio geografico e rimozione dei duplicati . . 14

3.3.2 Ottimizzazione della memoria 15

3.3.3 Calcolo della velocità media e classificazione degli stati 15

3.4 Implementazione del framework TREAD e differenze rispetto all'originale . . . 18
3.4.1 Architettura generale . . . 18
3.4.2 Identificazione dei waypoint: DBSCAN e H-DBSCAN . . . 18
3.4.3 Costruzione dei waypoint e identificazione delle rotte . . . 21
3.5 Anomaly detection . . . 22
3.5.1 Il modello probabilistico di riferimento . . . 23
3.5.2 Decomposizione della velocità . . . 24
3.5.3 Termine di osservazione . . . 25
3.5.4 Termine di transizione . . . 26
3.5.5 Punteggio di normalità . . . 28
3.6 Tecnologie utilizzate . . . 29
3.7 Limiti della metodologia . . . 30
3.8 Sintesi e anticipazione dei risultati . . . 31

4 Risultati **32**
4.1 Dataset . . . 32
4.1.1 Dimensioni e composizione . . . 32
4.1.2 Classificazione degli stati e punti stazionari . . . 33
4.1.3 Waypoint e rotte estratte . . . 33
4.2 Risultati qualitativi . . . 33
4.2.1 Waypoint identificati . . . 34
4.2.2 Rotte estratte . . . 35
4.2.3 Trip sulla rotta selezionata . . . 43
4.3 Risultati quantitativi . . . 44
4.3.1 KDE . . . 44
4.3.2 Parametri del modello Weibull . . . 45
4.3.3 Punteggio di normalità e ranking dei trip . . . 46
4.3.4 Metriche di valutazione . . . 49
4.4 Interpretazione dei risultati . . . 52
4.5 Sintesi . . . 54

5 Conclusioni **55**
5.1 Sezione 1 - Sintesi dei contributi principali . . . 55
5.2 Sezione 2 - Migliorie ottenute . . . 55
5.3 Sezione 3 - Limititazioni/difetti . . . 55
5.4 Sezione 4 - Sviluppi futuri . . . 55
5.5 Sezione 5 - Conclusione finale . . . 55

Bibliografia **57**

Elenco delle figure

3.1 Portale NOAA *AccessAIS* per il download di dati AIS. 11
3.2 Rappresentazione cartesiana di un record AIS. 13
3.3 Estratto del dataset di partenza. 13
3.4 Punti della rotta selezionata (in grigio) e stato di raggio $d = 500$ m di un punto scelto a caso (in rosso). 26
3.5 Schema dell'errore di predizione. 27

4.1 Waypoint identificati con DBSCAN. 34
4.2 Waypoint identificati con H-DBSCAN. 35
4.3 Grafo delle rotte tra waypoint distinti con almeno 10 trip. 36
4.4 Grafo delle rotte tra waypoint distinti senza soglia sul numero di trip, senza i numeri accanto alle frecce. 37
4.5 Ingrandimento del grafo delle rotte sul canale tra le isole di Maui e Lanai. 37
4.6 Ingrandimento del grafo delle rotte sulla costa meridionale dell'isola di Oahu. 38
4.7 Ingrandimento del grafo delle rotte sul porto di Honolulu (`WP_135`). . 38
4.8 Self-loop del porto di Honolulu (`WP_135`) che restano all'interno del waypoint. 39
4.9 Self-loop del porto di Honolulu (`WP_135`) che escono almeno una volta dal waypoint. 40
4.10 Waypoint dell'isola di Oahu con almeno 10 trip che escono dal waypoint e vi ritornano. 41
4.11 Waypoint delle isole di Maui, Lanai e Molokai con almeno 10 trip che escono dal waypoint e vi ritornano. 41
4.12 Waypoint della costa di Kona, sull'isola di Hawaii, con almeno 10 trip che escono dal waypoint e vi ritornano. 42
4.13 Trip con origine non classificata (`<NA>` → WP, in blu) e con destinazione non classificata (WP → `<NA>`, in arancione). 42

4.14 Punti dei 184 trip della rotta `WP_135 - WP_118`, colorati in base alla velocità media (campione di 5.000 punti su 20.241). 43
4.15 Ingrandimento della rotta selezionata all'uscita dal porto di Honolulu. 44
4.16 KDE spaziale dei punti della rotta `WP_135 - WP_118`. 44
4.17 KDE dei punti della rotta `WP_135 - WP_118` pesata per la velocità (`SOG`). 45
4.18 Somma L_i dei logaritmi delle densità nell'intorno di 500 m di ogni punto della rotta `WP_135 - WP_118`. 46
4.19 Distribuzioni delle distanze Δp tra posizione prevista e posizione osservata per ciascun lag temporale, con la distribuzione di Weibull stimata. 47
4.20 A sinistra, parametri di scala stimati ai diversi lag e retta di regressione $\alpha = m \cdot \Delta t$; a destra, probabilità di transizione per tre lag temporali. 47
4.21 Distribuzione sui 184 trip della rotta selezionata del termine di transizione (a sinistra) e del punteggio di normalità (a destra). 48
4.22 I cinque trip con punteggio più alto (in rosso) e i cinque con punteggio più basso (in blu) sulla rotta `WP_135 - WP_118`, colorati in base al punteggio. 49
4.23 Matrici di confusione con la soglia di Tukey, considerando tutte le anomalie (a) e le sole route deviation (b). 51
4.24 Curve ROC del punteggio di normalità considerando tutte le anomalie e le sole route deviation. 52

Elenco delle tabelle

3.1 Struttura del dataset AIS del NOAA. 12
3.2 Ottimizzazione dei tipi di dato. 16

4.1 I dieci trip con punteggio più alto e i dieci con punteggio più basso sulla rotta `WP_135 - WP_118`. 48
4.2 Metriche di valutazione con la soglia di Tukey ($s = 1.035{,}48$) nei due casi considerati. 51

Capitolo 1

Introduzione

1.1 Il sistema AIS

L'Automatic Identification System (AIS) è un sistema di trasmissione e ricezione dati utilizzato in maniera diffusa sia da imbarcazioni commerciali che da diporto. Nasce con lo scopo di migliorare la sicurezza della navigazione riducendo il rischio di collisioni e, con l'evolversi della tecnologia, assume anche un ruolo legato al tracciamento delle imbarcazioni. Dal 2004 l'International Maritime Organization (IMO) ne ha reso obbligatoria l'installazione su tutte le navi passeggeri e sulle navi commerciali al di sopra di una certa stazza [1].

Al di là di queste finalità operative, l'AIS rappresenta oggi una fonte ricca di informazioni per lo studio dei comportamenti delle navi. Ogni nave trasmette periodicamente la propria posizione, la velocità, la direzione del moto, lo stato di navigazione e altre caratteristiche statiche, come tipo e dimensioni. La frequenza di trasmissione varia con la velocità e lo stato della nave, da pochi secondi a qualche minuto; i dati utilizzati in questa tesi, come si vedrà, sono invece campionati a un record al minuto. Grazie alla larga adozione del sistema, anche aree circoscritte ma trafficate generano grandi moli di dati, che per vastità, rumorosità e complessità richiedono tecniche automatiche per essere analizzate.

1.2 Il problema dei comportamenti anomali

Tra le informazioni che si possono estrarre dai dati AIS, una delle più utili è la segnalazione dei comportamenti anomali, cioè dei movimenti che si discostano da quelli abituali. Una nave che devia dal percorso solito tra due porti, che si ferma in un punto insolito o che conclude il proprio viaggio lontano da un porto può essere in difficoltà, oppure coinvolta in attività illecite come il contrabbando o la pesca

in aree protette. Questa tesi si concentra sulla prima di queste situazioni, la *route deviation* (deviazione dalla rotta), che è anche la tipologia di anomalia più studiata in letteratura; le altre categorie sono descritte nel Capitolo 2.

In linea di massima riconoscere queste situazioni a mano è complicato e spesso richiede competenze ed esperienze specifiche. Inoltre, non esiste un elenco di casi già classificati come normali o anomali da cui partire. Servono quindi metodi *non supervisionati*, in grado di apprendere dai soli dati storici che cosa sia il comportamento normale e di segnalare ciò che se ne discosta.

1.3 L'approccio: il framework TREAD

Il metodo adottato è il framework TREAD (Traffic Route Extraction and Anomaly Detection), proposto da Pallotta et al. [2] e pubblicato nel 2013. L'idea di base è la seguente: dai dati storici si individuano prima i *waypoint*, cioè le aree in cui le navi si fermano (ad esempio aree portuali) oppure entrano o escono dall'area di studio. I percorsi seguiti dalle navi da un waypoint all'altro definiscono poi le *rotte*, e ogni singolo viaggio compiuto da una nave lungo una rotta prende il nome di *trip*. A ogni trip viene infine assegnato un punteggio che risponde a due domande: i punti del trip si trovano dove passano di solito le navi di quella rotta? Il moto da un punto al successivo è prevedibile a partire dalla posizione e dalla velocità precedenti? Un trip che passa per zone poco frequentate, o che si muove in modo difficile da prevedere, ottiene un punteggio che lo distingue dai trip normali.

Il metodo risale a più di dieci anni fa ed è stato sviluppato con le tecnologie dell'epoca. L'obiettivo della tesi è di riproporlo, implementandolo di nuovo con gli strumenti oggi disponibili e applicandolo a un dataset AIS di grandi dimensioni. Il metodo è ripreso nella sua struttura generale, mentre alcuni passaggi sono stati adattati o migliorati.

1.4 Obiettivi e quesiti di ricerca

I quesiti di ricerca su cui è stato sviluppato il lavoro sono i seguenti:

1. Il framework TREAD, sviluppato agli inizi degli anni 2010, è ancora applicabile con gli strumenti attuali a un dataset AIS reale di milioni di record?

2. Quali aspetti e caratteristiche dell'algoritmo sono "riciclabili" e quali hanno richiesto adattamenti o sostituzioni?

3. Quali passaggi del metodo originale possono essere migliorati con gli strumenti attuali?

4. Quali metriche è opportuno utilizzare per quantificare le prestazioni dell'algoritmo?

1.5 Caso di studio e contributi

I dati utilizzati sono i messaggi AIS pubblicati dal NOAA (National Oceanic and Atmospheric Administration), l'agenzia statunitense che tra i suoi compiti ha il monitoraggio oceanico. Sono stati preferiti ad altre fonti perché sottoposti dall'ente a un controllo di qualità, e perché gli attributi statici delle navi sono verificati sul registro ufficiale della Guardia Costiera statunitense [3]. L'area oggetto di studio è l'arcipelago delle Hawaii, scelto perchè è una zona circoscritta ma con un traffico intenso ed eterogeneo, che va dai pescherecci alle navi mercantili e passeggeri, fino ai rimorchiatori e alle imbarcazioni da diporto. Il periodo analizzato copre i mesi da gennaio a marzo 2019. La durata di tre mesi è dettata dall'hardware disponibile; l'anno 2019 è stato scelto in quanto ultimo prima della pandemia di Covid-19, così da evitare possibili effetti della pandemia sul traffico marittimo. Il metodo viene infine valutato su una singola rotta, quella tra il porto di Honolulu e il porto di Kalaeloa, entrambi sull'isola di Oahu. Tra le rotte più frequentate è stata scelta questa perché percorsa in modo molto regolare, condizione che rende ben definito il comportamento normale e quindi più riconoscibili le deviazioni.

Rispetto al lavoro originale, la tesi apporta i seguenti contributi:

- la re-implementazione dell'intera pipeline in Python, con librerie moderne per la gestione di grandi volumi di dati;
- l'identificazione dei waypoint tramite H-DBSCAN, in grado di gestire aree a densità di traffico molto diversa, al posto di DBSCAN;
- un calcolo diretto delle componenti della velocità;
- una valutazione quantitativa del punteggio tramite un insieme di trip etichettati manualmente, assente nel lavoro originale.

La tesi è stata svolta nell'ambito del progetto europeo KOIOS[1], i cui fondi hanno finanziato la proposta di questo argomento di tesi.

[1] `https://www.koiosproject.eu/`

1.6 Struttura della tesi

Il resto della tesi è organizzato come segue.

- Il Capitolo 2 descrive il funzionamento del sistema AIS, le tipologie di anomalia e i principali approcci di anomaly detection presenti in letteratura, tra cui il framework TREAD.
- Il Capitolo 3 descrive il dataset, il pre-processing dei dati, l'implementazione delle fasi di identificazione dei waypoint e delle rotte e la fase di anomaly detection, evidenziando le differenze rispetto al lavoro originale.
- Il Capitolo 4 presenta i risultati ottenuti sul dataset delle Hawaii e la valutazione del punteggio di normalità sulla rotta selezionata.
- Il Capitolo 5 riassume il lavoro svolto, ne discute i limiti e indica i possibili sviluppi futuri.

Capitolo 2

Stato dell'arte

2.1 Contesto della tesi

L'obiettivo di questo capitolo è quello di esplorare lo stato dell'arte delle tecniche di analisi dei dati AIS per il rilevamento di anomalie nel traffico marittimo, cercando di fornire una panoramica generale.

2.1.1 Storia e funzionamento dell'AIS

L'Automatic Identification System (AIS) è un sistema di comunicazione utilizzato nella navigazione marittima. La sua origine viene generalmente attribuita a Benny Pettersson, che sviluppò un primo prototipo nei primi anni '90. Inizialmente venne concepito per ridurre il rischio di collisioni in mare in condizioni di scarsa visibilità; l'efficacia di tale strumento e il riconoscimento formale da parte dell'International Maritime Organization (IMO) hanno fatto si che tale sistema venisse progressivamente adottato a livello internazionale. Nell'ambito dell'accordo SOLAS, l'installazione dell'AIS è diventata obbligatoria per le navi con stazza lorda superiore a 300 tonnellate impegnate in viaggi internazionali e per tutte le navi passeggeri [1].

Dal punto di vista tecnico, l'AIS opera su due canali radio VHF intorno ai 162 MHz e utilizza il protocollo TDMA (Time-Division Multiple Access), che consente a più imbarcazioni di trasmettere senza interferire tra loro [4]. La copertura, in condizioni standard, arriva fino a circa 50 km (linea di vista), mentre l'integrazione di un collegamento via satellite (S-AIS) consente di estenderla anche alle acque oceaniche [4]. La frequenza di trasmissione dei messaggi non è costante, ma varia in funzione della velocità e dello stato della nave, passando da pochi secondi a diversi minuti [4].

2.1.2 Dati trasmessi

I messaggi AIS possono essere suddivisi in tre categorie principali [4]:

- **Dati statici**: includono informazioni identificative della nave, come MMSI, nome, tipo e dimensioni.
- **Dati dinamici**: descrivono lo stato corrente della navigazione, tra cui posizione GPS, velocità (SOG), rotta (COG), orientamento della prua (HE), variazione della rotta (ROT) e stato operativo.
- **Dati di viaggio**: comprendono informazioni aggiuntive come pescaggio, tipo di carico, destinazione ed tempo stimato di arrivo (ETA). Essendo inseriti manualmente, risultano generalmente meno affidabili [2].

Ai fini dell'analisi del comportamento delle navi, i dati dinamici sono in genere i più rilevanti, in quanto descrivono in modo continuo l'evoluzione delle traiettorie.

2.1.3 Limiti e problemi noti

Nonostante la ricchezza informativa, i dati AIS presentano diverse criticità che ne complicano l'analisi. Dal punto di vista della qualità, possono verificarsi lacune nella copertura dovute a limiti dei ricevitori terrestri o a interferenze, soprattutto in aree molto trafficate [2].

Inoltre, il protocollo AIS non prevede meccanismi di autenticazione o cifratura, rendendo possibile la manipolazione dei dati, ad esempio tramite spoofing o spegnimento del transponder [4]. Un ulteriore problema è rappresentato dalla diversa frequenza di trasmissione tra le varie classi di imbarcazioni, che introduce una certa eterogeneità nei dataset.

2.2 Panoramica degli approcci di anomaly detection

La letteratura sull'anomaly detection nei dati AIS è stata raccolta e sistematizzata da Wolsing et al. [4], che analizza 44 contributi pubblicati tra il 2007 e il 2021. Prima di esplorare i possibili approcci risolutivi, è utile adottare un'opportuna classificazione delle potenziali anomalie da rilevare tramite l'analisi dei dati AIS. Nell'ambito di questo lavoro di tesi tale classificazione viene presa da Lane et al. [5].

Di seguito le 5 tipologie di anomalie:

1. **Deviazione dalla rotta** (*route deviation*): la nave percorre un tragitto insolito rispetto alla rotta tipicamente più breve tra due porti, compatibilmente con i vincoli fisici e normativi. È la tipologia di anomalia più studiata in letteratura [4] e rappresenta il focus principale di questo lavoro.

2. **Attività AIS inaspettata** (*unexpected AIS activity*): comprende l'accensione o lo spegnimento improvviso del transponder AIS (che può indicare il tentativo di nascondere la posizione della nave) nonché la modifica dei dati identificativi trasmessi, come il nome o codice identificativo MMSI.

3. **Arrivo in porto inaspettato** (*unexpected port arrival*): una nave approda in un porto non previsto o incoerente rispetto alla destinazione dichiarata o alla rotta storica. Questo comportamento può essere indicativo di attività illecite quali il contrabbando, l'evasione dei controlli doganali oppure essere associato ad errori o dimenticanze nella compilazione dei dati di viaggio.

4. **Avvicinamento ravvicinato** (*close approach*): due navi si portano a distanza molto ridotta l'una dall'altra al di fuori di contesti in cui sia legittimo farlo (ad esempio le aree portuali), il che potrebbe indicare il tentativo di nascondere il trasferimento di merci o persone.

5. **Ingresso in zona** (*zone entry*): una nave entra in un'area geografica soggetta a restrizioni, sorveglianza speciale o nota per attività illegali (ad esempio zone di pesca protette o aree riservate a determinate imbarcazioni).

Nel resoconto prodotto dall'analisi sistematica condotta da Wolsing et al. [4] sui vari approcci risolutivi, si evince come la maggior parte dei contributi adotta una struttura in due fasi: prima viene costruito un modello del traffico normale a partire dai dati storici, poi si identificano le traiettorie che si discostano da quel modello come potenziali anomalie.

Infine, i lavori esaminati vengono classificati in tre macro categorie principali, a cui si aggiungono approcci ibridi che combinano più metodologie.

2.2.1 Approcci di Machine Learning

Gli approcci basati su machine learning comprendono principalmente metodi di clustering e reti neurali. Tra i primi, DBSCAN è particolarmente diffuso, in quanto si adatta bene alla natura spaziale dei dati e consente di identificare cluster senza specificarne a priori il numero. Un esempio rappresentativo è il framework TREAD di Pallotta et al. [2], che applica l'algoritmo DBSCAN in maniera incrementale per

individuare i "waypoint" caratteristici del traffico (principalmente porti, piattaforme offshore, punti di ingresso e uscita dall'area monitorata). Le nuove rotte vengono confrontate con il modello appreso fino a quel momento e, se la loro probabilità rispetto alle rotte già note risulta bassa, vengono scartate.

Le reti neurali, invece, permettono di modellare relazioni più complesse e non lineari, e nelle versioni più recenti hanno mostrato buone prestazioni.

Questi approcci risultano scalabili e relativamente semplici da implementare, ma presentano anche alcuni limiti, tra cui la scarsa interpretabilità (soprattutto per le reti neurali) e la difficoltà di generalizzazione a contesti geografici diversi [6].

2.2.2 Approcci Stocastici

Gli approcci stocastici modellano il comportamento delle navi come un processo probabilistico. Tra le tecniche più comuni si trovano GMM, KDE, Gaussian Process e reti bayesiane.

In generale, questi metodi stimano la distribuzione delle traiettorie normali a partire dai dati storici e classificano come anomale quelle con bassa probabilità. Offrono una buona base teorica e permettono di quantificare l'incertezza, ma possono risultare onerosi dal punto di vista computazionale su dataset molto grandi.

Alcuni lavori, come quello di Kowalska et al. [7], mostrano l'efficacia dei Gaussian Process. In particolare nel loro lavoro Kowalska et al. propongono un modello non parametrico basato su un Gaussian Process per apprendere il comportamento normale delle navi a partire dai dati AIS. Il loro modello assegna a ciascuna trasmissione ricevuta una misura di normalità in funzione della velocità osservata rispetto alla posizione geografica: le navi con comportamento inusuale ottengono uno score elevato e vengono prioritizzate per un'analisi più approfondita. Per rendere il metodo applicabile a dataset di grandi dimensioni, gli autori introducono una strategia di "active learning" che seleziona automaticamente un sottoinsieme informativo dei dati per l'addestramento, riducendo il costo computazionale senza compromettere le prestazioni.

Mascaro et al. [6] mostrano invece come le reti bayesiane possano essere interessanti per la loro maggiore interpretabilità, pur presentando difficoltà di scalabilità. In particolare, nel loro lavoro, apprendono reti bayesiane direttamente dai dati AIS, producendo modelli dinamici (che catturano l'evoluzione della traiettoria passo dopo passo) e modelli statici basati su un riassunto dell'intera rotta. I due approcci mostrano punti di forza complementari: il modello dinamico risulta più efficace nel rilevare anomalie localizzate nel tempo, mentre quello statico cattura meglio pattern

anomali che si manifestano sull'intera traiettoria. La loro combinazione migliora le prestazioni complessive di rilevamento rispetto all'uso di uno solo dei due.

2.2.3 Approcci Geometrici

Gli approcci geometrici si basano sulle proprietà spaziali delle traiettorie, ad esempio tramite il calcolo del convex hull (inviluppo convesso) delle rotte osservate [4]. Si tratta in genere di metodi semplici e interpretabili, ma meno flessibili e meno robusti in presenza di rumore rispetto ad altri approcci.

2.3 Il framework TREAD di Pallotta et al.

Tra gli approcci presenti in letteratura, il metodo adottato in questo lavoro è il framework TREAD (Traffic Route Extraction and Anomaly Detection) proposto da Pallotta et al. [2], che combina tecniche di clustering e analisi statistica.

Il framework è non supervisionato e incrementale, ossia apprende i pattern di traffico direttamente dai dati AIS senza richiedere informazioni preliminari. Il processo si articola in due fasi principali. Nella prima fase, vengono identificati i waypoint caratteristici (come porti o punti di ingresso/uscita) tramite un algoritmo di clustering basato su DBSCAN. Tali waypoint vengono usati per costruire le rotte, definite come il percorso di un nave da un waypoint di partenza a uno di arrivo. Waypoint di partenza e di arrivo possono coincidere.

Nella seconda fase, le rotte apprese vengono utilizzate per analizzare nuove traiettorie e individuare eventuali anomalie, sulla base della loro probabilità rispetto al modello.

Tra i principali vantaggi di questo approccio vi sono la possibilità di aggiornare il modello in modo incrementale, la capacità di gestire dati AIS anche non continui e una rappresentazione relativamente compatta del traffico, adatta anche a dataset di grandi dimensioni.

Capitolo 3

Metodologia

3.1 Introduzione

Questo capitolo descrive in dettaglio il lavoro svolto per analizzare, re-implementare ed estendere il framework TREAD di Pallotta et al. [2], applicandolo a un dataset AIS reale relativo all'arcipelago delle Hawaii.

Come anticipato nel Capitolo 2, il framework TREAD è stato scelto come punto di partenza in quanto combina un approccio non supervisionato e incrementale con una rappresentazione compatta del traffico, caratteristiche che lo rendono adatto all'analisi di dataset di grandi dimensioni. Il lavoro non si limita a una replica dell'algoritmo originale, ma ne valuta criticamente l'applicabilità a un contesto più moderno, su un dataset reale di milioni di record, identificando gli aspetti mantenuti, quelli adattati e le eventuali possibilità di miglioramento.

La pipeline implementata si articola in tre fasi principali: **Pre-Processing** dei dati grezzi, **Knowledge Discovery** per l'identificazione dei waypoint e l'estrazione delle rotte tramite clustering, e **Anomaly Detection** basata su un modello probabilistico (KDE e distribuzione di Weibull).

Le sezioni seguenti descrivono ciascuna fase nel dettaglio, a partire dalla descrizione del dataset utilizzato.

3.2 Dataset

I dati utilizzati provengono dal portale pubblico del NOAA[1] (National Oceanic and Atmospheric Administration), un'agenzia scientifica e normativa statunitense con

[1]Il NOAA mette a disposizione due modalità di accesso ai dati: tramite il portale `https://marinecadastre.gov/accessais/`, che consente di filtrare per zona geografica e intervallo temporale, oppure tramite `https://hub.marinecadastre.gov/pages/vesseltraffic`, che offre il download in bulk di tutti i dati AIS registrati suddivisi per anno.

diversi compiti tra cui il monitoraggio oceanico. I file scaricati dalla piattaforma hanno nome nel formato `AIS_YYYY_MM_DD` (dove YYYY rappresenta l'anno, MM il mese e DD il giorno di registrazione dei dati) e contengono tutti i messaggi ricevuti dall'ente in una singola giornata di tutto il territorio nazionale monitorato. I messaggi originali sono campionati dall'ente a un record al minuto per nave [3]. Per questa tesi sono stati utilizzati i dati relativi al periodo gennaio-marzo 2019 (estremi inclusi), filtrati sull'area delle Hawaii tramite una bounding box le cui estremità hanno le seguenti coordinate:

- Latitudine: da 18,77°N a 22,63°N,
- Longitudine: da 160,11°W a 154,39°W.

La Figura 3.1 mostra un passaggio della fase di scaricamento dei dati dal portale del NOAA. Si può vedere su mappa il rettangolo descritto dalle coordinate di latitudine e longitudine di cui sopra.

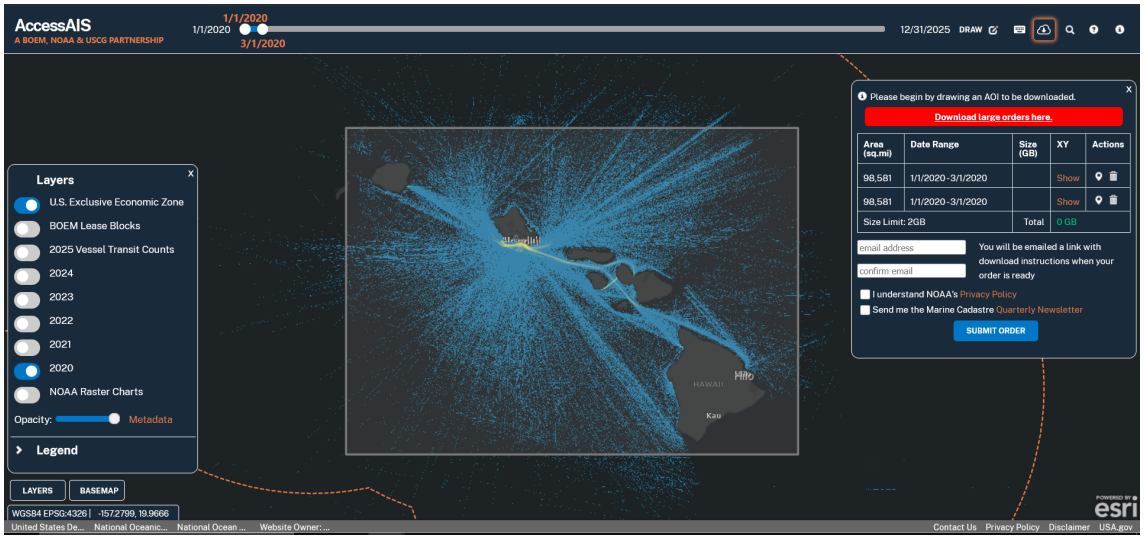


Figura 3.1: Portale NOAA *AccessAIS* per il download di dati AIS.

3.2.1 Struttura del dataset

Ogni record del dataset corrisponde a un singolo messaggio AIS trasmesso da una nave e contiene diversi campi, riportati in Tabella 3.1, che seguono la specifica AIS. I campi si dividono in due categorie: attributi statici, che descrivono le caratteristiche fisse della nave e normalmente non variano tra un messaggio e l'altro, e attributi dinamici, che riflettono lo stato corrente della nave al momento della trasmissione.

Ogni record del dataset, contenendo una coppia di coordinate geografiche (`LAT`, `LON`), è rappresentabile come un punto su una mappa. A ciascun punto è inoltre

Tabella 3.1: Struttura del dataset AIS del NOAA.

Colonna	**Tipo**	**Descrizione**
Attributi statici		
`MMSI`	intero	Maritime Mobile Service Identity: identificativo univoco della nave
`VesselName`	stringa	Nome della nave
`IMO`	stringa	Numero IMO (International Maritime Organization)
`CallSign`	stringa	Nominativo radio della nave
`VesselType`	intero	Codice numerico che indica la tipologia di nave (cargo, tanker, passeggeri, ecc.)
`Length`	intero	Lunghezza della nave in metri
`Width`	intero	Larghezza della nave in metri
`Draft`	decimale	Pescaggio della nave in metri
`Cargo`	intero	Codice del tipo di carico trasportato
`TransceiverClass`	stringa	Classe del transponder AIS: `A` o `B` (imbarcazioni minori)
Attributi dinamici		
`BaseDateTime`	datetime	Timestamp del messaggio (UTC)
`LAT`	decimale	Latitudine della posizione (gradi decimali)
`LON`	decimale	Longitudine della posizione (gradi decimali)
`SOG`	decimale	Speed Over Ground: velocità rispetto al fondale in nodi
`COG`	decimale	Course Over Ground: direzione di movimento in gradi (0–360°)
`Heading`	decimale	Prua della nave in gradi (0–360°), distinta dal COG
`Status`	intero	Stato di navigazione AIS (es. in navigazione, all'ancora, in manovra)

associato un vettore, il cui modulo corrisponde alla velocità istantanea della nave (`SOG`), mentre la direzione è determinata dall'angolo `COG`, espresso in gradi rispetto al nord geografico. Questa rappresentazione vettoriale è alla base delle elaborazioni descritte nelle sezioni successive, ed è il motivo per cui nel resto del capitolo i termini *record* e *punto* vengono usati in modo intercambiabile.

In Figura 3.2 viene mostrata una visualizzazione grafica dei concetti di LON, LAT, SOG, COG, Heading. Ogni punto è identificato dalla coppia di coordinate (LON, LAT). Il vettore SOG indica la velocità istantanea della nave, con direzione data dall'angolo COG misurato rispetto al nord geografico in senso orario. L'Heading indica l'orientamento della prua, che può differire dal COG a causa di correnti, vento o altre cause.



Figura 3.2: Rappresentazione cartesiana di un record AIS.

	# MMSI	BaseDateTime	# LAT	# LON	# SOG	# COG	# Heading	VesselName	IMO
0	367060130	2019-01-01T00:00:00	29.68313	-91.1679	5.6	282.4	511.0	Missing value	Missing value
1	368029640	2019-01-01T00:00:00	40.68142	-74.01218	0.0	360.0	511.0	Missing value	Missing value
2	367141210	2019-01-01T00:00:00	39.8976	-75.13971	0.1	198.8	511.0	Missing value	Missing value
3	316038603	2019-01-01T00:00:00	48.65235	-123.4493	0.0	17.2	511.0	Missing value	Missing value
4	366876000	2019-01-01T00:00:00	27.7313	-92.28222	9.1	110.0	109.0	Missing value	Missing value
5	368062270	2019-01-01T00:00:01	29.74715	-95.17277	7.9	264.0	263.0	Missing value	Missing value
6	368063460	2019-01-01T00:00:00	30.06378	-93.26706	6.4	149.3	511.0	Missing value	Missing value
7	316038834	2019-01-01T00:00:00	49.19619	-123.13591	0.0	212.2	511.0	Missing value	Missing value
8	338458000	2019-01-01T00:00:00	30.49525	-88.0443	9.1	123.2	119.0	Missing value	Missing value
9	367528080	2019-01-01T00:00:00	28.76662	-95.62543	4.8	235.7	511.0	MISS MARY JEAN	Missing value
10	368050140	2019-01-01T00:00:01	39.92184	-91.41509	0.0	130.5	511.0	Missing value	Missing value
11	368019930	2019-01-01T00:00:02	33.72979	-118.2756	0.0	248.6	126.0	Missing value	Missing value
12	368007030	2019-01-01T00:00:02	35.36905	-120.85569	0.0	225.5	511.0	IRENE'S WAY	IMO8133279
13	366990580	2019-01-01T00:00:00	47.7901	-122.49089	17.2	298.0	297.0	FINEST	IMO9132076
14	368926258	2019-01-01T00:00:00	39.26699	-76.5795	0.0	228.9	511.0	Missing value	Missing value
15	368015740	2019-01-01T00:00:00	36.84844	-76.31547	0.0	4.1	220.0	Missing value	Missing value
16	368028980	2019-01-01T00:00:00	38.80961	-75.12962	4.3	315.9	511.0	DANIELLE MILLER	Missing value
17	368070320	2019-01-01T00:00:01	40.73076	-74.01356	0.0	276.5	511.0	Missing value	Missing value
18	247293200	2019-01-01T00:00:01	17.07412	-67.67	12.6	155.0	153.0	MARE PICENUM	IMO9449405
19	367728730	2019-01-01T00:00:01	29.8103	-93.9965	6.5	37.5	36.0	CONCHO	Missing value

Figura 3.3: Estratto del dataset di partenza.

In Figura 3.3 è possibile vedere un esempio dei dati contenuti nelle colonne `MMSI, BaseDateTime, LAT, LON, SOG, COG, Heading, VesselName, IMO`.

3.2.2 Qualità dei dati

Oltre alla struttura, è opportuno considerare la qualità intrinseca dei dati. Un vantaggio rilevante del dataset NOAA rispetto ad altre fonti pubbliche (in particolare i dati danesi considerati e poi scartati in fase esplorativa) è che i dati sono già stati filtrati dagli errori più grossolani, rendendo l'uso di tecniche di pulizia aggiuntive meno critico. È stata tuttavia mantenuta l'assunzione esplicita che le colonne `MMSI` e `BaseDateTime` siano affidabili e prive di errori, in quanto queste due colonne costituiscono la base di tutte le elaborazioni successive.

3.3 Pre-processing dei dati

L'intera fase di pre-processing, nonchè le successive analisi, sono implementate in Python, utilizzando dei notebook Jupyter. Le tecnologie utilizzate verranno descritte meglio nella Sezione 3.6.

3.3.1 Importazione, filtraggio geografico e rimozione dei duplicati

I file scaricati dalla piattaforma del NOAA sono in formato ".zip". Pertanto vengono automaticamente decompressi e successivamente eliminati dal disco per liberare spazio, mentre i file csv così estratti vengono mantenuti. Il nome di ogni archivio decompresso viene registrato in un apposito file di log, così da non ripetere l'operazione nelle esecuzioni successive. Durante l'importazione, ogni file csv letto viene salvato in memoria sotto forma di `DataFrame`. In questa fase, vengono immediatamente scartati tutti quei messaggi le cui coordinate di latitudine e longitudine ricadono al di fuori del perimetro citato nella Sezione 3.2. Tutti i `DataFrame` così creati vengono concatenati in un unico `DataFrame` finale, che viene esportato in un unico file CSV di backup. Le operazioni di importazione e filtraggio avvengono grazie alla libreria **Polars**, che è stata scelta per il fatto che (a differenza di Pandas) supporta il multithreading nativamente.

In una fase successiva, i record esattamente duplicati (identici in ogni attributo) vengono rimossi, lasciandone solo uno per ogni gruppo di duplicati.

Viene poi rimosso un ulteriore sottoinsieme di record, ossia quelli generati da navi, la cui somma di record presenti nel database è inferiore al 10% della media

calcolata sul totale delle navi presenti. Per identificare l'appartenenza di un record ad una nave o meno, è stato utilizzato il valore di `MMSI`. Come citato in precedenza alla Sezione 3.2.2, tale attributo si assume corretto e validato dal NOAA in fase di raccolta dei dati.

La soglia usata per rimuovere le navi meno attive è calcolata dinamicamente (e non come valore fisso) in modo da rendere il codice indipendente dalle dimensioni del dataset che si decide di utilizzare. L'idea dietro la decisione di rimuovere queste navi è che, al di sotto di questa soglia, non contribuiscono in maniera significativa al traffico dell'area e la loro presenza potrebbe distorcere la fase di clustering. Prima dell'applicazione di questa soglia il dataset conteneva 602 imbarcazioni distinte (5.460.800 record). In seguito il numero di navi distinte è passato a 403 (5.415.168 righe), eliminando 199 vascelli (circa un terzo delle imbarcazioni di partenza) che costituivano solo lo 0,84% dei record totali.

3.3.2 Ottimizzazione della memoria

Il dataset pulito viene riletto in Pandas per le elaborazioni successive. Per ridurre il consumo di memoria (il dataset occupa circa 702 MB nella rappresentazione di default) i tipi di dato delle colonne vengono convertiti nelle rappresentazioni più compatte compatibili con i limiti tecnici definiti dalla normativa ITU-R M.1371-6 [8], che specifica la codifica binaria di ciascun campo del messaggio AIS. La Tabella 3.2 riassume le conversioni effettuate con la relativa giustificazione.

Grazie alle conversioni effettuate, l'occupazione in memoria del dataset si riduce da circa 702 MB a circa 465 MB, con un risparmio prossimo al 34%.

3.3.3 Calcolo della velocità media e classificazione degli stati

Una volta completata la fase di importazione e pulizia, l'analisi viene condotta su una nave alla volta utilizzando il valore di `MMSI` per distinguerle tra loro. Per ciascuna nave viene costruito un `DataFrame` separato, ordinato cronologicamente per `BaseDateTime` e contenente tutti i messaggi che quell'imbarcazione ha generato nel periodo di analisi all'interno dell'area di studio. Prima di questa suddivisione vengono eliminati i record che hanno la stessa coppia (`MMSI`, `BaseDateTime`) di un altro record, conservando il primo. L'idea dietro questa scelta è che due posizioni della stessa nave con lo stesso timestamp darebbero un intervallo di tempo nullo nel calcolo della velocità. Nel dataset analizzato si tratta di 5 record, che portano il totale da 5.415.168 a 5.415.163. Per ogni coppia di punti consecutivi appartenenti alla stessa nave viene calcolata la velocità media `Avg_Speed`, come rapporto tra

Tabella 3.2: Ottimizzazione dei tipi di dato.

Colonna	**Tipo originale**	**Nuovo tipo**	**Motivazione**
`MMSI`	`int64`	`int32`	Codificato su 30 bit; valori fino a 999.999.999. Un `int32` ($\approx 2{,}1 \times 10^9$) è sufficiente.
`LAT`	`float64`	`float64`[a]	Tipo invariato. I valori vengono arrotondati a 4 cifre decimali ($\approx$ 10 m di risoluzione) per ridurre il numero di coordinate distinte nelle operazioni di group-by.
`LON`	`float64`	`float64`[a]	Stessa giustificazione di `LAT`.
`SOG`	`float64`	`float64`	Tipo invariato.
`COG`	`float64`	`float64`	Tipo invariato.
`Heading`	`float64`	`float64`	Tipo invariato.
`VesselType`	`float64`	`int16`[b]	Formalmente 8 bit (0–255), ma il dataset NOAA presenta valori superiori. I `NaN` vengono sostituiti con 0.
`Status`	`float64`	`int8`	Codificato su 4 bit (valori 0–15). I `NaN` vengono sostituiti con 99.
`Length`	`float64`	`int16`	Valore massimo 511 m. I valori frazionari vengono troncati (errore < 1 m). I `NaN` vengono sostituiti con 0.
`Width`	`float64`	`int16`	Stessa giustificazione di `Length`.
`Draft`	`float64`	`float32`	Codificato su 8 bit con risoluzione di 0,1 m, massimo 25,5 m.
`Cargo`	`float64`	`int16`[b]	Stessa giustificazione di `VesselType`.
`TransceiverClass`	`object`	`bool`	Assume solo i valori `A` o `B`. Rinominato `IsClassA`.
`BaseDateTime`	`object`	`datetime64[s]`	Conversione da object a tipo temporale nativo di Pandas.

[a] Tipo invariato; l'unica trasformazione è l'arrotondamento a 4 cifre decimali.

[b] Scostamento dalla specifica ITU-R M.1371-6, giustificato dai valori presenti nel dataset NOAA.

la distanza percorsa e l'intervallo di tempo trascorso. La distanza viene calcolata sfruttando la formula della *Great-Circle Distance*, che tiene conto della curvatura terrestre usando come raggio della Terra il raggio equatoriale definito dallo standard WGS-84 e pari a 6.378.137 m. L'intervallo di tempo tra i due punti viene individuato facendo la differenza tra i due timestamp e sfruttando l'ordinamento cronologico applicato in precedenza. La velocità risultante viene convertita in nodi nautici.

Il calcolo viene gestito in modo vettorizzato: ogni traiettoria viene rappresentata come due sequenze di punti sfalsate di un passo, ottenendo le coppie (punto precedente, punto corrente). Nei casi in cui l'intervallo di tempo tra due punti consecutivi supera la soglia `LOST_TIME_THRESHOLD_SECONDS` (impostata a 620 s e corrispondente a circa 10 volte l'intervallo di campionamento dei dati), la velocità media del secondo punto appena calcolata viene scartata e sostituita con il valore di `SOG`, a condizione che quest'ultimo sia plausibile (inferiore alla soglia `ABSURD_SPEED_THRESHOLD` di 102 nodi). In caso contrario, la velocità viene ricalcolata ancora come rapporto distanza/tempo. Al primo punto di ogni traiettoria, per il quale non esiste un punto precedente, viene assegnato direttamente il valore di `SOG`. I punti con `Avg_Speed` superiore a 102 nodi (e che non fanno scattare la soglia `LOST_TIME_THRESHOLD_SECONDS`) vengono eliminati, in quanto ritenuti il risultato di errori di posizionamento GPS. In totale dal dataset sono stati rimossi 7 record su 5.415.163 che ricadevano in quest'ultima casistica.

A partire da `Avg_Speed`, viene costruita la colonna `EstimatedStatus`, che classifica ogni punto in una delle sei categorie seguenti. Le prime quattro riguardano la gestione dei gap temporali e vengono assegnate durante il calcolo della velocità:

- **lost**: record immediatamente precedente un gap temporale superiore a `LOST_TIME_THRESHOLD_SECONDS`. Indica l'ultimo momento in cui la nave era tracciata prima di scomparire temporaneamente dal sistema.

- **return**: primo record successivo al gap citato al punto precedente. Indica il momento in cui la nave torna visibile dopo una breve interruzione. I punti *lost* e *return* non entrano nella fase di clustering, ma sono utili per la corretta interpretazione delle traiettorie.

- **exit**: record precedente un gap superiore a `EXIT_TIME_THRESHOLD_HOURS` (12 ore). Indica che la nave ha lasciato l'area di studio o ha smesso di trasmettere per un periodo prolungato.

- **entry**: primo record successivo al gap citato al punto precedente. Indica il rientro della nave nell'area di studio dopo un'assenza significativa.

Gli status *exit* e *entry* vengono assegnati dopo *lost* e *return*, sovrascrivendoli quando il gap supera la soglia più lunga. Le restanti due categorie vengono assegnate in una seconda fase, sui punti che non hanno ancora ricevuto uno status:

- **stationary**: punti con `Avg_Speed` $\leq$ `SPEED_THRESHOLD` (0,5 nodi).
- **sailing**: tutti i punti rimanenti, in navigazione ordinaria.

Al termine, il primo punto di ciascuna traiettoria viene forzato a *entry* e l'ultimo a *exit*, indipendentemente dallo status eventualmente già calcolato. Quando più punti consecutivi risultano tutti *entry* o tutti *exit* (situazione possibile in presenza di gap ravvicinati) viene conservato solo l'ultimo punto *entry* della sequenza e il primo punto *exit*, eliminando i rimanenti. Nel dataset analizzato questa regola elimina 27 record, relativi a 24 navi.

3.4 Implementazione del framework TREAD e differenze rispetto all'originale

3.4.1 Architettura generale

Il framework TREAD di Pallotta et al. [2] si articola in due macro fasi: *Knowledge Discovery* e *Knowledge Exploitation*. Nella prima fase, il flusso di messaggi AIS viene elaborato per costruire un modello statistico del traffico normale, articolato in tre classi di oggetti: vessel objects (Vs), waypoint objects (WPS) e route objects (Rs). Nella seconda fase, le rotte apprese vengono utilizzate per classificare nuove traiettorie e individuare comportamenti anomali.

La presente implementazione riproduce questa struttura a due fasi. Tuttavia, il processo non è incrementale in senso stretto: anzichè aggiornare il modello messaggio per messaggio come nell'algoritmo originale, l'intero dataset viene caricato in memoria e processato in batch. L'analisi è condotta a posteriori su un periodo già concluso, per cui l'aggiornamento continuo del modello non è necessario; inoltre l'elaborazione messaggio per messaggio sarebbe stata troppo onerosa per l'hardware disponibile.

3.4.2 Identificazione dei waypoint: DBSCAN e H-DBSCAN

Il passo centrale della fase di Knowledge Discovery è l'identificazione dei waypoint. In questo contesto, un waypoint viene definito come una zona dell'area di studio in cui le navi:

- iniziano a manifestare la propria presenza nell'area di studio (entry);
- cessano di manifestare la propria presenza nell'area di studio (exit);
- rallentano significativamente, con velocità media inferiore alla soglia `SPEED_THRESHOLD` (0,5 nodi), al di sotto della quale la nave è ritenuta sostanzialmente stazionaria.

A differenza di quanto avviene su terra, in mare è molto difficile per una nave rimanere completamente ferma per via di correnti, vento e onde che spesso causano qualche tipo di movimento. Per questo motivo, anziché cercare punti di velocità nulla, si è deciso di introdurre una soglia (`SPEED_THRESHOLD`) sotto la quale un'imbarcazione è considerata stazionaria. I waypoint non hanno dimensione fissa: ciascuno occupa una porzione dello spazio geografico determinata da come si distribuiscono e da quanti sono i punti che lo compongono. Nella pratica, la maggior parte di essi tende ad occupare una porzione molto ridotta dell'area di studio. Nell'algoritmo originale l'identificazione dei waypoint viene effettuata tramite un approccio basato su DBSCAN. La presente implementazione applica prima DBSCAN e poi H-DBSCAN come variante migliorativa (*Hierarchical DBSCAN*).

Preparazione degli input per il clustering

L'input fornito agli algoritmi di clustering è costituito da tutti i punti classificati come *stationary*, *entry* o *exit*, che rappresentano circa il 69,6% del dataset totale.

Per ridurre la dimensione dell'input e superare le limitazioni di memoria dell'implementazione scikit-learn di DBSCAN, il cui costo di memoria è $O(n^2)$, i punti vengono aggregati tramite un'operazione di *group-by* sulle sole coordinate GPS, contando quante volte ogni coppia (`LAT`, `LON`) compare nel dataset. Questa operazione è il motivo per cui si è deciso di arrotondare da 5 a 4 cifre decimali i valori di latitudine e longitudine (vedi Tabella 3.2). Così facendo si riduce il numero di coppie distinte in input all'algoritmo di clustering e allo stesso tempo la perdita di precisione è considerata trascurabile. Infatti, con 5 cifre decimali la risoluzione massima è attorno ad 1 metro; con 4 cifre decimali la risoluzione passa a circa 10 metri. Le somme risultanti dall'operazione di *group-by* vengono utilizzate come *pesi* da associare a ciascuna coordinata, allo scopo di rappresentare la frequenza con cui ogni posizione è stata visitata. Tuttavia si è notato che esistono diversi dispositivi statici (es: boe, stazioni costiere) che, dotati di transponder AIS, restano stazionari in un punto e continuano periodicamente a trasmettere, riempiendo il database. Per attenuare lo sbilanciamento tra queste coordinate che all'apparenza sembrano molto visitate e le altre coordinate, i pesi vengono normalizzati applicando il logaritmo base 2 e

approssimando il risultato all'intero piu vicino; infine le coordinate con peso zero dopo la trasformazione logaritmica vengono riportate artificialmente a 1. La tabella risultante usata come input per l'applicazione dell'algoritmo di DBSCAN ha circa 52.000 righe, mentre il numero di punti stazionari processati è pari a circa 3.770.000 righe.

DBSCAN

L'algoritmo DBSCAN viene eseguito con i parametri $\varepsilon = 0{,}075$ e $N_{\min} = 10$, scelti empiricamente in modo da produrre cluster geograficamente coerenti con i porti e i punti di passaggio dell'arcipelago delle Hawaii. Il parametro ε è il raggio dell'intorno considerato attorno a ogni punto, uguale in tutta l'area di studio; poiché le distanze sono calcolate direttamente su latitudine e longitudine, è espresso in gradi e corrisponde a circa 8 km. $N_{\min}$ è il peso complessivo minimo che deve ricadere nell'intorno di un punto perché questo sia considerato il nucleo di un cluster; essendo l'input la tabella aggregata, ogni coordinata contribuisce con il proprio peso. Questo passo riproduce l'approccio di Pallotta et al. ed è incluso come riferimento per il confronto con la variante H-DBSCAN.

H-DBSCAN

Il motivo principale per introdurre H-DBSCAN è la sua capacità di identificare cluster di densità variabile, cosa che DBSCAN non riesce a gestire bene. Il traffico nelle Hawaii presenta una densità fortemente eterogenea: i porti principali come Honolulu hanno concentrazioni di punti molto più elevate rispetto a zone di passaggio o porti minori. In questo contesto, i parametri fissi di DBSCAN tendono a sovrasegmentare le aree sparse o a fondere artificialmente cluster distinti nelle aree dense.

Poiché la libreria `hdbscan`[2] non consente di associare i pesi ad ogni punto ma li considera tutti equiponderati, la tabella aggregata viene espansa, replicando ogni coordinata un numero di volte pari al suo peso calcolato in precedenza applicando il logaritmo. La tabella espansa conta circa 97.000 righe, ossia poco meno del doppio della tabella utilizzata come input per l'algoritmo DBSCAN. Infine, H-DBSCAN viene eseguito con parametri scelti empiricamente con lo stesso criterio usato per DBSCAN: min_cluster_size = 30, max_cluster_size = 10.000 e cluster_selection_epsilon = 0,01. Il parametro min_cluster_size è il numero minimo di punti che un cluster deve contenere. max_cluster_size invece è il numero massimo di punti di un cluster e impedisce che nelle aree più dense si formi un unico

[2]Libreria esterna `hdbscan` (`https://github.com/scikit-learn-contrib/hdbscan`), distinta dall'implementazione inclusa in scikit-learn.

cluster molto esteso. cluster_selection_epsilon è una distanza, espressa in gradi come ε e pari a circa 1 km, al di sotto della quale cluster vicini vengono uniti, evitando di frammentare una stessa area in molti cluster di piccole dimensioni. I parametri dei due algoritmi non hanno una corrispondenza diretta, in quanto H-DBSCAN non usa un raggio fisso come ε, ma si adatta alla densità locale dei punti, e i suoi parametri pongono solo dei limiti alla dimensione e alla separazione dei cluster. Anche $N_{\min}$ e min_cluster_size, pur esprimendo entrambi una quantità minima di punti, non sono confrontabili: il primo si riferisce all'intorno di un singolo punto, il secondo all'intero cluster.

3.4.3 Costruzione dei waypoint e identificazione delle rotte

Una volta determinati i cluster tramite H-DBSCAN, per ciascun cluster viene calcolato il *convex hull* (inviluppo convesso) tramite `scipy.spatial.ConvexHull`. L'inviluppo convesso di ogni cluster definisce il perimetro del waypoint corrispondente e viene rappresentato come un poligono.

Per ogni punto del dataset viene quindi verificato se esso ricade all'interno o sul bordo di uno dei poligoni waypoint, informazione salvata nella colonna `IsInWP`. Il bordo viene incluso perché i vertici dell'inviluppo convesso sono essi stessi punti del dataset. Poiché gli inviluppi convessi di cluster diversi possono sovrapporsi, un punto può ricadere in più di un waypoint; in tal caso viene assegnato a quello con indice (assegnato dall'algoritmo) minore. Per valutare l'impatto di questa scelta, viene inoltre calcolato il numero di punti che ricadono in più di un waypoint. Non tutti i punti che ricadono in un waypoint indicano però che la nave vi ha fatto tappa: una nave può attraversare l'area di un waypoint senza fermarsi, ad esempio passando davanti a un porto. Per questo un waypoint è considerato *significativo* per un dato punto solo se quest'ultimo soddisfa almeno una delle condizioni seguenti: `Avg_Speed` $\leq$ `SPEED_THRESHOLD`, oppure il suo `EstimatedStatus` è *entry* o *exit*. In altre parole, un waypoint significativo è un'area in cui l'imbarcazione sosta, entra o esce dall'area di studio.

Prima di descrivere l'assegnazione delle rotte, è opportuno distinguere due concetti fondamentali. Una **rotta** è un'entità astratta che modella il fatto che almeno una volta una nave ha viaggiato dal waypoint di partenza a quello di arrivo (e non il viceversa). Ipotizzando di modellare i waypoint come nodi di un grafo orientato, una rotta sarebbe uno degli archi. Un **trip** indica invece il singolo viaggio compiuto da una specifica nave lungo una rotta. A ogni rotta possono quindi essere associati più trip, anche della stessa nave, che può percorrere la stessa rotta più volte nel

periodo analizzato: il numero di trip di una rotta è quindi maggiore o uguale al numero di navi che l'hanno percorsa.

L'assegnazione delle rotte avviene una nave alla volta, all'interno di ogni coppia (*entry*, *exit*) identificata nel dataset, cioè per ogni periodo in cui la nave è presente nell'area di studio. A ogni punto viene assegnata un'etichetta secondo la seguente logica:

- se il punto si trova all'interno di un waypoint significativo, l'etichetta corrisponde al nome di quel waypoint;
- se il punto si trova in navigazione tra due waypoint significativi, l'etichetta assume il formato `WP_X - WP_Y`, dove `WP_X` e `WP_Y` sono rispettivamente il waypoint significativo precedente e quello successivo; nei casi in cui uno o entrambi non siano identificabili, viene utilizzato il segnaposto `<NA>`.

I trip si ottengono infine raggruppando i punti consecutivi della stessa nave che hanno la stessa etichetta di rotta, per cui ogni tratto di navigazione compreso tra due waypoint significativi costituisce un trip. Se il waypoint significativo di partenza e quello di arrivo coincidono, l'etichetta assume la forma `WP_X - WP_X` e la rotta corrispondente è detta *self-loop*.

Si consideri ad esempio una nave ferma nel porto di Honolulu (`WP_135`) che salpa, raggiunge il porto di Kalaeloa (`WP_118`) e vi si ferma. I punti registrati durante la sosta a Honolulu ricevono l'etichetta `WP_135`, quelli della navigazione l'etichetta `WP_135 - WP_118` e quelli della sosta a Kalaeloa l'etichetta `WP_118`. La navigazione costituisce quindi un trip della rotta `WP_135 - WP_118`. Se la nave torna poi a Honolulu, i punti del viaggio di ritorno formano un nuovo trip, che appartiene alla rotta opposta `WP_118 - WP_135`. Se invece la nave uscisse da Honolulu e vi rientrasse senza fermarsi altrove, il viaggio sarebbe un trip del self-loop `WP_135 - WP_135`.

Con queste ultime operazioni, termina la fase di Knowledge Discovery, in cui ad ogni punto del dataset viene associata un'etichetta di rotta secondo i criteri appena descritti, e il modello di traffico appreso è pronto per essere utilizzato nella fase di Knowledge Exploitation.

3.5 Anomaly detection

La fase di anomaly detection assegna a ogni trip un punteggio che misura quanto il trip è compatibile con il comportamento abituale delle navi sulla rotta che percorre. Il punteggio risponde a due domande. La prima è se i punti del trip si trovano nelle

zone in cui passano di solito le navi della rotta. La seconda è se il moto della nave da un punto al successivo è prevedibile a partire dalla posizione e dalla velocità precedenti. Il punteggio è costruito come una log-probabilità e prende il nome di *punteggio di normalità*. Per come è costruito a valori alti si ha un trip normale, a valori bassi un trip potenzialmente anomalo.

L'analisi si concentra su una singola rotta, una delle più trafficate tra quelle estratte nella fase precedente, e utilizza i trip associati a tale rotta come unità di analisi. La rotta selezionata è quella dal porto di Honolulu al porto di Kalaeloa, presentata nel Capitolo 4.

3.5.1 Il modello probabilistico di riferimento

Nel framework di Pallotta et al. [2] il comportamento di una nave è descritto da una *traccia*, cioè da una sequenza di T osservazioni

$$V = \{v_1, v_2, \ldots, v_T\}, \qquad v_t = [x_t,\, y_t,\, \dot{x}_t,\, \dot{y}_t]^\top,$$

ciascuna delle quali contiene la posizione $[x_t, y_t]$ e le componenti della velocità $[\dot{x}_t, \dot{y}_t]$ della nave. A ogni osservazione è associato uno *stato* s_t, cioè la regione circolare di raggio d centrata nella posizione osservata, per cui la traccia corrisponde a una sequenza di stati $\bar{S} = \{s_1, \ldots, s_T\}$. Questo concetto di stato è diverso dallo stato di navigazione (`EstimatedStatus`) introdotto nella Sezione 3.3.3.

Pallotta et al. associano una traccia alla rotta R che rende massima la probabilità a posteriori, che per la regola di Bayes si scompone come

$$P(R \mid V, \bar{S}) \;\propto\; P(V \mid \bar{S}, R)\; P(\bar{S} \mid R)\; P(R). \tag{3.1}$$

Ai tre fattori possono essere assegnati, a livello intuitivo, i significati descritti di seguito. Il primo misura quanto le osservazioni sono compatibili con i punti della rotta che cadono nei rispettivi stati. Assumendo le osservazioni indipendenti tra loro, è il prodotto dei contributi delle singole osservazioni,

$$P(V \mid \bar{S}, R) = \prod_{t=1}^{T} P(v_t \mid s_t, R), \qquad P(v_t \mid s_t, R) = P(\dot{x}_t, \dot{y}_t \mid s_t, R)\; P(x_t, y_t \mid s_t, R),$$

dove il primo fattore valuta la velocità osservata rispetto a quelle registrate nello stato e il secondo la posizione. Il secondo fattore dell'equazione (3.1) misura quanto è plausibile il passaggio da ciascuno stato al successivo ed è il prodotto delle probabilità

di transizione,

$$P(\bar{S} \mid R) \;\propto\; \prod_{t=2}^{T} P(s_t \mid s_{t-1}, R).$$

L'ultimo fattore, $P(R)$, è la probabilità a priori della rotta. Pallotta et al. usano la stessa grandezza anche per l'anomaly detection: una traccia è considerata anomala quando il valore massimo di $P(V, \bar{S} \mid R)\, P(R)$ sulle rotte compatibili scende sotto una soglia, da fissare in base ai tassi di rilevamento e di falso allarme richiesti.

Passando ai logaritmi, i prodotti diventano somme. Nella presente implementazione il punteggio di normalità di un trip di n punti è

$$S \;=\; \underbrace{\frac{1}{n}\sum_{i=1}^{n} L_i}_{\text{osservazione}} \;+\; \underbrace{\frac{1}{n-1}\sum_{t=2}^{n} \log P(s_t \mid s_{t-1}, R)}_{\text{transizione}} \;+\; \underbrace{\log P(R)}_{\text{a priori}}, \tag{3.2}$$

i cui tre addendi sono detti rispettivamente *termine di osservazione*, *termine di transizione* e *termine a priori*. Rispetto al logaritmo dell'equazione (3.1), le somme sono sostituite da medie, così da rendere confrontabili trip di lunghezza diversa, e il termine di osservazione è calcolato in forma semplificata. Le sottosezioni seguenti descrivono i tre termini.

3.5.2 Decomposizione della velocità

Per ogni punto del dataset vengono calcolate le componenti cartesiane della velocità V_x (verso est) e V_y (verso nord), che corrispondono a $\dot{x}_t$ e $\dot{y}_t$, a partire da `SOG` e `COG`. Il COG, espresso in gradi rispetto al nord geografico, viene convertito in angolo aritmetico convenzionale tramite la formula $\theta = (450 - \mathrm{COG}) \mod 360$, e poi in radianti. Le componenti risultanti sono:

$$V_x = \mathrm{SOG} \cdot \cos(\theta), \qquad V_y = \mathrm{SOG} \cdot \sin(\theta)$$

Pallotta et al. [2] definiscono le stesse componenti in modo implicito, tramite le relazioni

$$\mathrm{SOG}_t = \sqrt{\dot{x}_t^2 + \dot{y}_t^2}, \qquad \mathrm{COG}_t = \tan^{-1}\!\left(\frac{\dot{x}_t}{\dot{y}_t}\right).$$

Ricavare le componenti invertendo queste relazioni richiederebbe di gestire esplicitamente il quadrante della direzione, perché l'arcotangente è definita a meno di un'ambiguità di segno. Per questo motivo, nella presente implementazione V_x e V_y sono calcolate direttamente tramite seno e coseno dell'angolo θ.

3.5.3 Termine di osservazione

Il termine di osservazione misura quanto i punti del trip si trovano nelle zone in cui passano abitualmente le navi della rotta. Per individuare queste zone si usa la *Kernel Density Estimation* (KDE), grazie alla quale si riesce a ricavare una densità di probabilità continua da un insieme di punti. Detto in altre parole, è come se attorno ad ogni punto osservato venisse posta una piccola "campana" gaussiana, e la densità in una posizione è la somma dei contributi di tutte le campane. La densità risulta quindi alta dove i punti sono numerosi e vicini tra loro, bassa dove sono radi. La larghezza delle campane viene scelta automaticamente dalla libreria in base al numero e alla dispersione dei punti.

Nella presente implementazione la KDE è bivariata e viene calcolata su longitudine e latitudine (`LON`, `LAT`) di tutti i punti della rotta, usando la funzione `scipy.stats.gaussian_kde`. Viene inoltre calcolata una seconda KDE sulle stesse coordinate, in cui ogni punto pesa in proporzione alla propria velocità (`SOG`). Questa seconda densità è alta nelle zone con molto traffico e con le navi che transitano a velocità elevata. Il prodotto delle due KDE, valutato in ogni punto della rotta, fornisce la densità p_i del punto, che combina informazione spaziale e cinematica. Si tratta di una versione semplificata del contributo $P(v_t \mid s_t, R)$ della Sezione 3.5.1, in cui le probabilità della posizione e delle componenti della velocità sono stimate sui soli punti della rotta che cadono nello stato s_t. Qui invece entrambe le KDE sono calcolate sull'intera rotta e la seconda dipende dal solo modulo della velocità, per cui la direzione del moto non entra nel termine di osservazione. Le KDE vengono così stimate una sola volta per l'intera rotta, coerentemente con l'approccio batch descritto nella Sezione 3.4.1; stimarle separatamente per ogni stato richiederebbe migliaia di stime, ciascuna basata su pochi punti.

Lo stato (o intorno) associato a un punto i è l'insieme N_i dei punti della rotta la cui distanza da i, calcolata con la Great-Circle Distance, è inferiore a $d = 500$ m. In Figura 3.4 è riportato, in rosso, lo stato di un punto della rotta selezionata scelto a caso. A ogni punto viene associata la somma dei logaritmi delle densità dei punti del suo stato,

$$L_i = \sum_{j \in N_i} \log p_j,$$

e il termine di osservazione di un trip è la media dei valori L_i dei suoi punti. Questa formulazione si discosta da quella di Pallotta et al. [2], in cui lo stato serve a stimare le probabilità a partire dai soli punti vicini. Poiché le densità, espresse in deg^{-4}, sono in gran parte maggiori di 1, i loro logaritmi sono positivi e L_i cresce con il numero di punti nello stato premiando in questo modo i punti che si trovano nelle

zone più frequentate della rotta.

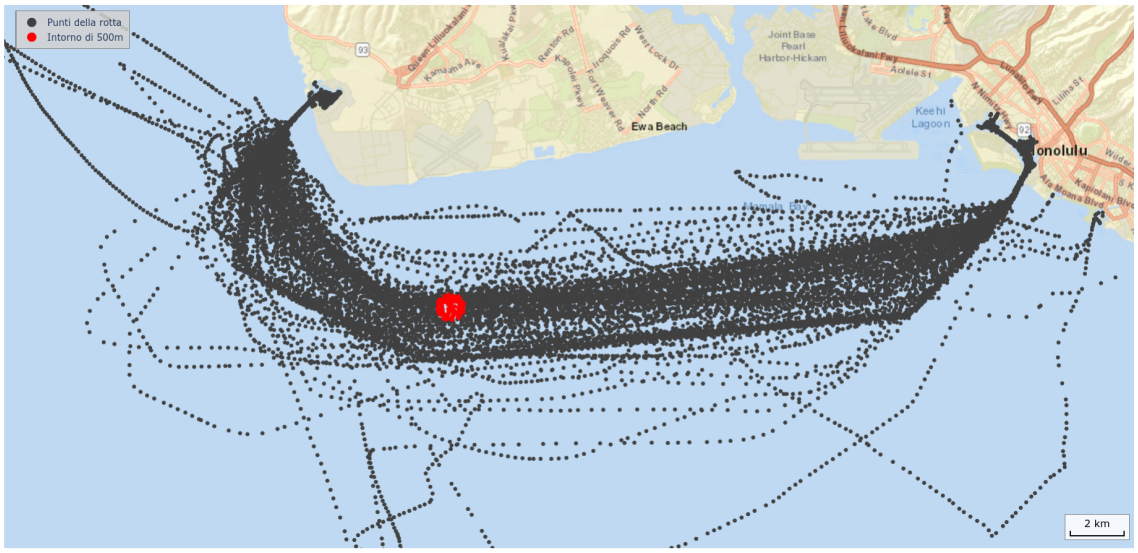


Figura 3.4: Punti della rotta selezionata (in grigio) e stato di raggio $d = 500$ m di un punto scelto a caso (in rosso).

3.5.4 Termine di transizione

Il termine di transizione misura quanto è prevedibile il moto della nave da un punto al successivo. Per ogni coppia di punti consecutivi del trip, la posizione del secondo punto viene predetta a partire dal primo, e la distanza Δp tra la posizione predetta e quella osservata misura l'errore di predizione (Figura 3.5). Un errore piccolo indica che la nave si è mossa come previsto, un errore grande che ha cambiato velocità o direzione in modo inatteso.

La predizione si ispira al Track Predictor (algoritmo 4 di Pallotta et al. [2]), che propaga la posizione a piccoli passi usando la mediana delle velocità dei punti della rotta vicini alla posizione corrente. La presente implementazione è più semplice e stima la posizione futura ipotizzando che la nave proceda con la stessa direzione e la stessa velocità della propria ultima osservazione. La semplificazione è giustificata dal fatto che i record sono campionati al minuto (quindi due punti consecutivi sono vicini nel tempo) e in un intervallo così breve la nave mantiene in genere velocità e direzione. Si evita inoltre la ricerca dei punti vicini a ogni passo di propagazione. Lo spostamento viene calcolato a partire dalle componenti della velocità V_x e V_y ed è espresso in miglia nautiche. Viene poi convertito in gradi considerando che un miglio nautico corrisponde a 1/60 di grado di latitudine, mentre in longitudine il valore va ulteriormente diviso per cos(lat). La distanza Δp, espressa in metri, è infine calcolata in maniera analoga a quanto descritto nella Sezione 3.3.3.

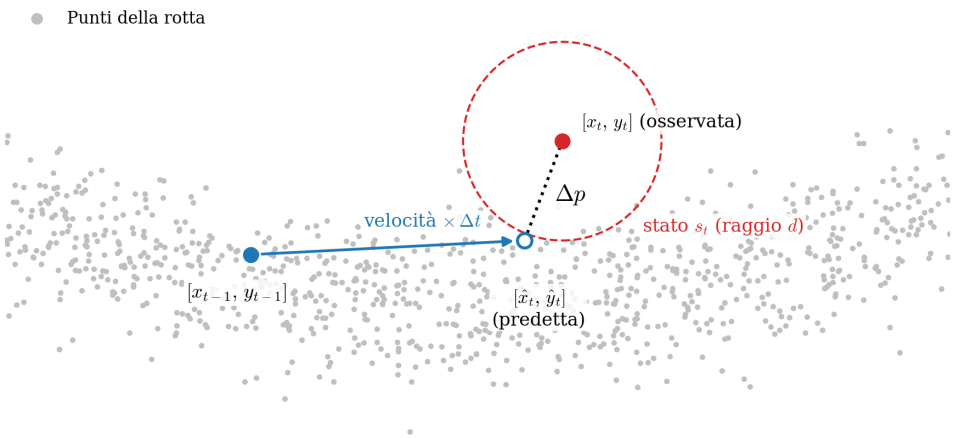


Figura 3.5: Schema dell'errore di predizione. A partire dalla posizione precedente (in blu) e dalla sua velocità si predice la posizione dopo un intervallo Δt (cerchio vuoto). La distanza Δp dalla posizione osservata (in rosso) è l'errore di predizione. Il cerchio tratteggiato è lo stato s_t della posizione osservata.

Per trasformare l'errore in una probabilità, Pallotta et al. ricorrono alla distribuzione di Weibull. La probabilità di transizione è

$$P(s_t \mid s_{t-1}, R) = \exp\left[-\left(\frac{\Delta p}{\alpha}\right)^{\beta}\right], \tag{3.3}$$

cioè la probabilità che l'errore di predizione sia almeno pari a Δp. Vale 1 per $\Delta p = 0$ e decresce all'aumentare dell'errore, tanto più rapidamente quanto più piccolo è il parametro di scala α. Secondo Pallotta et al. [2], il parametro di forma β è costante, mentre il parametro di scala cresce linearmente con l'intervallo di tempo Δt tra le due osservazioni, $\alpha = m \cdot \Delta t$. Sostituendo nell'equazione (3.3) si ottiene l'equazione 14 di Pallotta et al. [2],

$$P(s_t \mid s_{t-1}, R) = \exp\left[-\left(\frac{\Delta p}{m \cdot \Delta t}\right)^{\beta}\right].$$

A parità di Δt la probabilità diminuisce al crescere dell'errore Δp, mentre a parità di errore aumenta al crescere di Δt.

I parametri m e β sono stimati sull'intero insieme dei trip della rotta, considerando diversi *lag* temporali, cioè intervalli di tempo su cui viene misurato l'errore di predizione. Per ogni punto di un trip si cerca il punto dello stesso trip registrato circa un lag prima, si predice da questo la posizione del punto corrente e se ne misura l'errore Δp. Il punto precedente viene accettato solo se la sua distanza temporale

dal punto corrente differisce dal lag di non più del 30–50%, con una tolleranza maggiore per i lag più brevi. Pallotta et al. usano lag da 5 a 60 minuti, con passo di 5 minuti. Nella presente implementazione si usano invece 11 lag equidistanti adattati alla durata dei trip, con un minimo pari al maggiore tra 30 s e un ventesimo della durata del trip più breve e un massimo pari al minore tra un quinto della durata mediana dei trip e un'ora. Questa scelta si lega al fatto che i trip della rotta selezionata durano da circa 84 minuti a qualche ora, con una mediana di circa 2,3 ore. In questo caso lag fino a 60 minuti coprirebbero una parte troppo grande di ciascun trip, lasciando poche coppie di punti per la stima. Per ogni lag si ottiene così una distribuzione di distanze Δp, su cui viene stimata una distribuzione di Weibull tramite `scipy.stats.weibull_min`. Il parametro m è infine ottenuto con una regressione lineare dei parametri di scala stimati rispetto ai lag, mentre β è la media dei parametri di forma, ottenuti dalle stime delle distribuzioni di Weibull per ogni lag. Sulla rotta selezionata i lag vanno da 252 a 1.679 secondi, mentre la maggior parte dei punti consecutivi è separata da intervalli più brevi; questo limite è discusso nella Sezione 3.7.

Il termine di transizione di un trip è la media dei logaritmi delle probabilità di transizione tra punti consecutivi,

$$\frac{1}{n-1}\sum_{t=2}^{n}\log P(s_t \mid s_{t-1}, R) \;=\; -\frac{1}{n-1}\sum_{t=2}^{n}\left(\frac{\Delta p_t}{m\cdot\Delta t_t}\right)^{\beta},$$

calcolata direttamente in forma logaritmica, per evitare che le probabilità molto piccole vengano arrotondate a zero. La divisione per il numero di transizioni, assente nell'originale, rende confrontabili trip di lunghezza diversa. Senza di essa i trip più lunghi otterrebbero punteggi più bassi solo per il maggior numero di termini nella somma.

3.5.5 Punteggio di normalità

Il punteggio di normalità di un trip è la somma dei tre termini dell'equazione (3.2). Il termine a priori è stimato come il rapporto tra il numero di navi distinte che percorrono la rotta e il numero di navi distinte presenti nelle rotte analizzate. Questo denominatore si discosta da quello di Pallotta et al. [2], in cui la stessa grandezza è rapportata al numero totale di navi del dataset. La probabilità a priori serve infatti a confrontare tra loro le rotte candidate, per cui viene normalizzata sulle sole rotte analizzate. Poiché l'analisi è condotta su una sola rotta, numeratore e denominatore coincidono e la probabilità a priori risulta pari a 1 per tutti i trip. Con il denominatore di Pallotta et al. varrebbe invece 40/403, cioè circa 0,099. La

scelta non influisce però sul ranking, in quanto il denominatore è lo stesso per tutte le rotte e per tutti i trip, quindi cambiarlo aggiunge la stessa costante al punteggio di ogni trip. Il termine viene comunque mantenuto nell'implementazione per consentire l'estensione dell'analisi a più rotte contemporaneamente.

I trip vengono infine ordinati per punteggio di normalità, e quelli con punteggio più basso sono i candidati anomali. La scelta della soglia che separa i trip normali da quelli anomali è descritta nella Sezione 4.3.4.

3.6 Tecnologie utilizzate

L'intera pipeline è implementata in **Python 3**, organizzata in file Jupyter Notebook separati. I parametri di configurazione sono centralizzati in un unico file ".py" a cui hanno accesso tutti i Notebook Jupyter.

Le librerie principali utilizzate sono:

- **Polars**: per sfruttare il multithreading durante l'importazione dei file CSV giornalieri e il filtraggio geografico iniziale;
- **Pandas**: per la manipolazione del dataset nelle fasi successive all'importazione;
- **NumPy**: per i calcoli vettoriali e le operazioni sulle serie temporali;
- **scikit-learn**: per l'implementazione di DBSCAN;
- **hdbscan**: per l'implementazione di H-DBSCAN;
- **SciPy**: per il calcolo dei convex hull, la Kernel Density Estimation e il fitting della distribuzione di Weibull;
- **Shapely**: per le operazioni geometriche sui poligoni waypoint;
- **GeoPandas**: per la visualizzazione rapida dei poligoni waypoint per verifiche qualitative;
- **Plotly**: per la visualizzazione interattiva dei risultati su mappa geografica.

La scelta di Python è motivata dalla disponibilità di un ecosistema maturo per l'analisi di dati anche geospaziali e la sua relativa facilità di utilizzo.

3.7 Limiti della metodologia

La metodologia presentata in questo capitolo presenta alcuni limiti che è opportuno dichiarare esplicitamente. Un primo limite, comune a molti dei lavori citati nel Capitolo 2, riguarda la copertura geografica: il dataset del NOAA è limitato alle aree costiere statunitensi, e la tesi si concentra sulle Hawaii, un arcipelago con un traffico relativamente contenuto rispetto ad aree come lo Stretto di Gibilterra o l'Adriatico settentrionale studiate nell'articolo originale di Pallotta et al. [2]. I risultati ottenuti potrebbero quindi non generalizzarsi ad aree con densità di traffico diverse.

Un secondo limite è di natura computazionale: l'implementazione scikit-learn di DBSCAN ha un costo in memoria $O(n^2)$ rispetto al numero di punti in input (si veda la Sezione 3.4.2 per i dettagli). La RAM disponibile sulla macchina utilizzata non era sufficiente per eseguire l'algoritmo direttamente sui punti grezzi del dataset, rendendo necessaria una fase di pre-aggregazione per coordinate GPS. Questa fase è un vincolo imposto dall'hardware, che con risorse maggiori non sarebbe stato necessario, e comporta una perdita di informazione contenuta, perché le coordinate vengono arrotondate e i punti con le stesse coordinate vengono fusi in un'unica riga con un peso. L'espansione della tabella dei pesi usata per H-DBSCAN dipende invece dalla libreria `hdbscan`, che non supporta l'associazione di pesi ai vari punti da processare.

Un ulteriore limite, intrinseco alla tecnologia AIS stessa e già discusso nel Capitolo 2, riguarda la natura dei dati alla fonte. Il sistema AIS traccia esclusivamente le imbarcazioni che montano e utilizzano attivamente il transponder. Poichè l'obbligo di installazione, imposto dalla convenzione SOLAS, si applica solo alle navi con stazza lorda superiore a una certa soglia e alle navi passeggeri [1], il naviglio minore (imbarcazioni da diporto, pescherecci di piccole dimensioni, mezzi non commerciali) non è quindi soggetto a tale obbligo ed è presente nel dataset solo in parte. Nel dataset analizzato i dispositivi di Classe B, tipicamente utilizzati da questa categoria di imbarcazioni, generano il 35,4% dei record e riguardano 190 navi su 403. Ne consegue che tutto il traffico associato a vascelli privi di transponder AIS risulta completamente invisibile a questa analisi. A questo si aggiungono i limiti di qualità del dato già discussi nel Capitolo 2, quali le lacune di copertura dei ricevitori terrestri e la possibilità di manipolazione dei messaggi tramite spoofing o spegnimento volontario del transponder [4], fattori che, pur non specificamente analizzati in questa tesi, contribuiscono al divario tra il traffico realmente presente nell'area e quello effettivamente osservabile tramite AIS.

Un ultimo limite riguarda la stima della distribuzione di Weibull. I parametri

sono stimati su intervalli temporali compresi tra 252 e 1.679 secondi, mentre i dati sono campionati a un record al minuto e il 99,1% delle transizioni tra punti consecutivi dei trip della rotta selezionata dura meno di 252 secondi. Il modello viene quindi applicato quasi sempre al di fuori dell'intervallo su cui è stato stimato. L'effetto sui risultati è trascurabile, perché il termine di transizione varia in un intervallo molto più piccolo del termine di osservazione e incide poco sul ranking (Sezione 4.4). Una prova con parametri stimati su intervalli tra 60 e 300 secondi ha infatti lasciato invariati ranking e metriche. Una stima su intervalli coerenti con il campionamento dei dati resta comunque un possibile sviluppo futuro.

3.8 Sintesi e anticipazione dei risultati

Il capitolo ha descritto la metodologia adottata per replicare, adattare e estendere il framework TREAD di Pallotta et al. su dati AIS reali relativi alle Hawaii. La pipeline comprende una fase di pre-processing (importazione, pulizia e ottimizzazione, calcolo della velocità media e classificazione degli stati), la fase di Knowledge Discovery con il doppio utilizzo di DBSCAN e H-DBSCAN per l'identificazione dei waypoint e la successiva assegnazione delle rotte, e infine una fase di anomaly detection basata su KDE e distribuzione di Weibull.

Le principali differenze rispetto all'algoritmo originale sono: l'adozione di H-DBSCAN al posto di DBSCAN incrementale, motivata dalla necessità di gestire cluster a densità variabile, l'approccio batch in luogo di quello incrementale (dovuto all'hardware disponibile), il calcolo del punteggio sull'intero trip anziché su una finestra temporale mobile, il termine di osservazione basato sull'intorno di 500 m e la predizione della posizione a partire dall'ultima osservazione della nave, l'introduzione della normalizzazione per lunghezza del trip nel calcolo del punteggio di normalità, non presente nell'originale.

Il Capitolo 4 presenta i risultati ottenuti tra cui ad esempio: i waypoint identificati, le rotte estratte, i parametri del modello Weibull stimati e il ranking di anomalia dei trip sulla rotta selezionata.

Capitolo 4

Risultati

Questo capitolo presenta i risultati ottenuti applicando la pipeline descritta nel Capitolo 3 al dataset AIS delle Hawaii. I risultati sono organizzati in cinque sezioni. La prima descrive il dataset nelle sue dimensioni finali dopo il pre-processing; la seconda mostra i risultati qualitativi prodotti dalla fase di Knowledge Discovery; la terza riporta i risultati quantitativi della fase di anomaly detection; la quarta ne discute l'interpretazione e le implicazioni; la quinta riassume i risultati principali.

4.1 Dataset

Il dataset utilizzato comprende i messaggi AIS ricevuti dal NOAA nel primo trimestre del 2019 (gennaio-marzo inclusi), filtrati sull'area geografica delle Hawaii tramite la bounding box descritta nella Sezione 3.2.

4.1.1 Dimensioni e composizione

I dati grezzi, dopo il filtraggio geografico, ammontano a 5.462.415 record. A seguito della rimozione dei duplicati esatti il dataset si riduce a 5.460.800 record, generati da 602 imbarcazioni distinte (in media 9.071 record per nave, con un minimo di 1 e un massimo di 82.554).

L'applicazione della soglia dinamica sull'attività delle imbarcazioni (Sezione 3.3), pari al 10% del numero medio di record per nave e quindi a 907 record, ha eliminato 199 imbarcazioni, corrispondenti allo 0,84% dei record totali. Il dataset risultante conta 5.415.168 record relativi a 403 imbarcazioni. Il numero di record per nave ha una media di 13.437 e una deviazione standard di 16.309, con un massimo di 82.554 e un minimo di 921.

4.1.2 Classificazione degli stati e punti stazionari

Prima del calcolo della velocità sono stati rimossi 5 record con la stessa coppia (`MMSI`, `BaseDateTime`) di un altro record, lasciandone 5.415.163. Nella fase di classificazione degli stati di navigazione sono stati poi rimossi 7 record associati a velocità istantanee non plausibili (superiori a 102 nodi) e 27 record appartenenti a sequenze di punti *entry* o *exit* consecutivi (Sezione 3.3.3), portando il dataset a 5.415.129 record complessivi. Di questi, 3.766.844 punti (69,56%) sono stati classificati come stazionari (comprendendo gli stati *stationary*, *entry* ed *exit*), e costituiscono l'insieme di partenza per la fase di Knowledge Discovery. L'aggregazione di questi punti per coppia di coordinate, necessaria per contenere il costo computazionale del clustering (Sezione 3.4.2), ha prodotto 51.801 coordinate distinte, ciascuna con un peso legato al numero di punti che vi ricadono.

4.1.3 Waypoint e rotte estratte

Il clustering H-DBSCAN applicato ai punti stazionari aggregati ha identificato 144 waypoint distinti (da `WP_0` a `WP_143`). I punti che ricadono in più di un waypoint, a causa della sovrapposizione degli inviluppi convessi, sono 7.298, pari allo 0,135% del dataset, per cui l'effetto della regola di assegnazione descritta nella Sezione 3.4.3 è trascurabile. A partire da questi waypoint, sono state estratte in tutto 766 rotte distinte e 36.033 trip.

Per la fase di anomaly detection è stata selezionata la rotta `WP_135 - WP_118`, una delle più trafficate tra quelle estratte, percorsa da 40 imbarcazioni distinte per un totale di 184 trip. La lunghezza dei trip varia da 41 a 524 punti, con una media di circa 110 punti e una mediana di 95,5.

4.2 Risultati qualitativi

Questa sezione mostra gli output visivi prodotti dalla fase di Knowledge Discovery, con l'obiettivo di verificare che i waypoint e le rotte estratte corrispondano a strutture geograficamente coerenti con il traffico marittimo dell'arcipelago delle Hawaii.

Tutte le mappe di questa sezione seguono le stesse convenzioni. Il riquadro rosso delimita l'area di studio, cioè la bounding box descritta nella Sezione 3.2, e la barra in basso a destra indica la scala della mappa, che varia da una figura all'altra. Ogni waypoint è rappresentato dal suo inviluppo convesso (*convex hull*), con il contorno nero; nelle mappe delle rotte accanto a ogni waypoint ne è riportato il nome. Il

significato del colore è indicato dalla barra a destra di ogni mappa. Nelle mappe dei waypoint il colore rappresenta il peso delle coordinate aggregate; in quelle delle rotte rappresenta il numero di trip in scala logaritmica.

4.2.1 Waypoint identificati

Le Figure 4.1 e 4.2 mostrano i cluster di punti stazionari ottenuti rispettivamente con DBSCAN ($\varepsilon = 0{,}075$ e $N_{\min} = 10$) e con H-DBSCAN (min_cluster_size = 30, max_cluster_size = 10.000, cluster_selection_epsilon = 0,01), con i parametri descritti nella Sezione 3.4.2. In entrambe le figure i punti colorati sono quelli assegnati a un cluster e i punti bianchi quelli classificati come rumore. Il colore indica il peso di ciascuna coordinata aggregata, pari al logaritmo in base 2 del numero di messaggi AIS che vi ricadono, arrotondato all'intero più vicino (Sezione 3.4.2).

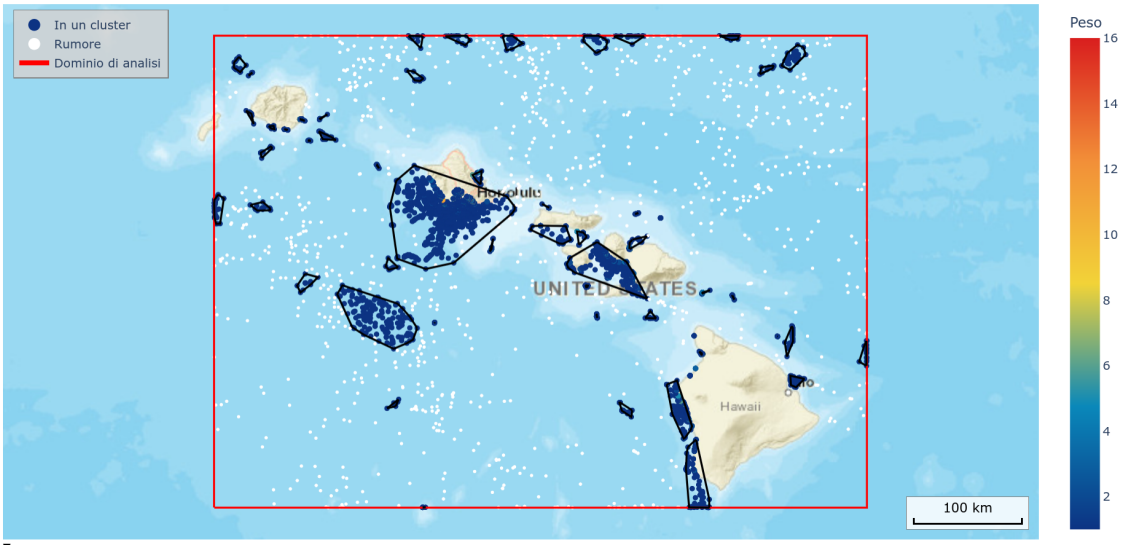


Figura 4.1: Waypoint identificati con DBSCAN ($\varepsilon = 0{,}075$ e $N_{\min} = 10$).

DBSCAN individua 55 cluster e classifica come rumore 1.001 delle 51.801 coordinate aggregate (1,93%); H-DBSCAN, eseguito sulla tabella espansa secondo i pesi (Sezione 3.4.2), individua 144 cluster e scarta 2.800 punti su 96.913 (2,89%). Il confronto mette in evidenza il limite principale di DBSCAN con un raggio ε fisso. Nell'area del porto di Honolulu e delle zone di ancoraggio vicine, la densità di punti stazionari è molto alta, e DBSCAN raggruppa tutta la zona in un unico grande cluster che copre buona parte dell'isola di Oahu. Lo stesso succede lungo la costa occidentale dell'isola di Maui e lungo la costa di Kona sull'isola di Hawaii, dove punti di sosta distinti vengono fusi in poligoni allungati. Un waypoint di queste dimensioni non è utile per l'estrazione delle rotte, perché fa coincidere in un solo nodo del grafo origini e destinazioni che invece sono diverse.

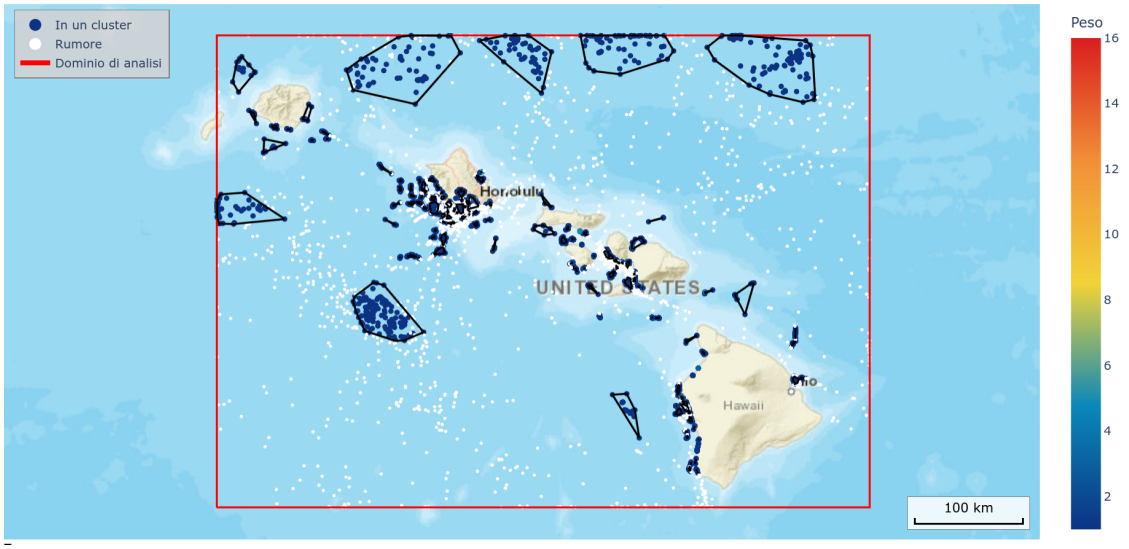


Figura 4.2: Waypoint identificati con H-DBSCAN (min_cluster_size = 30, max_cluster_size = 10.000, cluster_selection_epsilon = 0,01).

H-DBSCAN, potendo adattarsi a densità locali diverse, scompone le stesse aree in molti cluster più piccoli e compatti, che corrispondono in modo più plausibile a singoli porti, moli e zone di ancoraggio. Nelle zone a bassa densità in mare aperto avviene invece il contrario. Lungo il bordo settentrionale della bounding box DBSCAN individua solo alcuni cluster di piccole dimensioni, mentre H-DBSCAN raggruppa i punti sparsi della stessa zona in pochi cluster molto estesi. Per la sua capacità di separare porti e zone di ancoraggio distinti nelle aree più dense, H-DBSCAN è stato adottato come approccio principale per le fasi successive della pipeline.

4.2.2 Rotte estratte

Per visualizzare le rotte, i trip sono stati divisi in tre gruppi in base ai waypoint di origine e di destinazione, cioè rotte tra due waypoint distinti (`WP_A - WP_B`), rotte che tornano al waypoint di partenza (`WP_A - WP_A`, *self-loop*) e rotte con almeno un estremo non classificato (`<NA>`). Dei 36.033 trip estratti, 4.089 (11,3%) appartengono al primo gruppo, 30.981 (86,0%) al secondo e 963 (2,7%) al terzo.

Rotte tra waypoint distinti. La Figura 4.3 mostra le rotte come archi di un grafo orientato i cui nodi sono i waypoint. Le coppie ordinate di waypoint distinti collegate da almeno un trip sono 557; per leggibilità sono disegnate solo le 63 rotte con almeno 10 trip, che coprono comunque 3.062 dei 4.089 trip del gruppo (74,9%). Senza questa soglia, come mostra il confronto con la Figura 4.4, le rotte con meno

di 10 trip, che sono la grande maggioranza, coprirebbero gran parte dell'area e renderebbero difficile distinguere quelle principali. Ogni freccia segue il trip *medoide* della rotta, calcolato come segue. Ogni trip della rotta viene ricampionato in 60 punti equidistanti lungo il suo percorso, così che tutti i trip abbiano lo stesso numero di punti indipendentemente dalla loro lunghezza e dalla frequenza dei messaggi AIS. La distanza tra due trip è la media delle distanze tra i punti corrispondenti, cioè tra l'i-esimo punto del primo e l'i-esimo punto del secondo. Il medoide è il trip con la minima somma delle distanze da tutti gli altri trip della stessa rotta. A differenza di una traiettoria media, il medoide è sempre un trip realmente percorso. Il numero accanto a ogni freccia, qui e negli ingrandimenti che seguono, indica il numero di trip rilevati per quella rotta.

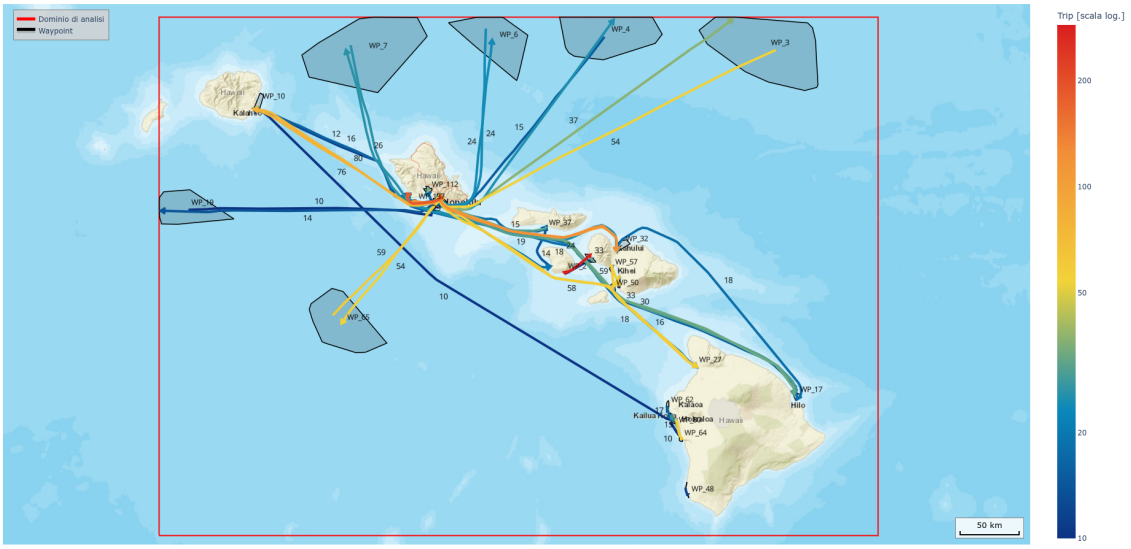


Figura 4.3: Grafo delle rotte tra waypoint distinti con almeno 10 trip.

Le rotte più frequentate sono `WP_2 - WP_111` e `WP_111 - WP_2` (288 e 287 trip), tra Lahaina, sull'isola di Maui, e la costa meridionale dell'isola di Lanai (Figura 4.5). Il numero quasi identico di trip nei due versi è compatibile con un servizio di linea che fa la spola tra le due isole. Inoltre, il medoide segue quasi esattamente la linea tratteggiata del traghetto tra le isole di Maui e Lanai riportata sulla mappa di base.

Seguono `WP_135 - WP_118` e `WP_118 - WP_135` (184 e 161 trip), tra il porto di Honolulu e quello di Kalaeloa, sulla costa sud dell'isola di Oahu (Figura 4.6). Il waypoint `WP_135`, che corrisponde al porto di Honolulu, è il nodo con più collegamenti (Figura 4.7).

I cluster in mare aperto si trovano in gran parte lungo il bordo della bounding box e rappresentano quindi i punti in cui le navi entrano o escono dall'area di studio.

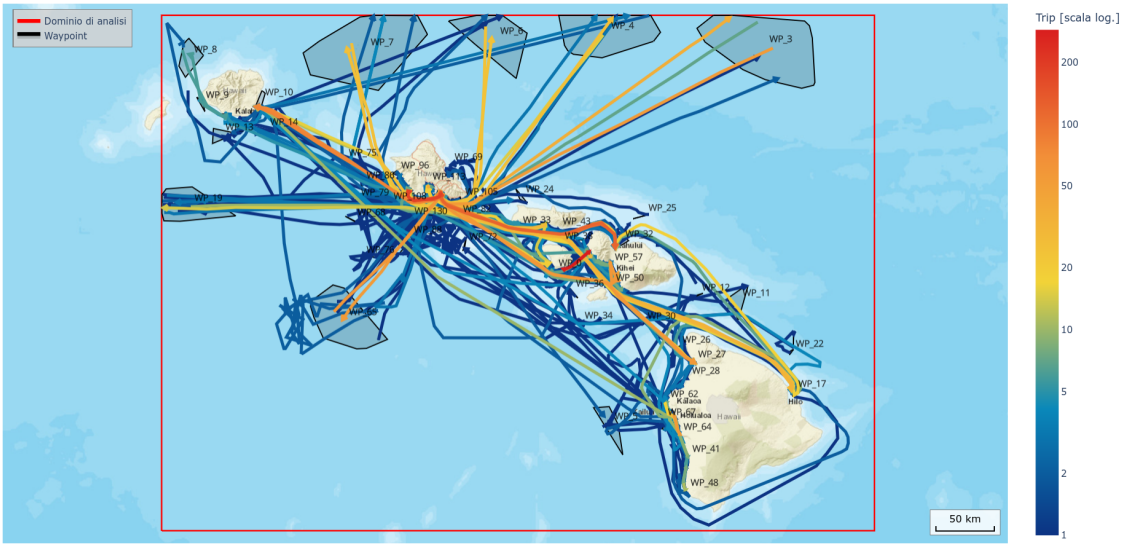


Figura 4.4: Grafo delle rotte tra waypoint distinti senza soglia sul numero di trip, senza i numeri accanto alle frecce.

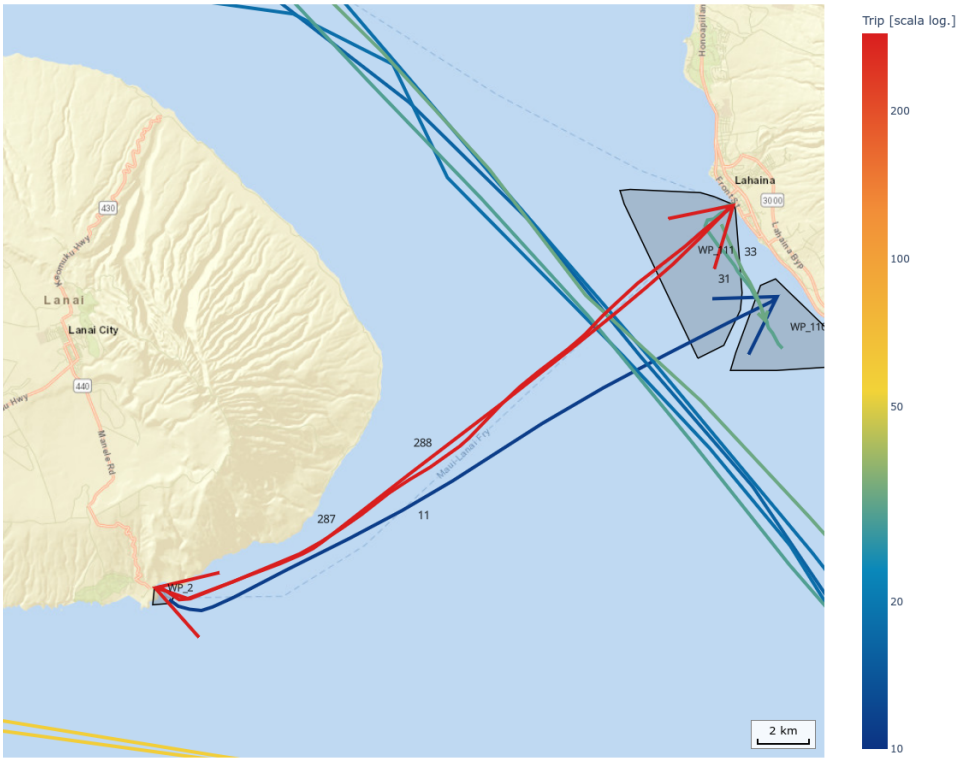


Figura 4.5: Ingrandimento del grafo delle rotte sul canale tra le isole di Maui e Lanai.

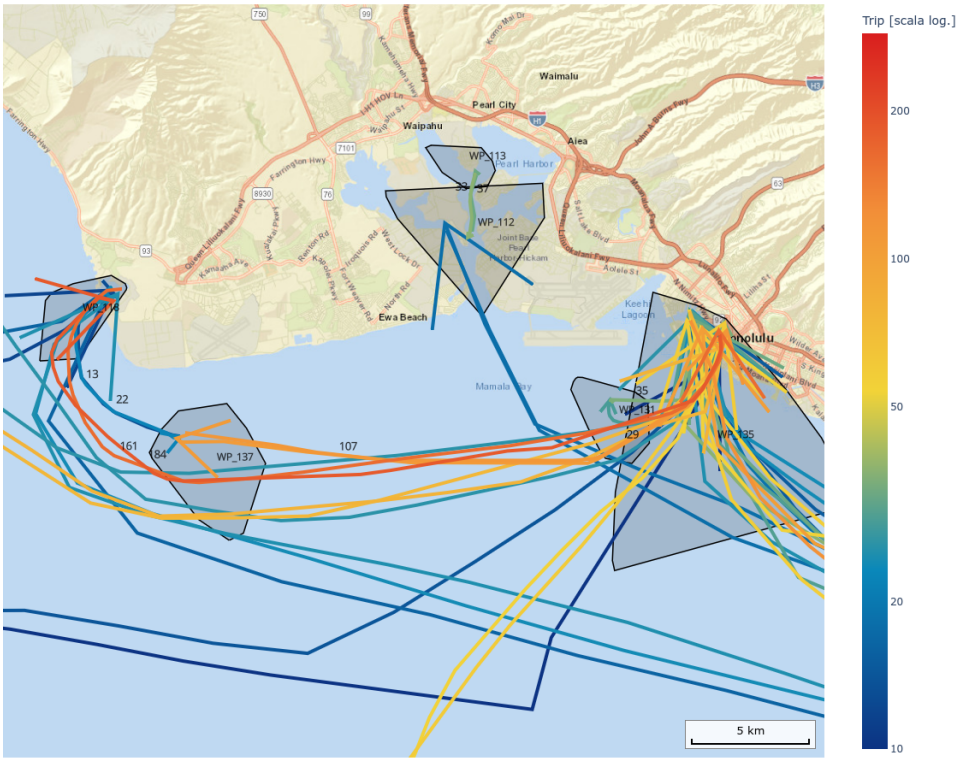


Figura 4.6: Ingrandimento del grafo delle rotte sulla costa meridionale dell'isola di Oahu.

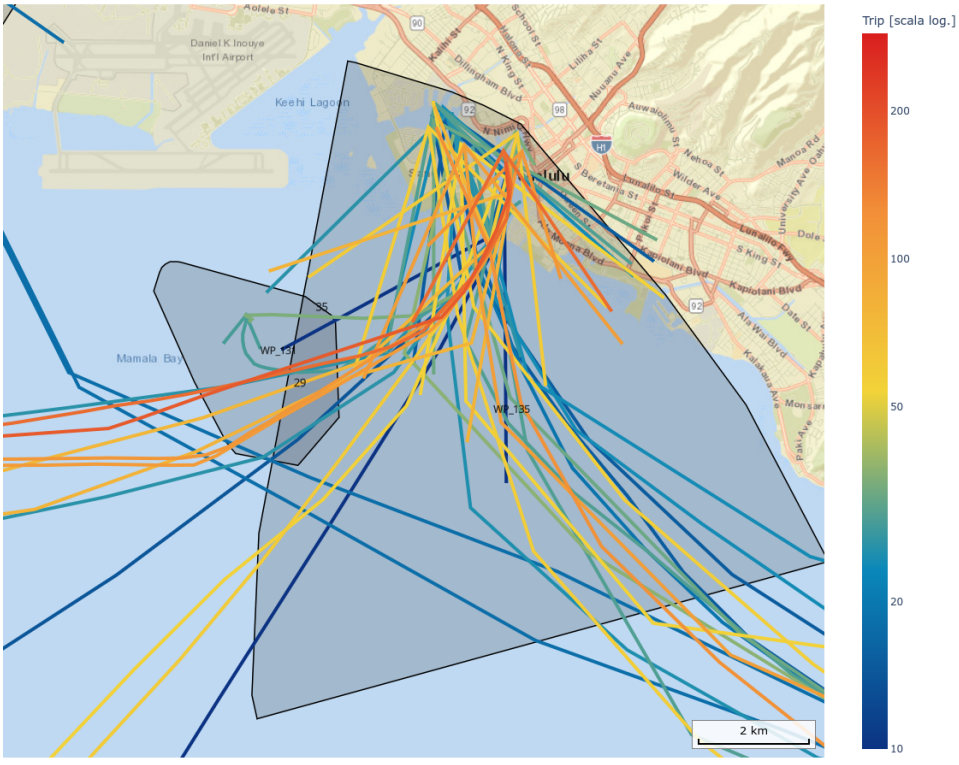


Figura 4.7: Ingrandimento del grafo delle rotte sul porto di Honolulu (`WP_135`).

Per questo le rotte che li raggiungono vanno lette come collegamenti con l'esterno dell'arcipelago più che come tratte tra due località precise.

Rotte di ritorno al waypoint di partenza. I self-loop sono la grande maggioranza dei trip, ma nella maggior parte dei casi non corrispondono a un'uscita in mare. Un punto viene attribuito a un waypoint come sosta solo se la nave è quasi ferma (Sezione 3.4.3). Quando una nave si sposta all'interno del waypoint a una velocità superiore alla soglia, ad esempio per cambiare ormeggio o posizione di ancoraggio, i punti di questo spostamento formano un trip `WP_A - WP_A` anche se la nave non è mai uscita dal waypoint. Solo 1.387 dei 30.981 self-loop (4,5%) contengono almeno un punto esterno al waypoint di partenza. Gli altri, essendo spostamenti interni a un porto o a una zona di ancoraggio, sono esclusi dalle mappe di questa sezione, ma restano inclusi nei conteggi complessivi riportati sopra. La differenza tra i due gruppi è visibile nelle Figure 4.8 e 4.9, che mostrano tutti i self-loop del porto di Honolulu (`WP_135`). Quelli interni restano all'interno del poligono del waypoint, tra le banchine del porto e il tratto di mare compreso nel waypoint, mentre quelli che escono si allontanano in mare aperto prima di farvi ritorno.

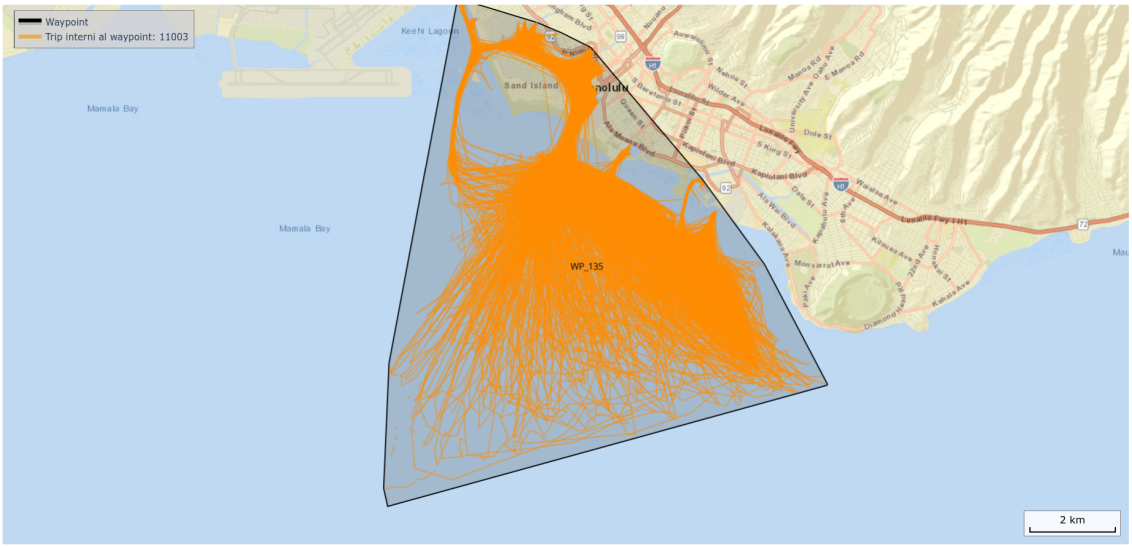


Figura 4.8: Self-loop del porto di Honolulu (`WP_135`) che restano all'interno del waypoint.

I 1.387 trip che escono almeno una volta dal waypoint si distribuiscono su 116 rotte distinte. Di queste 116 rotte, 17 hanno almeno 10 trip e raccolgono complessivamente 1.090 dei 1.387 trip (78,6%). I trip di una stessa rotta self-loop possono avere forma e lunghezza molto diverse, a seconda di dove la nave si è diretta prima di tornare. Per questo non viene disegnata una traiettoria rappresentativa, ma solo

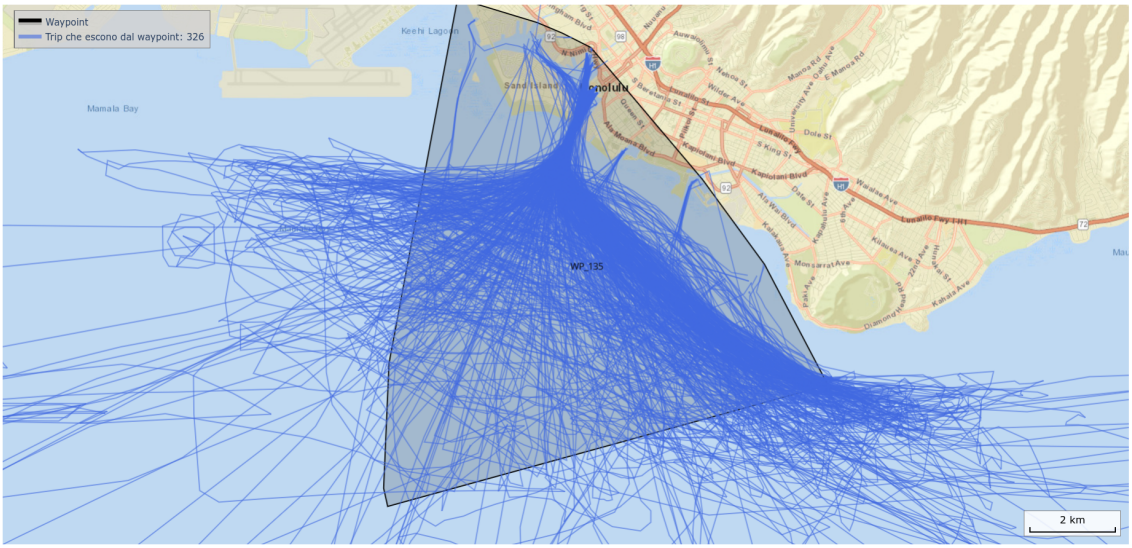


Figura 4.9: Self-loop del porto di Honolulu (`WP_135`) che escono almeno una volta dal waypoint.

i waypoint coinvolti, colorati in base al numero di trip che vi ritornano, con un ingrandimento per ciascuna delle tre aree in cui si concentrano (Figure 4.10, 4.11 e 4.12). L'etichetta `WP_x: n` accanto a ogni waypoint ne riporta il nome e il numero n di questi trip.

I due waypoint con più self-loop sono il porto di Honolulu (`WP_135`, 327 trip, Figura 4.10) e l'area antistante Lahaina (`WP_111`, 278 trip, Figura 4.11). Uscite in mare con ritorno allo stesso porto sono tipiche di imbarcazioni da pesca, di rimorchiatori e delle imbarcazioni che offrono escursioni e altri servizi ai turisti. Sulla costa di Kona (Figura 4.12) il più attivo dei due waypoint è quello più a sud, in corrispondenza di Kailua-Kona.

Rotte con un estremo non classificato. Un trip ha origine o destinazione `<NA>` quando inizia o termina con un punto di *entry* o *exit* che non ricade in alcun waypoint. La Figura 4.13 mostra le traiettorie dei 455 trip con origine non classificata (in blu) e dei 473 con destinazione non classificata (in arancione); i 35 trip in cui entrambi gli estremi non sono classificati non sono disegnati, perché non sono collegati ad alcun waypoint. Poiché `<NA>` non ha una posizione, per questi trip non è possibile calcolare un medoide e vengono disegnate le singole traiettorie, con un marcatore bianco sul primo punto e uno nero sull'ultimo.

Più di tre quarti di questi trip (710 su 928) partono dal porto di Honolulu o vi arrivano (367 trip della rotta `WP_135 - <NA>` e 343 della rotta `<NA> - WP_135`). Gli estremi non classificati si dividono in due gruppi. Una parte si trova sul bordo della bounding box e corrisponde a navi che entrano o escono dall'area di studio; gli

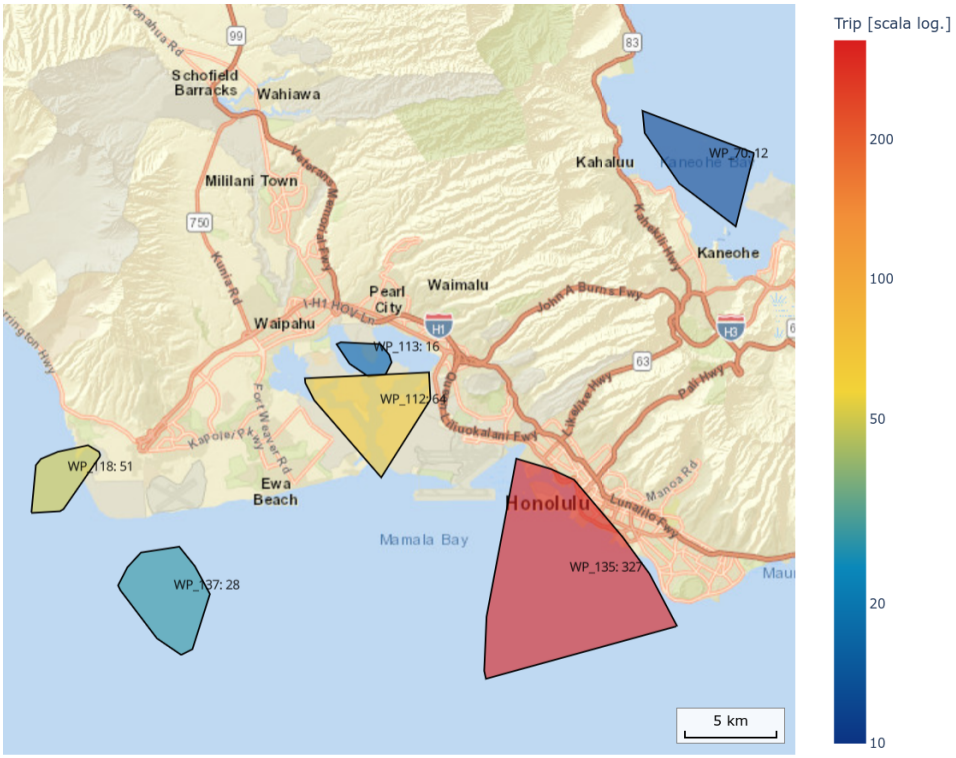


Figura 4.10: Waypoint dell'isola di Oahu con almeno 10 trip che escono dal waypoint e vi ritornano.

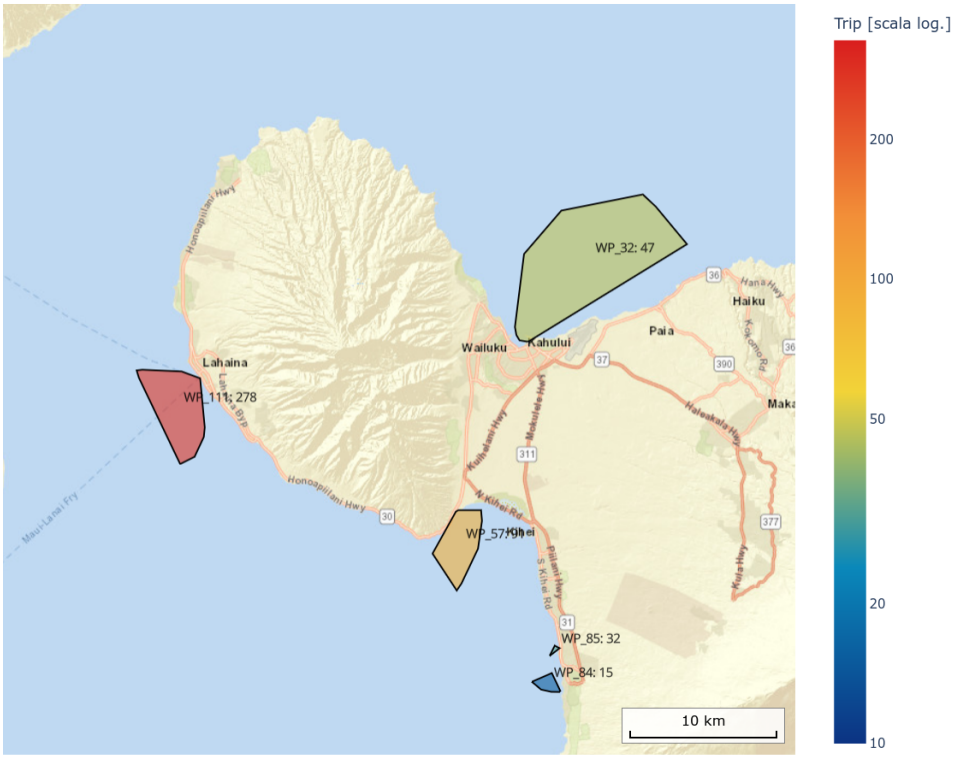


Figura 4.11: Waypoint delle isole di Maui, Lanai e Molokai con almeno 10 trip che escono dal waypoint e vi ritornano.

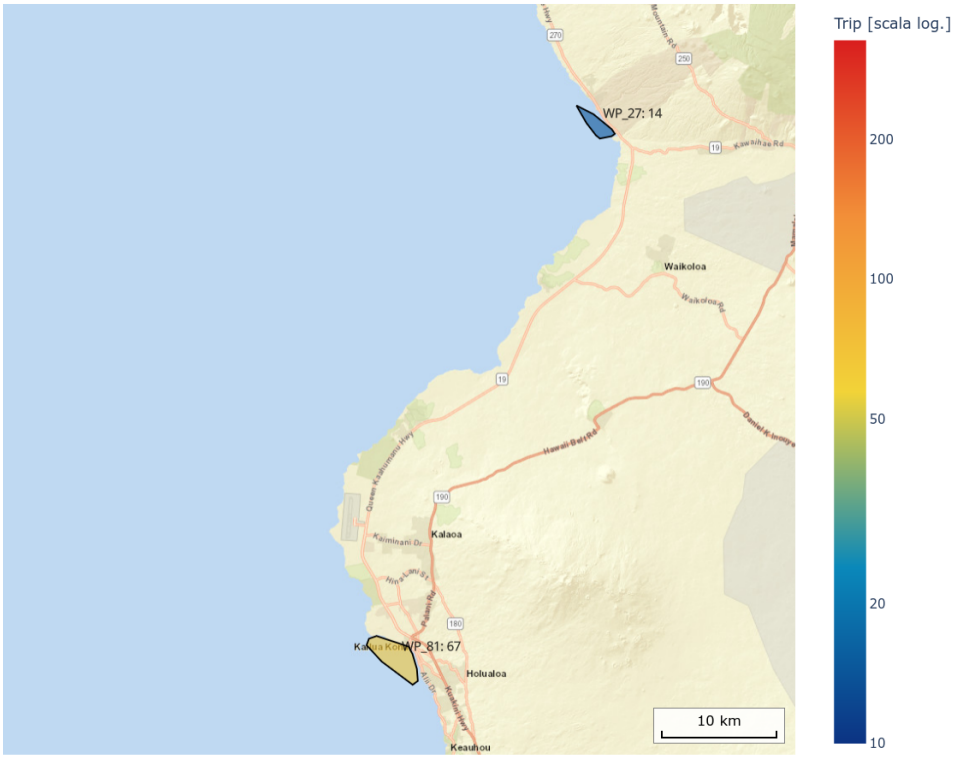


Figura 4.12: Waypoint della costa di Kona, sull'isola di Hawaii, con almeno 10 trip che escono dal waypoint e vi ritornano.

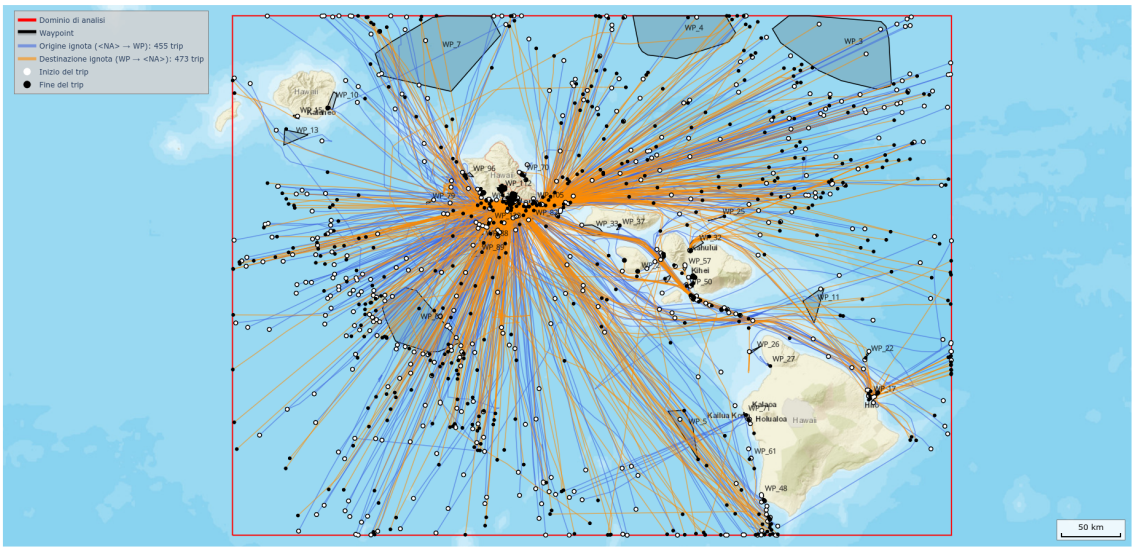


Figura 4.13: Trip con origine non classificata (<NA> → WP, in blu) e con destinazione non classificata (WP → <NA>, in arancione).

altri sono sparsi in mare aperto e corrispondono a soste che non sono state assegnate ad alcun cluster, in quanto classificate come rumore da H-DBSCAN perché troppo isolate per formare un waypoint.

4.2.3 Trip sulla rotta selezionata

La Figura 4.14 mostra i punti dei 184 trip della rotta selezionata `WP_135 - WP_118`, dal porto di Honolulu a Kalaeloa, lungo la costa meridionale dell'isola di Oahu. Ogni punto è colorato in base alla velocità media `Avg_Speed` (Sezione 3.3.3) ed è accompagnato da una freccia grigia, orientata secondo la rotta sul fondo (`COG`) e di lunghezza proporzionale alla velocità media. Per scongiurare problemi di caricamento e visualizzazione del disegno, la mappa mostra un campione casuale uniforme di 5.000 dei 20.241 punti della rotta. La maggior parte dei punti si concentra in un corridoio parallelo alla costa, con velocità più basse in prossimità dei due porti; alcuni trip se ne discostano, allontanandosi verso il largo prima di raggiungere la destinazione.

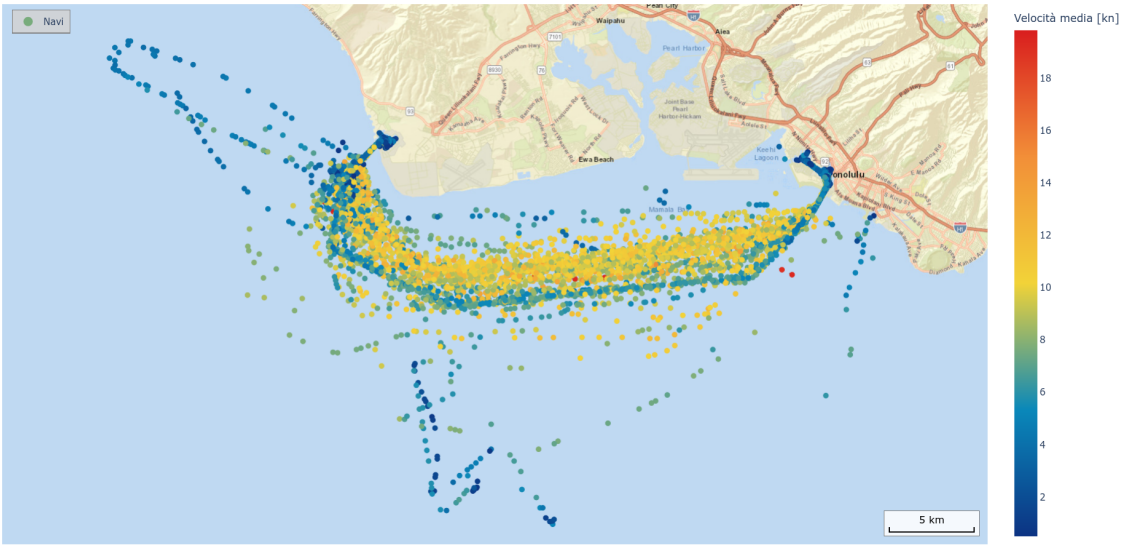


Figura 4.14: Punti dei 184 trip della rotta `WP_135 - WP_118`, colorati in base alla velocità media (campione di 5.000 punti su 20.241).

Alla scala della Figura 4.14 le frecce sono troppo corte rispetto alla dimensione dei punti e non risultano visibili. Per questo motivo la Figura 4.15 riporta un ingrandimento del tratto iniziale della rotta, dal canale di accesso al porto di Honolulu fino al mare aperto, in cui si può apprezzare la direzione del moto. Le frecce sono rivolte verso sud-ovest e poi verso ovest, in accordo con il verso di percorrenza della rotta.

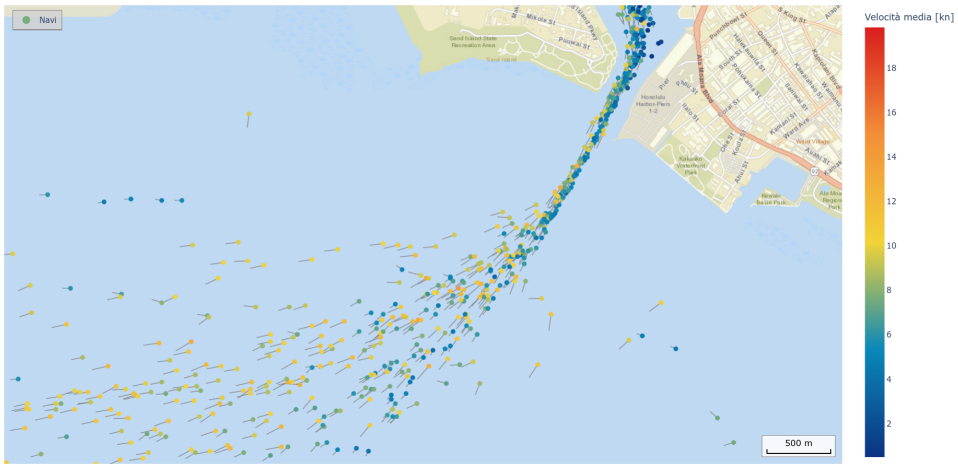


Figura 4.15: Ingrandimento della Figura 4.14 all'uscita dal porto di Honolulu. Le frecce indicano la direzione del moto, con lunghezza proporzionale alla velocità media.

4.3 Risultati quantitativi

4.3.1 KDE

Le due KDE descritte nella Sezione 3.5.3 sono state stimate sui 20.241 punti della rotta selezionata e valutate su una griglia regolare che copre l'area occupata dai punti. La Figura 4.16 mostra la KDE spaziale. La densità è massima all'uscita del porto di Kalaeloa, dove arriva a circa 110 deg^{-2}, e resta elevata lungo il corridoio parallelo alla costa e all'imbocco del porto di Honolulu; al di fuori del corridoio è prossima a zero.

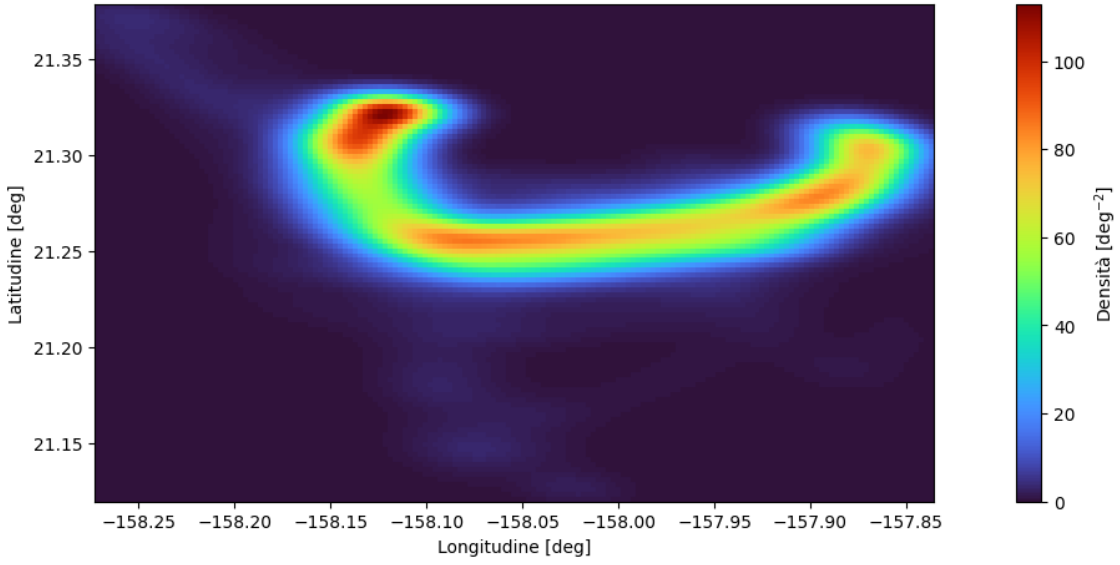


Figura 4.16: KDE spaziale dei punti della rotta `WP_135 - WP_118`.

La KDE pesata per la velocità (Figura 4.17) ha la stessa forma, ma il massimo si sposta sul tratto centrale del corridoio, dove le navi navigano alla velocità di crociera, mentre in prossimità dei due porti, dove le velocità sono più basse, la densità diminuisce.

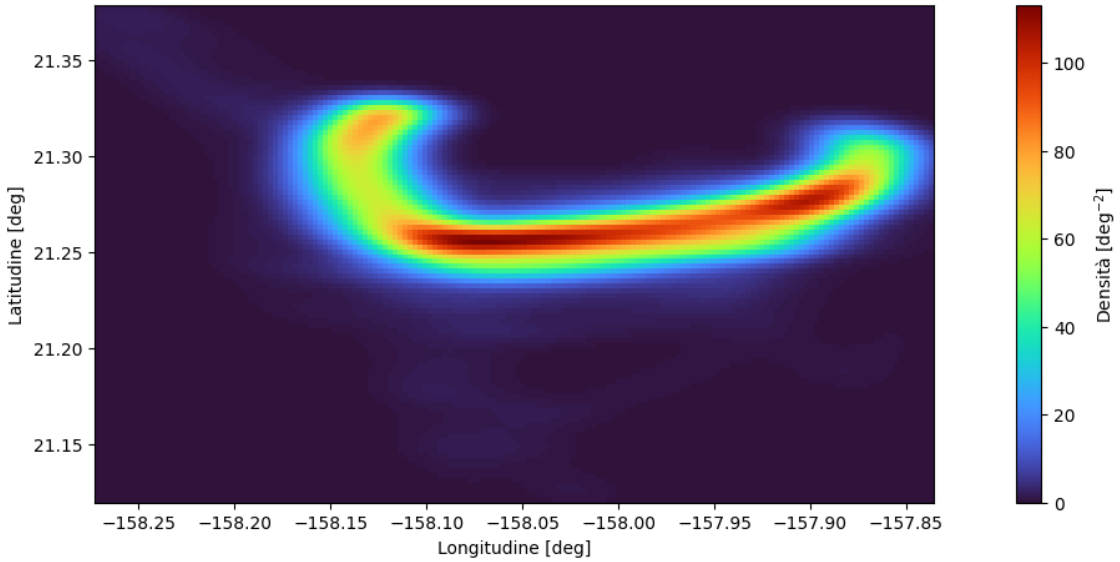


Figura 4.17: KDE dei punti della rotta `WP_135 - WP_118` pesata per la velocità (`SOG`).

Il prodotto delle due KDE fornisce la densità p_i di ogni punto, da cui si ottiene la somma L_i dei logaritmi delle densità nell'intorno di 500 m (Sezione 3.5.3), riportata in Figura 4.18. I valori più alti, fino a circa 9.000, si trovano nel canale di accesso al porto di Kalaeloa e, in misura minore, in quello di Honolulu, dove le navi rallentano e i punti si addensano, per cui ogni intorno contiene molti punti. Lungo il corridoio L_i vale tra circa 1.000 e 2.000, mentre i punti dei trip che si allontanano verso il largo hanno valori prossimi a zero. Sono questi punti ad abbassare il termine di osservazione dei trip corrispondenti, che occupano infatti le ultime posizioni del ranking (Sezione 4.3.3).

4.3.2 Parametri del modello Weibull

I parametri della distribuzione di Weibull, stimati sull'intero insieme di 184 trip della rotta selezionata (Sezione 3.5), risultano pari a $m = 1{,}3105$ m/s (coefficiente della relazione $\alpha = m \cdot \Delta t$ tra parametro di scala e intervallo temporale) e $\beta = 0{,}9358$ (parametro di forma medio). I lag temporali utilizzati sono 11, equidistanti, da 252 s (4,2 minuti) a 1.679 s (28 minuti). Per ciascun lag la Figura 4.19 mostra la distribuzione delle distanze Δp tra posizione prevista e posizione osservata, insieme

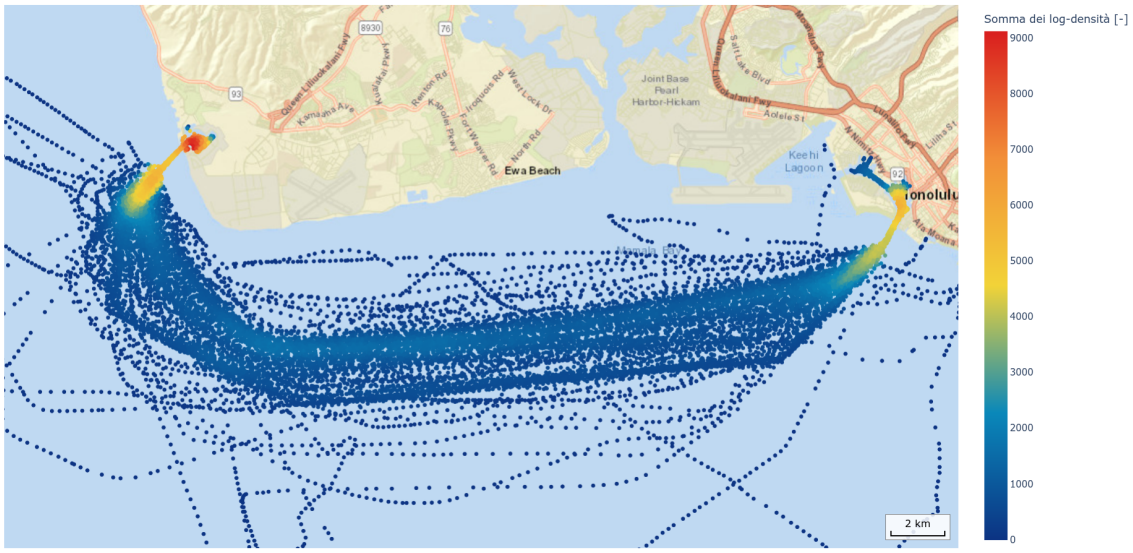


Figura 4.18: Somma L_i dei logaritmi delle densità nell'intorno di 500 m di ogni punto della rotta `WP_135 - WP_118`.

alla distribuzione di Weibull stimata. Il parametro di forma passa da 0,87 per il lag più breve a 1,03 per il più lungo; il parametro di scala cresce da circa 125 m a circa 2.551 m.

La Figura 4.20 mostra a sinistra i parametri di scala stimati ai diversi lag e la retta $\alpha = m \cdot \Delta t$ ottenuta per regressione, a destra le probabilità di transizione (equazione 14 di Pallotta et al. [2]) che ne derivano per tre lag. La relazione lineare ipotizzata da Pallotta et al. [2] descrive i dati solo in modo approssimativo. I parametri di scala crescono più che linearmente con il lag, per cui la retta sovrastima α per i lag brevi e lo sottostima per quelli lunghi. Anche il parametro di forma, che nel modello originale è considerato pressoché costante, aumenta al crescere del lag. Relazioni alternative tra parametro di scala e intervallo temporale potrebbero essere esplorate in sviluppi futuri del lavoro.

4.3.3 Punteggio di normalità e ranking dei trip

Applicando il modello ai 184 trip della rotta selezionata si ottiene un punteggio di normalità per ciascun trip. I punteggi vanno da 211,39 a 3.134,05; la media è pari a 1.994,39 e la deviazione standard a 458,45. La Tabella 4.1 riporta i dieci trip con punteggio più alto, cioè quelli che il modello giudica più regolari, e i dieci con punteggio più basso, che sono i candidati più probabili come anomalie. Il trip più anomalo è il 3372, con un punteggio nettamente inferiore a quello del secondo trip della lista (211,39 contro 385,96 del trip 3413).

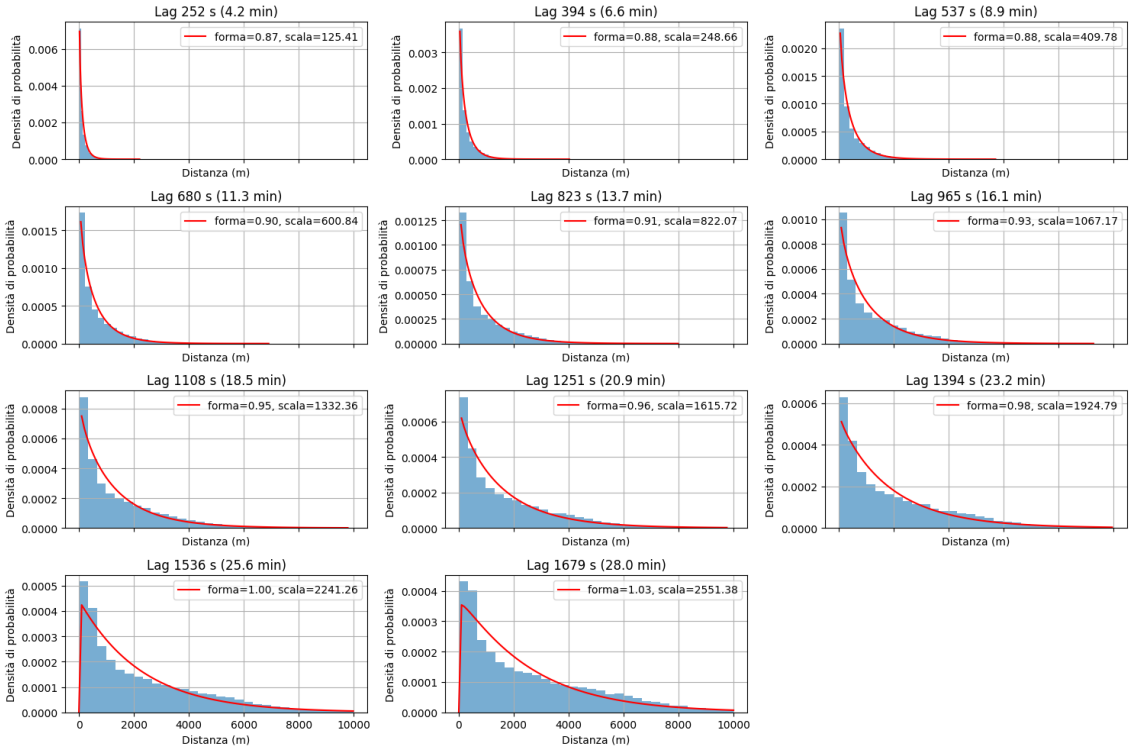


Figura 4.19: Distribuzioni delle distanze Δp tra posizione prevista e posizione osservata per ciascun lag temporale, con la distribuzione di Weibull stimata.

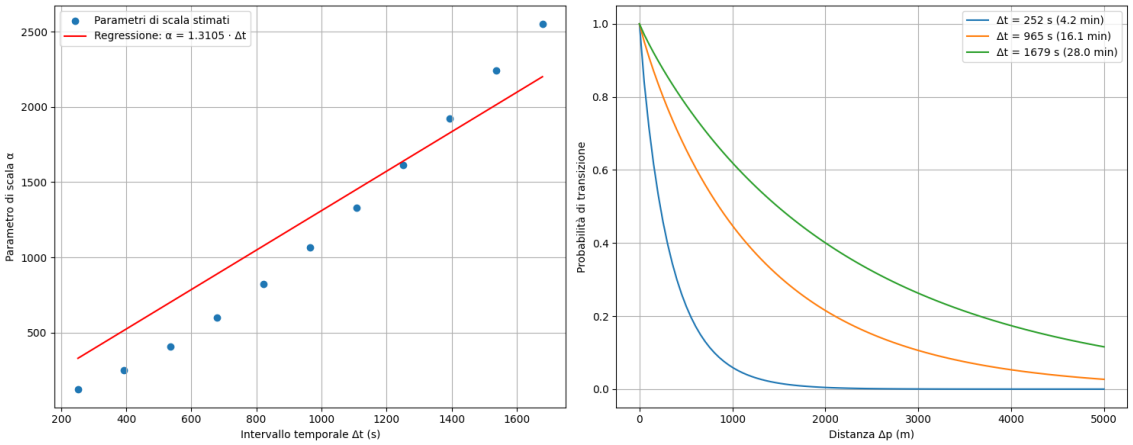


Figura 4.20: A sinistra, parametri di scala stimati ai diversi lag e retta di regressione $\alpha = m \cdot \Delta t$; a destra, probabilità di transizione per tre lag temporali.

Tabella 4.1: I dieci trip con punteggio più alto e i dieci con punteggio più basso sulla rotta `WP_135 - WP_118`.

	Punteggio più alto		Punteggio più basso	
Pos.	**Trip**	**Punteggio**	**Trip**	**Punteggio**
1	23184	3.134,05	3372	211,39
2	24337	2.965,51	3413	385,96
3	23474	2.952,94	3362	420,81
4	8857	2.856,19	10288	468,32
5	11128	2.724,76	30627	712,32
6	14569	2.651,54	10279	733,16
7	8374	2.618,94	24701	814,71
8	15733	2.596,34	7889	942,09
9	25609	2.577,47	30752	1.014,65
10	11307	2.534,98	28433	1.196,21

La Figura 4.21 mostra la distribuzione dei punteggi sui 184 trip, con a sinistra il solo termine di transizione, cioè la log-probabilità delle transizioni normalizzata per il numero di transizioni del trip, e a destra il punteggio di normalità complessivo. Il termine di transizione varia tra $-0{,}78$ e $-0{,}12$; un solo trip, in corrispondenza del valore minimo, è nettamente separato dagli altri. Il punteggio complessivo si concentra tra circa 1.500 e 2.500, con il massimo della distribuzione tra 2.000 e 2.250, e presenta una coda più lunga verso i valori bassi, in cui ricadono i trip candidati come anomalie. L'intervallo di variazione del termine di transizione è più piccolo di oltre tre ordini di grandezza rispetto a quello del punteggio complessivo, per cui il ranking dei trip è determinato quasi interamente dal termine di osservazione derivato dalla KDE.

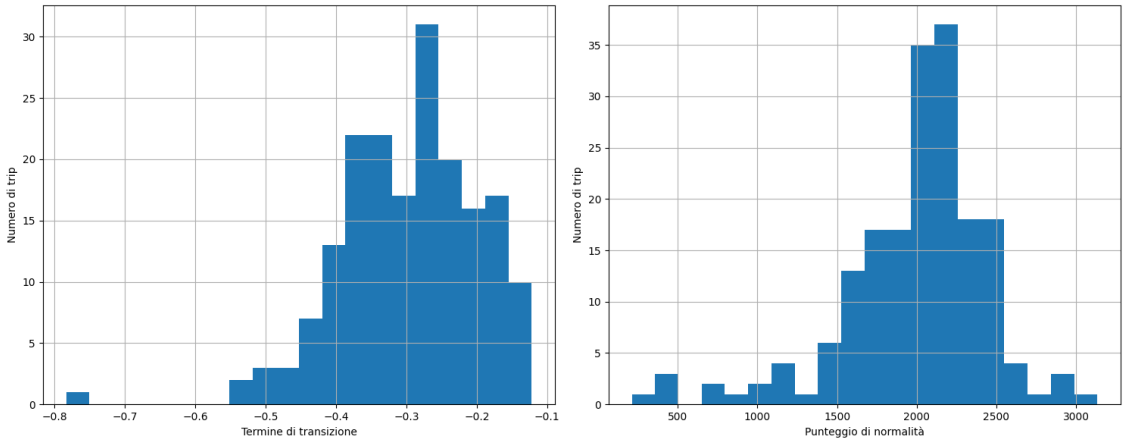


Figura 4.21: Distribuzione sui 184 trip della rotta selezionata del termine di transizione (a sinistra) e del punteggio di normalità (a destra).

La Figura 4.22 mette a confronto sulla mappa i cinque trip con punteggio più alto e i cinque con punteggio più basso, colorati in base al punteggio. I primi, in rosso, seguono traiettorie quasi sovrapposte lungo il corridoio principale della rotta (Figura 4.14), dall'uscita del porto di Honolulu fino all'ingresso del porto di Kalaeloa. I secondi, in blu, se ne discostano in modo evidente. Un trip compie un ampio giro al largo a nord-ovest di Kalaeloa prima di entrare in porto, uno si allontana dalla costa verso sud per più di 10 km prima di tornare indietro, mentre gli altri seguono percorsi più vicini alla costa o con cambi di direzione lungo il tragitto. I trip classificati come più anomali corrispondono quindi a traiettorie visibilmente diverse da quella tipica della rotta.

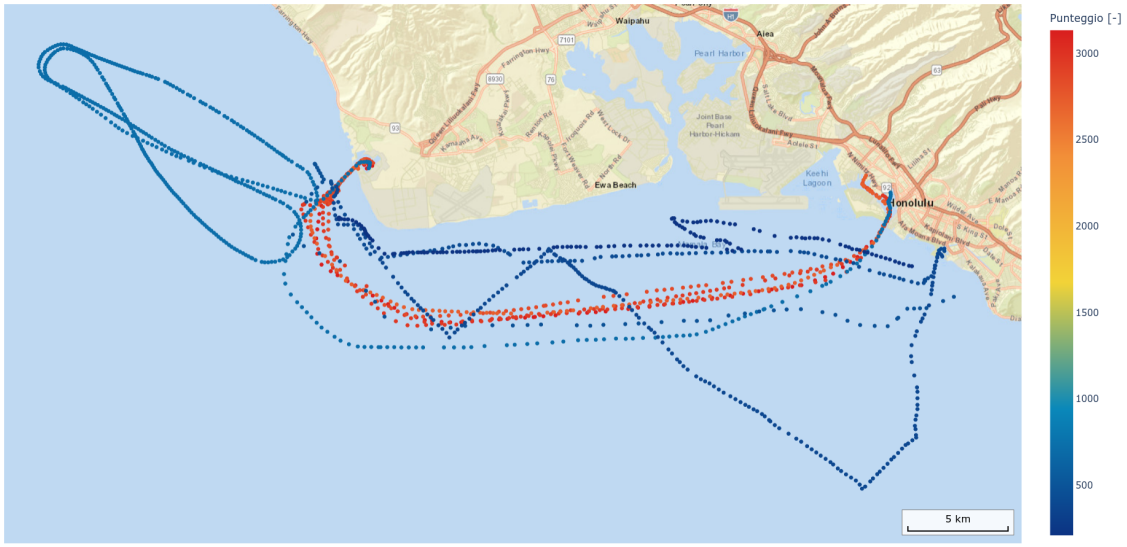


Figura 4.22: I cinque trip con punteggio più alto (in rosso) e i cinque con punteggio più basso (in blu) sulla rotta `WP_135 - WP_118`, colorati in base al punteggio.

4.3.4 Metriche di valutazione

Il metodo non richiede etichette, perché i punteggi e il ranking dei trip sono ottenuti in modo completamente automatico. Per valutarne quantitativamente le prestazioni, i 184 trip della rotta selezionata sono stati etichettati a mano, esclusivamente come riferimento per il calcolo delle metriche. L'etichettatura è stata svolta da un solo annotatore, a vista, osservando ciascun trip sulla mappa insieme agli altri trip della rotta; i trip classificati come normali dal metodo ma etichettati come anomali sono stati poi riesaminati uno a uno, per correggere eventuali errori di etichettatura.

Ogni trip è stato assegnato a una di tre classi. Un trip è una *route deviation* se almeno un tratto del percorso tra la partenza e l'arrivo esce chiaramente dal corridoio seguito dalla maggior parte dei trip della rotta. Nella classe delle altre

anomalie ricadono i trip che terminano il viaggio fuori dal porto di arrivo (15 trip), quelli che compiono manovre insolite nella zona di avvicinamento al porto (4 trip) e un trip che compie un piccolo giro subito dopo la partenza. Tutti gli altri trip sono normali. Si ottengono così 143 trip normali, 21 route deviation e 20 altre anomalie.

Poiché il metodo è pensato per rilevare le route deviation, la valutazione considera due casi:

- caso (a), *tutte le anomalie*: tutti i 184 trip, con le route deviation e le altre anomalie riunite in un'unica classe di trip anomali (41 trip);
- caso (b), *solo route deviation*: i 164 trip normali o etichettati come route deviation (21 trip anomali), esclusi i 20 trip con altre anomalie.

Per trasformare il punteggio in una classificazione occorre una soglia, al di sotto della quale un trip è considerato anomalo. Per non usare le etichette nella scelta della soglia, questa è calcolata con la regola di Tukey sui punteggi di tutti i 184 trip:

$$s = Q_1 - 1{,}5 \cdot (Q_3 - Q_1), \tag{4.1}$$

dove $Q_1 = 1.760{,}74$ e $Q_3 = 2.244{,}25$ sono il primo e il terzo quartile dei punteggi. La soglia vale $s = 1.035{,}48$; sono classificati come anomali i nove trip con punteggio inferiore, cioè i primi nove della colonna dei punteggi più bassi della Tabella 4.1.

La Figura 4.23 riporta le matrici di confusione dei due casi e la Tabella 4.2 le metriche che ne derivano. I nove trip classificati come anomali sono tutti route deviation, quindi in entrambi i casi non ci sono falsi positivi e la precision è pari a 1. La recall è invece bassa. Il metodo rileva 9 delle 41 anomalie del caso (a) e 9 delle 21 route deviation del caso (b). Escludere le altre anomalie fa salire la recall da 0,220 a 0,429 e l'F1 da 0,360 a 0,600. I trip non rilevati sono quindi soprattutto anomalie di tipo diverso dalle route deviation. L'accuracy è elevata in entrambi i casi (0,826 e 0,927), ma è poco indicativa, perché i trip normali sono la grande maggioranza.

La soglia di Tukey è molto severa. Per valutare il punteggio indipendentemente dalla soglia, la Figura 4.24 riporta le curve ROC dei due casi, ottenute facendo variare la soglia su tutti i valori del punteggio. L'area sotto la curva (AUC) vale 0,751 nel caso (a) e 0,844 nel caso (b). Nel caso (b) la curva sale rapidamente. Con un tasso di falsi positivi di circa il 6% si rileva circa il 71% delle route deviation, per cui una soglia meno severa permetterebbe di recuperare buona parte dei trip non rilevati al prezzo di pochi falsi positivi. Nel caso (a), invece, la curva resta piatta per un ampio tratto e nella parte alta scende sotto la diagonale del classificatore casuale, perché alcune anomalie hanno punteggi più alti di quasi tutti i trip normali. Quattro

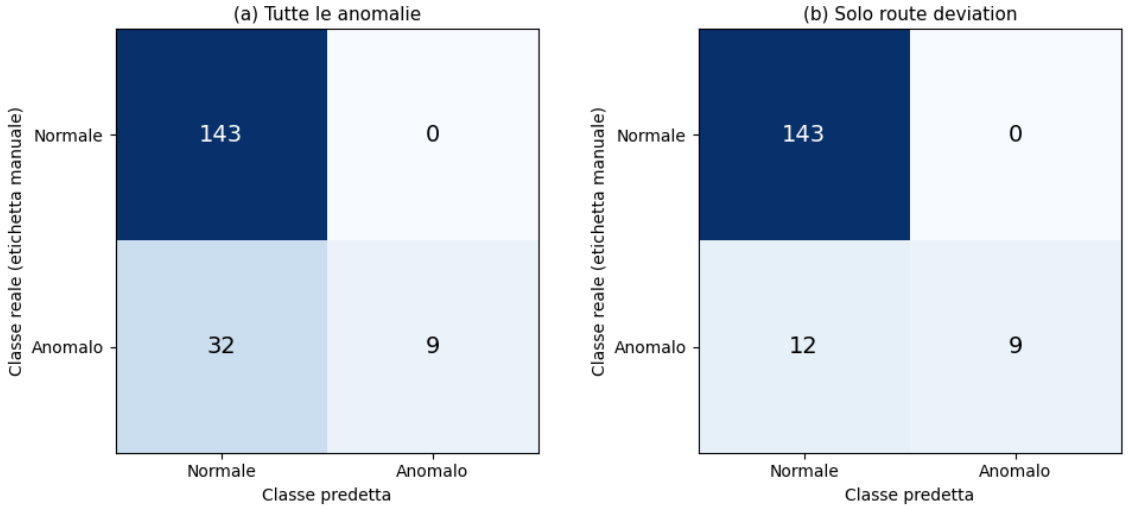


Figura 4.23: Matrici di confusione con la soglia di Tukey, considerando tutte le anomalie (a) e le sole route deviation (b).

Tabella 4.2: Metriche di valutazione con la soglia di Tukey ($s = 1.035{,}48$) nei due casi considerati.

Metrica	**(a) Tutte le anomalie**	**(b) Solo route deviation**
Trip valutati	184	164
Trip anomali	41	21
Accuracy	0,826	0,927
Precision	1,000	1,000
Recall	0,220	0,429
F1	0,360	0,600
AUC	0,751	0,844

di esse (i trip 23474, 8857, 8374 e 25609) compaiono tra i dieci trip con punteggio più alto della Tabella 4.1.

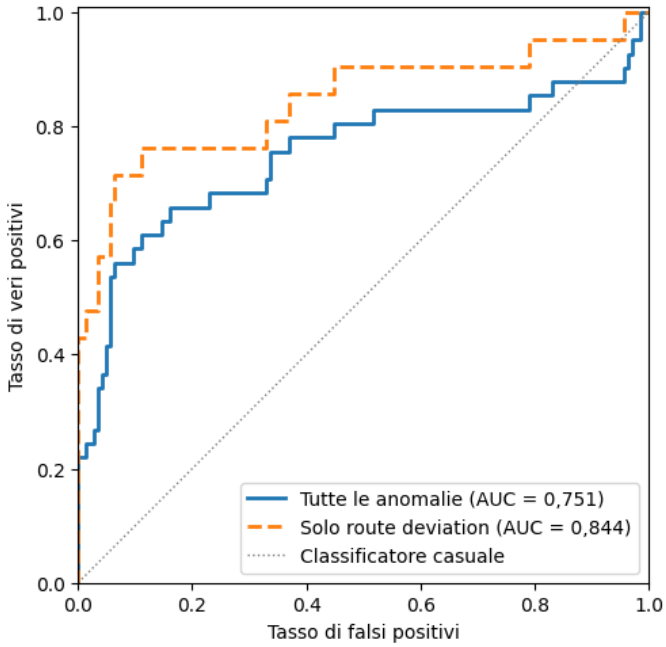


Figura 4.24: Curve ROC del punteggio di normalità considerando tutte le anomalie e le sole route deviation.

Questo comportamento dipende dall'addensamento dei punti nelle zone portuali, dove il termine di osservazione assume i valori più alti, come discusso nella Sezione 4.4.

4.4 Interpretazione dei risultati

Waypoint e rotte. La fase di Knowledge Discovery ha estratto una struttura del traffico coerente con la geografia dell'arcipelago, senza alcuna informazione a priori sui porti. I principali waypoint corrispondono a località note, come il porto di Honolulu (`WP_135`), che è anche il nodo con più collegamenti, il porto di Kalaeloa (`WP_118`) e altri porti importanti. I cluster sul bordo della bounding box non sono invece località precise, ma i punti in cui le navi entrano o escono dall'area di studio. Anche le rotte riflettono servizi reali. Le due rotte più frequentate, tra Lahaina e l'isola di Lanai, hanno un numero quasi identico di trip nei due versi e un medoide che segue la linea del traghetto riportata sulla mappa di base (Figura 4.5), mentre i self-loop descrivono l'attività delle imbarcazioni che partono da un porto e vi ritornano.

Peso dei termini del punteggio. Sulla rotta selezionata il punteggio è determinato quasi interamente dal termine di osservazione derivato dalla KDE, perché il termine di transizione varia in un intervallo più piccolo di oltre tre ordini di grandezza (Figura 4.21) e incide poco sul ranking. Il termine di osservazione è la media dei valori L_i dei punti del trip, cioè della somma delle log-densità nell'intorno di ogni punto (Sezione 3.5.3). Un trip ottiene quindi un punteggio basso quando molti dei suoi punti cadono in zone poco frequentate della rotta, e un punteggio alto quando molti dei suoi punti cadono nelle zone più dense.

Cosa rileva il metodo. I trip con punteggio più basso sono deviazioni dal corridoio evidenti sulla mappa (Figura 4.22), e i nove trip sotto la soglia di Tukey sono tutti route deviation. Il metodo è quindi adatto a rilevare le deviazioni dal corridoio lungo il tragitto, cioè proprio il tipo di anomalia per cui è stato pensato, e non produce falsi positivi con la soglia scelta. La soglia di Tukey, fissata senza usare le etichette, è però molto severa. La curva ROC delle sole route deviation (Figura 4.24) mostra che una soglia meno restrittiva recupererebbe gran parte delle deviazioni non rilevate al prezzo di pochi falsi positivi. La scelta della soglia dipende dall'applicazione e, come osservato da Pallotta et al. [2], va fissata in base ai tassi di rilevamento e di falso allarme richiesti.

Il limite delle zone portuali. Il metodo è invece poco sensibile alle anomalie che riguardano la zona dei porti. Davanti ai porti le navi rallentano e i punti si addensano, per cui L_i assume i valori più alti della rotta (Figura 4.18). Un trip che compie manovre lente nella zona di avvicinamento al porto accumula molti punti con L_i elevato e ottiene un punteggio alto anziché basso. Tra i dieci trip con punteggio più alto (Tabella 4.1) compaiono infatti quattro anomalie. Tre sono manovre nella zona di avvicinamento al porto (i trip 8857, 8374 e 25609), mentre la quarta (il trip 23474) termina il viaggio fuori dal porto. Per questo la curva ROC che considera tutte le anomalie scende sotto la diagonale. Per lo stesso motivo non vengono rilevate le route deviation che avvengono vicino al porto, come i trip 25652, 23889 e 10583. I trip che terminano il viaggio fuori dal porto, infine, seguono il corridoio per la maggior parte del percorso e, poiché il punteggio è una media su tutti i punti del trip, il tratto finale anomalo pesa poco sul risultato. Il punteggio misura quindi quanto un trip si trova nelle zone frequentate della rotta, più che quanto il suo comportamento sia insolito rispetto a quello atteso in ciascuna zona.

Confronto con il lavoro di riferimento. Un confronto quantitativo con il lavoro di Pallotta et al. [2] non è possibile. L'articolo applica la metodologia allo Stretto di

Gibilterra e al Mare Adriatico settentrionale, ma per l'anomaly detection riporta solo un esempio qualitativo, una nave che compie una doppia inversione di rotta davanti al porto di Livorno, senza metriche di rilevamento. Esistono inoltre alcune differenze di impostazione. Nel lavoro di riferimento l'anomaly detection è eseguita online, su una finestra temporale mobile che considera solo i punti più recenti della traccia, mentre in questo lavoro il punteggio è calcolato a posteriori sull'intero trip. Anche il termine di osservazione basato sull'intorno di 500 m, la predizione della posizione e la probabilità a priori della rotta sono calcolati in modo diverso, come descritto nel Capitolo 3. Il comportamento nelle zone portuali è in parte una conseguenza di queste scelte. Una finestra mobile, infatti, potrebbe rendere visibili anche le anomalie localizzate in un breve tratto del trip, che la media sull'intero trip tende ad attenuare. Inoltre la direzione del moto non entra nel termine di osservazione, che domina il punteggio, mentre nell'esempio di Livorno è proprio l'incompatibilità di direzione e velocità a far crollare la probabilità.

4.5 Sintesi

Applicata ai messaggi AIS delle Hawaii del primo trimestre del 2019, la pipeline ha ridotto 5.462.415 record a 5.415.129 record puliti e ha estratto, senza supervisione, 144 waypoint, tra cui i principali porti dell'arcipelago, e 766 rotte, per un totale di 36.033 trip. Le rotte più frequentate riflettono servizi di linea reali, come il collegamento tra Lahaina e l'isola di Lanai.

Sulla rotta `WP_135 - WP_118`, dal porto di Honolulu a Kalaeloa, il modello di anomaly detection ha assegnato un punteggio a 184 trip. Il ranking è determinato quasi interamente dal termine di osservazione derivato dalla KDE, e i trip con punteggio più basso sono deviazioni visibili dal corridoio della rotta. Rispetto a un'etichettatura manuale usata solo come riferimento, il metodo con la soglia di Tukey non produce falsi positivi e rileva 9 delle 21 route deviation; l'AUC è pari a 0,844 sulle sole route deviation e scende a 0,751 includendo le altre anomalie. Il limite principale riguarda le zone portuali, dove l'addensamento dei punti fa ottenere punteggi alti alle manovre lente e alle deviazioni vicine al porto.

Questi risultati, insieme ai possibili sviluppi del metodo, sono discussi nel Capitolo 5.

Capitolo 5

Conclusioni

Conclusioni, in cui indico in che modo il mio lavoro ha portato delle migliorie ed eventualmente quali aspetti possono/devono essere ancora esplorati/approfonditi

5.1 Sezione 1 - Sintesi dei contributi principali

Testo Sezione 1

5.2 Sezione 2 - Migliorie ottenute

Testo sezione 2

5.3 Sezione 3 - Limititazioni/difetti

Testo sezione 3

5.4 Sezione 4 - Sviluppi futuri

Testo Sezione 4

5.5 Sezione 5 - Conclusione finale

Bibliografia

[1] International Maritime Organization. Regulations for carriage of ais, 2000. Disponibile: https://www.imo.org/en/ourwork/safety/pages/ais.aspx. Accessed: 2026-04-12.

[2] Giuliana Pallotta, Michele Vespe, and Karna Bryan. Vessel pattern knowledge discovery from ais data: A framework for anomaly detection and route prediction. *Entropy*, 15(6):2218–2245, Jun 2013. doi: 10.3390/e15062218.

[3] NOAA Office for Coastal Management. Nationwide automatic identification system 2019. Scheda dei metadati InPort, https://www.fisheries.noaa.gov/inport/item/62733, 2020. Ultimo accesso: 08/11/2026.

[4] Konrad Wolsing, Linus Roepert, Jan Bauer, and Klaus Wehrle. Anomaly detection in maritime ais tracks: A review of recent approaches. *Journal of Marine Science and Engineering*, 10, 01 2022. doi: 10.3390/jmse10010112.

[5] Richard Lane, David Nevell, Steve Hayward, and T.W. Beaney. Maritime anomaly detection and threat assessment. pages 1 – 8, 08 2010. doi: 10.1109/ICIF.2010.5711998.

[6] Steven Mascaro, Ann E. Nicholso, and Kevin B. Korb. Anomaly detection in vessel tracks using bayesian networks. *International Journal of Approximate Reasoning*, 55:84–98, 2014. doi: 10.1016/j.ijar.2013.03.012. URL https://doi.org/10.1016/j.ijar.2013.03.012.

[7] Kira Kowalska and L. Peel. Maritime anomaly detection using gaussian process active learning. pages 1164–1171, 01 2012. ISBN 978-1-4673-0417-7.

[8] International Telecommunication Union. Recommendation ITU-R M.1371-6: Technical characteristics for VHF automatic identification system using time division multiple access in the maritime mobile service. ITU-R Recommendation M.1371-6, ITU Radiocommunication Sector, 2 2026. URL https://www.itu.int/rec/R-REC-M.1371/en.