

Università degli Studi di Bergamo

Dipartimento di Ingegneria Gestionale, dell'Informazione e della
Produzione

Corso di Laurea Magistrale in Ingegneria Informatica
Classe n. LM-32 – Ingegneria Informatica



TITOLO

Relatore:

Chiar.mo Prof./Chiar.ma Prof.ssa Nome Cognome

Correlatori:

Chiar.mo Prof./Chiar.ma Prof.ssa Nome Cognome

Dottorando Mario Rossi

Tesi di Laurea Magistrale

Nome COGNOME

Matricola n. 12345678

Anno Accademico 2024 / 2025

Sommario

Riassunto di quanto svolto, da fare alla fine

Indice

1	Introduction	1
1.1	Sezione 1	1
1.2	Thesis Structure	2
2	Literature Review	3
2.1	Contesto della tesi	3
2.1.1	Storia e funzionamento dell'AIS	3
2.1.2	Dati trasmessi	3
2.1.3	Limiti e problemi noti	4
2.2	Panoramica degli approcci di anomaly detection	4
2.2.1	Approcci di Machine Learning	5
2.2.2	Approcci Stocastici	6
2.2.3	Approcci Geometrici	7
2.3	Il framework TREAD di Pallotta et al.	7
3	Methodology	8
3.1	Introduzione	8
3.2	Obiettivi	8
3.3	Dataset	9
3.3.1	Struttura del dataset	9
3.3.2	Qualità dei dati	9
3.4	Pre-processing dei dati	11
3.4.1	Importazione, filtraggio geografico e rimozione dei duplicati	11
3.4.2	Calcolo della velocità media e classificazione degli stati	12
3.5	Implementazione del framework TREAD e differenze rispetto all'originale	13
3.5.1	Architettura generale	13
3.5.2	Identificazione dei waypoint: DBSCAN e H-DBSCAN	14
3.5.3	Costruzione dei waypoint e identificazione delle rotte	15

3.6	Anomaly detection	16
3.6.1	Decomposizione della velocità e preparazione delle feature . .	16
3.6.2	Stima della densità tramite Kernel Density Estimation	17
3.6.3	Classificazione dei trip e train/test split	17
3.6.4	Calcolo della probabilità di transizione e anomaly scoring . . .	18
3.7	Tecnologie utilizzate	18
3.8	Limiti della metodologia	19
3.9	Sintesi e anticipazione dei risultati	20
4	Results	21
4.1	Sezione 1 - Dataset utilizzati	21
4.2	Sezione 2 - Risultati qualitativi	21
4.3	Sezione 3 - Risultati quantitativi	21
4.4	Sezione 4 - Interpretazione risultati ottenuti	21
4.5	Sezione 5 - Conclusione	21
5	Conclusions	22
5.1	Sezione 1 - Sintesi dei contributi principali	22
5.2	Sezione 2 - Migliorie ottenute	22
5.3	Sezione 3 - Limititazioni/difetti	22
5.4	Sezione 4 - Sviluppi futuri	22
5.5	Sezione 5 - Conclusione finale	22

Elenco delle figure

Elenco delle tabelle

3.1	Struttura del dataset AIS del NOAA.	10
-----	---	----

Capitolo 1

Introduction

1.1 Sezione 1

L'Automatic Identification System (AIS) è un sistema di trasmissione e ricezione dati sviluppato da Benny Pettersson agli inizi degli anni '90 che viene utilizzato in maniera diffusa sia da imbarcazioni commerciali che da diporto. Tale dispositivo nasce originariamente con lo scopo di migliorare la sicurezza della navigazione attraverso la riduzione del rischio di collisioni; successivamente, con l'evolversi della tecnologia, assume anche un ruolo legato al tracciamento delle imbarcazioni. Al di là di queste finalità operative, l'AIS rappresenta oggi una fonte ricca di informazioni per lo studio dei comportamenti dei natanti: fornisce dati geolocalizzati (con frequenza temporale variabile ma comunque nell'ordine delle decine di secondi) che descrivono in dettaglio i percorsi seguiti dalle navi, la loro velocità, orientamento, stato di navigazione e altre caratteristiche sia statiche che dinamiche.

Grazie alla larga adozione del sistema AIS, e grazie anche all'elevata frequenza con cui i dati vengono trasmessi, è naturale che negli ultimi anni, anche in aree circoscritte ma sufficientemente trafficate, vengano generate grandi moli di dati AIS. Tuttavia, la vastità, rumorosità e complessità intrinseca di questi dataset rendono necessario l'impiego di diverse tecniche per estrarre informazioni utili. Tutto ciò ha quindi favorito lo sviluppo di diversi studi dedicati all'estrazione automatica di informazioni.

L'obiettivo della presente tesi si inserisce in questo contesto: partendo da un metodo di anomaly detection proposto in letteratura, esso viene analizzato, migliorato e applicato a un dataset AIS di grandi dimensioni. Prima di descrivere il lavoro svolto, è necessario delineare il quadro delle principali categorie di approcci esistenti, con particolare riferimento ai contributi discussi da Wolsing et al. nel loro lavoro di rassegna e al framework introdotto da Pallotta et al., da cui prende avvio il metodo

adottato in questa tesi.

1.2 Thesis Structure

Struttura della tesi.

- Chapter 2
- Chapter 3
- Chapter 4
- Chapter 5

Capitolo 2

Literature Review

2.1 Contesto della tesi

L'obiettivo di questa literature review è quello di esplorare lo stato dell'arte delle tecniche di analisi dei dati AIS per il rilevamento di anomalie nel traffico marittimo, cercando di fornire una panoramica generale.

2.1.1 Storia e funzionamento dell'AIS

L'Automatic Identification System (AIS) è un sistema di comunicazione utilizzato nella navigazione marittima. La sua origine viene generalmente attribuita a Benny Pettersson, che sviluppò un primo prototipo nei primi anni '90. Inizialmente concepito per ridurre il rischio di collisioni in mare, il sistema è stato poi progressivamente adottato a livello internazionale, fino a ottenere un riconoscimento formale da parte dell'International Maritime Organization (IMO). Nell'ambito dell'accordo SOLAS, l'installazione dell'AIS è diventata obbligatoria per le navi con stazza lorda superiore a 300 tonnellate impegnate in viaggi internazionali e per tutte le navi passeggeri [1].

Dal punto di vista tecnico, l'AIS opera su due canali radio VHF intorno ai 162 MHz e utilizza il protocollo TDMA (Time-Division Multiple Access), che permette a più imbarcazioni di trasmettere senza interferire tra loro [8]. La copertura, in condizioni standard, arriva fino a circa 50 km (linea di vista), mentre l'uso di ricevitori satellitari (S-AIS) consente di estenderla anche alle acque oceaniche [8]. La frequenza di trasmissione dei messaggi non è costante, ma varia in funzione della velocità e dello stato della nave, passando da pochi secondi a diversi minuti [8].

2.1.2 Dati trasmessi

I messaggi AIS possono essere suddivisi in tre categorie principali [8]:

- **Dati statici:** includono informazioni identificative della nave, come MMSI, nome, tipo e dimensioni.
- **Dati dinamici:** descrivono lo stato corrente della navigazione, tra cui posizione GPS, velocità (SOG), rotta (COG), orientamento della prua (HE), variazione della rotta (ROT) e stato operativo.
- **Dati di viaggio:** comprendono informazioni aggiuntive come pescaggio, tipo di carico, destinazione ed ETA. Essendo inseriti manualmente, risultano generalmente meno affidabili [6].

Ai fini dell'analisi del comportamento delle navi, i dati dinamici sono in genere i più rilevanti, in quanto descrivono in modo continuo l'evoluzione delle traiettorie.

2.1.3 Limiti e problemi noti

Nonostante la ricchezza informativa, i dati AIS presentano diverse criticità che ne complicano l'analisi. Dal punto di vista della qualità, possono verificarsi lacune nella copertura dovute a limiti dei ricevitori terrestri o a interferenze, soprattutto in aree molto trafficate [6].

Inoltre, il protocollo AIS non prevede meccanismi di autenticazione o cifratura, rendendo possibile la manipolazione dei dati, ad esempio tramite spoofing o spegnimento del transponder [8]. Un ulteriore problema è rappresentato dalla diversa frequenza di trasmissione tra le varie classi di imbarcazioni, che introduce una certa eterogeneità nei dataset.

Nel complesso, la dimensione, la rumorosità e la complessità di questi dati rendono necessario l'utilizzo di tecniche automatiche di analisi dei dati.

2.2 Panoramica degli approcci di anomaly detection

La letteratura sull'anomaly detection nei dati AIS è stata raccolta e sistematizzata da [8], che analizza 44 contributi pubblicati tra il 2007 e il 2021. Prima di esplorare i possibili approcci risolutivi, è utile adottare un'opportuna classificazione delle potenziali anomalie da rilevare tramite l'analisi dei dati AIS. Nell'ambito di questo lavoro di tesi tale classificazione viene presa da [4].

Di seguito le 5 tipologie di anomalie:

1. **Deviazione dalla rotta** (*route deviation*): la nave percorre un tragitto insolito rispetto alla rotta tipicamente più breve tra due porti, compatibilmente

con i vincoli fisici e normativi. È la tipologia di anomalia più studiata in letteratura [8] e rappresenta il focus principale di questo lavoro.

2. **Attività AIS inaspettata** (*unexpected AIS activity*): comprende l'accensione o lo spegnimento improvviso del transponder AIS (che può indicare il tentativo di nascondere la posizione della nave) nonché la modifica dei dati identificativi trasmessi, come il nome o codice identificativo MMSI.
3. **Arrivo in porto inaspettato** (*unexpected port arrival*): una nave approda in un porto non previsto o incoerente rispetto alla destinazione dichiarata o alla rotta storica. Questo comportamento può essere indicativo di attività illecite quali il contrabbando o l'evasione dei controlli doganali.
4. **Avvicinamento ravvicinato** (*close approach*): due navi si portano a distanza molto ridotta l'una dall'altra al di fuori di contesti giustificati (ad esempio le aree portuali), il che potrebbe indicare un passaggio non dichiarato di merci o persone.
5. **Ingresso in zona** (*zone entry*): una nave entra in un'area geografica soggetta a restrizioni, sorveglianza speciale o nota per attività illegali (ad esempio zone di pesca protette o aree riservate a determinate imbarcazioni).

Per ciascuna di queste categorie, Lane et al. [4] propongono un algoritmo probabilistico, i cui output vengono poi aggregati tramite una rete bayesiana per ottenere una stima complessiva della probabilità che una anomalia sia effettivamente in corso.

Nel resoconto prodotto dall'analisi sistematica condotta da [8] sui vari approcci risolutivi, si evince come la maggior parte dei contributi adotta una struttura in due fasi: prima viene costruito un modello del traffico normale a partire dai dati storici, poi si identificano le traiettorie che si discostano da quel modello come potenziali anomalie.

Infine, i lavori esaminati vengono classificati in tre macro categorie principali, a cui si aggiungono approcci ibridi che combinano più metodologie.

2.2.1 Approcci di Machine Learning

Gli approcci basati su machine learning comprendono principalmente metodi di clustering e reti neurali. Tra i primi, DBSCAN è particolarmente diffuso, in quanto si adatta bene alla natura spaziale dei dati e consente di identificare cluster senza specificarne a priori il numero. Un esempio rappresentativo è il framework TREAD di Pallotta et al. [6], che applica l'algoritmo DBSCAN in maniera incrementale per

individuare i "waypoint" caratteristici del traffico (principalmente porti, piattaforme offshore, punti di ingresso e uscita dall'area monitorata). Le nuove rotte vengono confrontate con il modello appreso e, se la sua probabilità rispetto alle rotte note risulta bassa, viene scartata.

Le reti neurali, invece, permettono di modellare relazioni più complesse e non lineari, e nelle versioni più recenti hanno mostrato buone prestazioni.

Questi approcci risultano scalabili e relativamente semplici da implementare, ma presentano anche alcuni limiti, tra cui la scarsa interpretabilità (soprattutto per le reti neurali) e la difficoltà di generalizzazione a contesti geografici diversi [5].

2.2.2 Approcci Stocastici

Gli approcci stocastici modellano il comportamento delle navi come un processo probabilistico. Tra le tecniche più comuni si trovano GMM, KDE, Gaussian Process e reti bayesiane.

In generale, questi metodi stimano la distribuzione delle traiettorie normali a partire dai dati storici e classificano come anomale quelle con bassa probabilità. Offrono una buona base teorica e permettono di quantificare l'incertezza, ma possono risultare onerosi dal punto di vista computazionale su dataset molto grandi.

Alcuni lavori, come [3], mostrano l'efficacia dei Gaussian Process. In particolare nel loro lavoro Kowalska et al. propongono un modello non parametrico basato su un Gaussian Process per apprendere il comportamento normale delle navi a partire dai dati AIS. Il loro modello assegna a ciascuna trasmissione ricevuta una misura di normalità in funzione della velocità osservata rispetto alla posizione geografica: le navi con comportamento inusuale ottengono uno score elevato e vengono priorizzate per un'analisi più approfondita. Per rendere il metodo applicabile a dataset di grandi dimensioni, gli autori introducono una strategia di "active learning" che seleziona automaticamente un sottoinsieme informativo dei dati per l'addestramento, riducendo il costo computazionale senza compromettere le prestazioni.

Mascaro et al. [5] mostrano invece come le reti bayesiane possano essere interessanti per la loro maggiore interpretabilità, pur presentando difficoltà di scalabilità. In particolare, nel loro lavoro, apprendono reti bayesiane direttamente dai dati AIS, producendo modelli dinamici (che catturano l'evoluzione della traiettoria passo dopo passo) e modelli statici basati su un riassunto dell'intera rotta. I due approcci mostrano punti di forza complementari: il modello dinamico risulta più efficace nel rilevare anomalie localizzate nel tempo, mentre quello statico cattura meglio pattern anomali che si manifestano sull'intera traiettoria. La loro combinazione migliora le prestazioni complessive di rilevamento rispetto all'uso di uno solo dei due.

2.2.3 Approcci Geometrici

Gli approcci geometrici si basano sulle proprietà spaziali delle traiettorie, ad esempio tramite il calcolo del convex hull (inviluppo convesso) delle rotte osservate [8]. Si tratta in genere di metodi semplici e interpretabili, ma meno flessibili e meno robusti in presenza di rumore rispetto ad altri approcci.

2.3 Il framework TREAD di Pallotta et al.

Tra gli approcci presenti in letteratura, il metodo adottato in questo lavoro è il framework TREAD (Traffic Route Extraction and Anomaly Detection) proposto da [6], che combina tecniche di clustering e analisi statistica.

Il framework è non supervisionato e incrementale: apprende i pattern di traffico direttamente dai dati AIS senza richiedere informazioni preliminari. Il processo si articola in due fasi principali. Nella prima fase, vengono identificati i waypoint caratteristici (come porti o punti di passaggio) tramite un algoritmo di clustering basato su DBSCAN. Tali waypoint vengono usati per costruire le rotte, definite come il percorso di una nave da un waypoint di partenza a uno di arrivo. Talvolta waypoint di partenza e di arrivo coincidono.

Nella seconda fase, le rotte apprese vengono utilizzate per analizzare nuove traiettorie e individuare eventuali anomalie, sulla base della loro probabilità rispetto al modello.

Tra i principali vantaggi di questo approccio vi sono la possibilità di aggiornare il modello in modo incrementale, la capacità di gestire dati AIS anche non continui e una rappresentazione relativamente compatta del traffico, adatta anche a dataset di grandi dimensioni.

Capitolo 3

Methodology

Questo capitolo descrive il lavoro svolto nell’ambito di questa tesi: viene illustrato come il framework TREAD proposto da Pallotta et al. [6] è stato analizzato, re-implementato e (in alcune componenti) esteso e migliorato, per poi testarlo su un dataset AIS con dati reali relativi all’arcipelago delle Hawaii.

3.1 Introduzione

Non so bene cosa scrivere qui

3.2 Obiettivi

I quesiti di ricerca su cui è stata sviluppata la metodologia sono i seguenti:

1. Il framework TREAD (che è stato sviluppato agli inizi degli anni 2010), è ancora applicabile ad un dataset moderno e più voluminoso?
2. Quali aspetti e caratteristiche dell’algoritmo sono “riciclabili” e quali hanno richiesto adattamenti o sostituzioni?
3. È possibile ottenere risultati qualitativamente migliori?
4. Quali metriche è opportuno utilizzare per quantificare le prestazioni dell’algoritmo?

3.3 Dataset

I dati utilizzati provengono dal portale pubblico del NOAA¹ (National Oceanic and Atmospheric Administration), un'agenzia scientifica e normativa statunitense con diversi compiti tra cui il monitoraggio oceanico [7]. I file scaricati dalla piattaforma hanno nome nel formato `AIS_YYYY_MM_DD` (dove `YYYY` rappresenta l'anno, `MM` il mese e `DD` il giorno di registrazione dei dati) e contengono tutti i messaggi ricevuti dall'ente in una singola giornata di tutto il territorio nazionale monitorato. Per questa tesi sono stati utilizzati i dati relativi al primo trimestre 2019 (gennaio-marzo, estremi inclusi), filtrati sull'area delle Hawaii tramite una bounding box le cui estremità hanno le seguenti coordinate:

- Latitudine: da 18.77°N a 22.63°N,
- Longitudine: da 160.11°W a 154.39°W.

3.3.1 Struttura del dataset

Ogni record del dataset corrisponde a un singolo messaggio AIS trasmesso da una nave e contiene diversi campi, riportati nella tabella 3.1. I campi si dividono in due categorie: attributi statici, che descrivono le caratteristiche fisse della nave e normalmente non variano tra un messaggio e l'altro, e attributi dinamici, che riflettono lo stato corrente della nave al momento della trasmissione.

Ogni record del dataset, contenendo una coppia di coordinate geografiche (`LAT`, `LOD`), è rappresentabile come un punto su una mappa. A ciascun punto è inoltre associato un vettore: il modulo corrisponde alla velocità istantanea della nave (`SOG`), mentre la direzione è determinata dall'angolo `COG`, espresso in gradi rispetto al nord geografico. Questa rappresentazione vettoriale è alla base delle elaborazioni descritte nelle sezioni successive, ed è il motivo per cui nel resto del capitolo i termini *record* e *punto* vengono usati in modo intercambiabile.

3.3.2 Qualità dei dati

Oltre alla struttura, è opportuno considerare la qualità intrinseca dei dati. Un vantaggio rilevante del dataset NOAA rispetto ad altre fonti pubbliche (in particolare i dati danesi considerati e poi scartati in fase esplorativa) è che i dati sono già stati

¹Il NOAA mette a disposizione due modalità di accesso ai dati: tramite il portale <https://marinecadastre.gov/accessais/>, che consente di filtrare per zona geografica e intervallo temporale, oppure tramite <https://hub.marin cadastre.gov/pages/vesseltraffic>, che offre il download in bulk di tutti i dati AIS registrati suddivisi per anno.

Tabella 3.1: Struttura del dataset AIS del NOAA.

Colonna	Tipo	Descrizione
<i>Attributi statici</i>		
MMSI	intero	Maritime Mobile Service Identity: identificativo univoco della nave
VesselName	stringa	Nome della nave
IMO	stringa	Numero IMO (International Maritime Organization)
CallSign	stringa	Nominativo radio della nave
VesselType	intero	Codice numerico che indica la tipologia di nave (cargo, tanker, passeggeri, ecc.)
Length	intero	Lunghezza della nave in metri
Width	intero	Larghezza della nave in metri
Draft	decimale	Pescaggio della nave in decimi di metro
Cargo	intero	Codice del tipo di carico trasportato
TransceiverClass	booleano	Classe del transponder AIS: A o B (imbarcazioni minori)
<i>Attributi dinamici</i>		
BaseDateTime	datetime	Timestamp del messaggio (UTC)
LAT	decimale	Latitudine della posizione (gradi decimali)
LON	decimale	Longitudine della posizione (gradi decimali)
SOG	decimale	Speed Over Ground: velocità rispetto al fondale in nodi
COG	decimale	Course Over Ground: direzione di movimento in gradi (0–360°)
Heading	decimale	Prua della nave in gradi (0–360°), distinta dal COG
Status	intero	Stato di navigazione AIS (es. in navigazione, all'ancora, in manovra)

filtrati dagli errori più grossolani, rendendo l'uso di tecniche di pulizia aggiuntive meno critico. È stata tuttavia mantenuta l'assunzione esplicita che le colonne **MMSI** e **BaseDateTime** siano affidabili e prive di errori, in quanto queste quattro colonne costituiscono la base di tutte le elaborazioni successive.

3.4 Pre-processing dei dati

L'intera fase di pre-processing, nonché le successive analisi, sono implementate in Python, utilizzando dei notebook Jupyter. Le tecnologie utilizzate verranno descritte meglio nella Sezione 3.7.

3.4.1 Importazione, filtraggio geografico e rimozione dei duplicati

I file scaricati dalla piattaforma del NOAA sono in formato “.zip”. Pertanto vengono automaticamente decompressi, importati in memoria e successivamente eliminati dal disco per liberare spazio. Durante l'importazione, ogni file csv letto viene salvato in memoria sottoforma di **DataFrame**. In questa fase, vengono immediatamente scartati tutti quei messaggi le cui coordinate di latitudine e longitudine ricadono al di fuori del perimetro citato nella sezione 3.3. Tutti i **DataFrame** così creati vengono concatenati in un unico **DataFrame** finale, che viene esportato in un unico file CSV di backup. Le operazioni di importazione e filtraggio avvengono grazie alla libreria **Polars**, che è stata scelta per il fatto che (a differenza di Pandas) supporta il multithreading nativamente.

In una fase successiva, i record esattamente duplicati (identici in ogni attributo) vengono rimossi, lasciandone solo uno per ogni gruppo duplicato.

Viene poi rimosso un ulteriore sottoinsieme di record: quelli generati da navi, la cui somma di record presenti nel database è inferiore al 10% della media calcolata sul totale delle navi presenti. Per identificare l'appartenenza di un record ad una nave o meno, è stato utilizzato il valore di **MMSI**. Come citato in precedenza alla sezione 3.3.2, tale attributo si assume corretto e validato dal NOAA in fase di raccolta dei dati.

La soglia usata per rimuovere le navi meno attive è calcolata dinamicamente (e non come valore fisso) in modo da rendere il codice indipendente dalle dimensioni del dataset che si decide di utilizzare. L'idea dietro questa decisione è che le navi al di sotto di questa soglia contribuiscono in maniera trascurabile al traffico dell'area e la loro presenza potrebbe distorcere la fase di clustering. Prima dell'applicazione di questa soglia il dataset conteneva 602 imbarcazioni distinte (5.460.800 record).

In seguito il numero di navi distinte è passato a 403 (5.415.168 righe), eliminando circa lo 0,84% dei record totali.

3.4.2 Calcolo della velocità media e classificazione degli stati

Una volta completata la fase di importazione e pulizia, l'analisi viene condotta su una nave alla volta utilizzando il valore di **MMSI** come chiave primaria. Per ciascuna nave viene costruito un **DataFrame** separato, ordinato cronologicamente per **BaseDateTime** e contenente tutti messaggi che quell'imbarcazione ha generato nel periodo di analisi all'interno dell'area geografica analizzata. Per ogni coppia di punti consecutivi appartenenti alla stessa nave viene calcolata la velocità media **Avg_Speed**, come rapporto tra la distanza percorsa e l'intervallo di tempo trascorso. La distanza viene calcolata sfruttando la formula della *Great-Circle Distance*, che tiene conto della curvatura terrestre usando come raggio della Terra il raggio equatoriale definito dallo standard WGS-84 e pari a 6 378 137 m. L'intervallo di tempo tra i due punti viene individuato facendo la differenza tra i due timestamp e sfruttando l'ordinamento cronologico applicato in precedenza. La velocità risultante viene convertita in nodi nautici.

Il calcolo viene gestito in modo vettorizzato: ogni traiettoria viene rappresentata come due sequenze di punti sfalsate di un passo, ottenendo le coppie (punto precedente, punto corrente). Nei casi in cui l'intervallo di tempo tra due punti consecutivi supera la soglia **LOST_TIME_THRESHOLD_SECONDS** (impostata a 620 s e corrispondente a circa 10 volte il periodo tipico di trasmissione di un dispositivo AIS di Classe A), la velocità media del secondo punto appena calcolata viene scartata e sostituita con il valore di **SOG**, a condizione che quest'ultimo sia plausibile (inferiore alla soglia **ABSURD_SPEED_THRESHOLD** di 102 nodi). In caso contrario, la velocità viene ricalcolata ancora come rapporto distanza/tempo. Al primo punto di ogni traiettoria, per il quale non esiste un punto precedente, viene assegnato direttamente il valore di **SOG**. I punti con **Avg_Speed** superiore a 102 nodi (e che non fanno scattare la soglia **LOST_TIME_THRESHOLD_SECONDS**) vengono eliminati, in quanto ritenuti il risultato di errori di posizionamento GPS.

A partire da **Avg_Speed**, viene costruita la colonna **EstimatedStatus**, che classifica ogni punto in una delle sei categorie seguenti. Le prime quattro riguardano la gestione dei gap temporali e vengono assegnate durante il calcolo della velocità:

- **lost**: record immediatamente precedente un gap temporale superiore a **LOST_TIME_THRESHOLD_SECONDS**. Indica l'ultimo momento in cui la nave era tracciata prima di scomparire temporaneamente dal sistema.

- **return**: primo record successivo al gap citato al punto precedente. Indica il momento in cui la nave torna visibile dopo una breve interruzione. I punti *lost* e *return* non entrano nella fase di clustering, ma sono utili per la corretta interpretazione delle traiettorie.
- **exit**: record precedente un gap superiore a `EXIT_TIME_THRESHOLD_HOURS` (12 ore). Indica che la nave ha lasciato l'universo di analisi o ha smesso di trasmettere per un periodo prolungato.
- **entry**: primo record successivo al gap citato al punto precedente. Indica il rientro della nave nell'universo di analisi dopo un'assenza significativa.

Gli status *exit* e *entry* vengono assegnati dopo *lost* e *return*, sovrascrivendoli quando il gap supera la soglia più lunga. Le restanti due categorie vengono assegnate in una seconda fase, sui punti che non hanno ancora ricevuto uno status:

- **stationary**: punti con $\text{Avg_Speed} \leq \text{SPEED_THRESHOLD}$ (0.5 nodi).
- **sailing**: tutti i punti rimanenti, in navigazione ordinaria.

Al termine, il primo punto di ciascuna traiettoria viene forzato a *entry* e l'ultimo a *exit*, indipendentemente dallo status calcolato. Quando più punti consecutivi risultano tutti *entry* o tutti *exit* (situazione possibile in presenza di gap ravvicinati) viene conservato solo l'ultimo punto *entry* della sequenza e il primo punto *exit*, eliminando i rimanenti.

3.5 Implementazione del framework TREAD e differenze rispetto all'originale

3.5.1 Architettura generale

Il framework TREAD di Pallotta et al. [6] si articola in due macro fasi: *Knowledge Discovery* e *Knowledge Exploitation*. Nella prima fase, il flusso di messaggi AIS viene elaborato per costruire un modello statistico del traffico normale, articolato in tre classi di oggetti: vessel objects (*Vs*), waypoint objects (*WPS*) e route objects (*Rs*). Nella seconda fase, le rotte apprese vengono utilizzate per classificare nuove traiettorie e individuare comportamenti anomali.

La presente implementazione riproduce questa struttura a due fasi. Tuttavia, il processo non è incrementale in senso stretto: anzichè aggiornare il modello messaggio per messaggio come nell'algoritmo originale, l'intero dataset viene caricato in

memoria e processato in batch. Questa scelta è stata motivata dai vincoli hardware descritti nella sezione 3.8.

3.5.2 Identificazione dei waypoint: DBSCAN e H-DBSCAN

Il passo centrale della fase di Knowledge Discovery è l'identificazione dei waypoint. In questo contesto, un waypoint è un'area geografica appartenente all'universo di analisi in cui le navi:

- entrano nell'universo di analisi;
- escono dall'universo di analisi;
- rallentano significativamente, con velocità media inferiore alla soglia `SPEED_THRESHOLD` (0.5 nodi), al di sotto della quale la nave è ritenuta sostanzialmente stazionaria.

A differenza di quanto avviene su terra, in mare è molto difficile per una nave rimanere completamente ferma per via di correnti, vento e onde che spesso causano qualche tipo di movimento. Per questo motivo, anziché cercare punti di velocità nulla, si è deciso di introdurre una soglia (`SPEED_THRESHOLD`) sotto la quale un'imbarcazione è considerata stazionaria. I waypoint non hanno dimensione fissa: ciascuno occupa una porzione dello spazio geografico determinata da come si distribuiscono e da quanti sono i punti che lo compongono. Nella pratica, la maggior parte di essi tende ad occupare un'area molto ridotta rispetto all'universo di analisi. Nell'algoritmo originale l'identificazione dei waypoint viene effettuata tramite un approccio basato su DBSCAN. La presente implementazione applica prima DBSCAN e poi H-DBSCAN come variante migliorativa (*Hierarchical DBSCAN*).

Preparazione degli input per il clustering

L'input fornito agli algoritmi di clustering è costituito da tutti i punti classificati come *stationary*, *entry* o *exit*, che rappresentano circa il 65,3% del dataset totale.

Per ridurre la dimensione dell'input e superare le limitazioni di memoria dell'implementazione scikit-learn di DBSCAN, il cui costo di memoria è $O(n^2)$, i punti vengono aggregati tramite un'operazione di *group-by* sulle sole coordinate GPS, contando quante volte ogni coppia (LAT, LON) compare nel dataset. Questa operazione è il motivo per cui si è deciso di arrotondare da 5 a 4 cifre decimali i valori di latitudine e longitudine (vedi Tabella ??). Così facendo si riduce il numero di coppie distinte in input all'algoritmo di clustering. Il conteggio risultante viene interpretato come un

peso di ciascuna coordinata. Per attenuare lo sbilanciamento tra coordinate molto visitate e coordinate rare, i pesi vengono normalizzati applicando il logaritmo base 2; le coordinate con peso zero dopo la trasformazione logaritmica vengono riportate artificialmente a 1.

DBSCAN

L'algoritmo DBSCAN viene eseguito con i parametri $\varepsilon = 0.075$ e $N_{\min} = 10$, scelti empiricamente in modo da produrre cluster geograficamente coerenti con i porti e i punti di passaggio dell'arcipelago delle Hawaii. Questo passo riproduce l'approccio di Pallotta et al. ed è incluso come riferimento per il confronto con la variante H-DBSCAN.

H-DBSCAN

Il motivo principale per introdurre H-DBSCAN è la sua capacità di identificare cluster di densità variabile, cosa che DBSCAN non riesce a gestire bene [?]. Il traffico nelle Hawaii presenta una densità fortemente eterogenea: i porti principali come Honolulu hanno concentrazioni di punti molto più elevate rispetto a zone di passaggio o porti minori. In questo contesto, i parametri fissi di DBSCAN tendono a sovra-segmentare le aree sparse o a fondere artificialmente cluster distinti nelle aree dense.

Poiché la libreria `hdbscan`² non consente di associare i pesi ad ogni punto ma li considera tutti equiponderati, la tabella aggregata viene espansa: ogni coordinata viene replicata un numero di volte pari al suo peso logaritmico. La tabella espansa conta circa 68.000 righe, una dimensione che consente l'esecuzione in poche decine di secondi. H-DBSCAN viene eseguito con i parametri `min_cluster_size = 30`, `max_cluster_size = 10 000` e `cluster_selection_epsilon = 0.01`.

3.5.3 Costruzione dei waypoint e identificazione delle rotte

Una volta determinati i cluster tramite H-DBSCAN, per ciascun cluster viene calcolato il *convex hull* (involuppo convesso) tramite `scipy.spatial.ConvexHull`. L'involuppo convesso di ogni cluster definisce il perimetro del waypoint corrispondente, rappresentato come un poligono tramite la libreria Shapely.

Per ogni punto del dataset viene quindi verificato se esso ricade all'interno di uno dei poligoni waypoint, informazione salvata nella colonna `IsInWP`. Un way-

²Libreria esterna `hdbscan` (<https://github.com/scikit-learn-contrib/hdbscan>), distinta dall'implementazione inclusa in `scikit-learn`.

point è considerato *significativo* per un dato punto se quest'ultimo soddisfa almeno una delle condizioni seguenti: $\text{Avg_Speed} \leq \text{SPEED_THRESHOLD}$, oppure il suo `EstimatedStatus` è *entry* o *exit*.

L'assegnazione delle rotte avviene una nave alla volta, all'interno di ogni coppia (*entry*, *exit*) identificata nel dataset. A ogni punto viene assegnata un'etichetta secondo la seguente logica:

- se il punto si trova all'interno di un waypoint significativo, l'etichetta corrisponde al nome di quel waypoint;
- se il punto si trova in navigazione tra due waypoint, l'etichetta assume il formato `WP_X -- WP_Y`, dove `WP_X` e `WP_Y` sono rispettivamente il waypoint di provenienza e quello di destinazione; nei casi in cui uno o entrambi non siano identificabili, viene utilizzato il segnaposto `<NA>`.

Con queste ultime operazioni, termina la fase di Knowledge Discovery: ogni punto del dataset ha associata un'etichetta di rotta secondo i criteri appena descritti, e il modello di traffico appreso è pronto per essere utilizzato nella fase di Knowledge Exploitation.

3.6 Anomaly detection

Prima di descrivere la fase di anomaly detection, è opportuno introdurre due concetti fondamentali. Una **rotta** è un'entità astratta che modella il fatto che almeno una volta una nave ha viaggiato dal waypoint di partenza a quello di arrivo (e non il viceversa). Ipotizzando di modellare i waypoint come nodi di un grafo orientato, una rotta sarebbe uno degli archi. Un **trip** indica invece il singolo viaggio compiuto da una specifica nave lungo una rotta. A ogni rotta possono quindi essere associati più trip, tanti quante sono le navi che l'hanno percorsa nel periodo analizzato.

La fase di anomaly detection segue le equazioni del framework TREAD originale [6]. L'analisi si concentra su una singola rotta selezionata (una delle più trafficate tra quelle estratte nella fase precedente) e utilizza i trip associati a tale rotta come unità di analisi

3.6.1 Decomposizione della velocità e preparazione delle feature

Per ogni punto del dataset vengono calcolate le componenti cartesiane della velocità V_x e V_y a partire da `SOG` e `COG`. Il `COG`, espresso in gradi rispetto al nord geografico

(angolo *bearing*), viene convertito in angolo aritmetico standard tramite la formula $\theta = (450 - \text{COG}) \bmod 360$, e poi in radianti. Le componenti risultanti sono:

$$V_x = \text{SOG} \cdot \cos(\theta), \quad V_y = \text{SOG} \cdot \sin(\theta)$$

Pallotta et al. [6] propongono un approccio alternativo per il calcolo delle stesse componenti, basato sulla funzione arcotangente e sul teorema di Pitagora. Questo approccio presenta alcune criticità. In primo luogo, la funzione arcotangente è definita a meno di un'ambiguità di segno: per ricavare il quadrante corretto della direzione è necessario gestire esplicitamente i casi in cui V_x e V_y assumono segno negativo, introducendo logica condizionale aggiuntiva. In secondo luogo, l'uso combinato di arcotangente e radice quadrata è computazionalmente più oneroso rispetto al calcolo diretto tramite seno e coseno. Infine, l'approccio inverso introduce potenziali errori numerici nelle situazioni limite, come velocità molto prossime a zero, in cui il rapporto tra le componenti diventa instabile. Per questi motivi, nella presente implementazione si è preferito calcolare V_x e V_y direttamente tramite seno e coseno dell'angolo θ , ottenendo un codice più semplice ed efficiente.

3.6.2 Stima della densità tramite Kernel Density Estimation

Per modellare il comportamento normale di una rotta, viene stimata la distribuzione spaziale dei punti tramite *Kernel Density Estimation* (KDE) bivariata sui valori di latitudine e Longitudine (LON, LAT), usando la funzione `scipy.stats.gaussian_kde`. Viene inoltre calcolata una seconda KDE, pesata per la magnitudine della velocità (SOG), che cattura le zone dove le navi transitano tipicamente a velocità elevate. Il prodotto punto per punto delle due KDE (equazione 8 di [6]) fornisce per ogni punto del dataset un valore di densità p_i che combina informazione spaziale e cinematica.

3.6.3 Classificazione dei trip e train/test split

I trip associati alla rotta selezionata vengono ordinati per lunghezza (numero di punti) in ordine crescente. Il dataset di addestramento (*train*) è composto da una frazione configurabile dei trip più corti, assunti come rappresentativi del comportamento normale; il restante costituisce il dataset di test. La scelta di usare i trip più corti come riferimento di normalità è motivata dall'osservazione che i trip anomali tendono ad avere traiettorie più lunghe o devianti rispetto a quelli regolari.

3.6.4 Calcolo della probabilità di transizione e anomaly scoring

Il modello di anomaly detection si basa sulla probabilità di transizione tra stati successivi di una traiettoria, modellata tramite una distribuzione di Weibull, seguendo l'equazione 14 di [6]:

$$p(\Delta p \mid \Delta t) = \exp \left[- \left(\frac{\Delta p}{m \cdot \Delta t} \right)^\beta \right]$$

dove Δp è la distanza tra la posizione predetta (tramite il Track Predictor, algoritmo 4 di [6]) e quella effettiva, Δt è l'intervallo di tempo, e m e β sono i parametri del modello stimati sui dati di addestramento.

I parametri vengono stimati calcolando, per un insieme di lag temporali adattativi (da un minimo di 30 s a un massimo di un quinto della durata mediana dei trip), le distribuzioni delle distanze Δp e fittando su ciascuna una distribuzione di Weibull tramite `scipy.stats.weibull_min`. Il parametro di scala $\alpha_k = m \cdot \Delta t$ viene stimato tramite regressione lineare sull'insieme dei valori ottenuti ai diversi lag; il parametro di forma β è preso come media dei valori stimati.

Ad ogni trip viene infine assegnato un punteggio di anomalia come log-somma normalizzata delle probabilità di transizione lungo la traiettoria (equazione 9 di [6]), combinata con la log-probabilità di osservazione derivata dalla KDE (equazione 6) e con la probabilità a priori della rotta (equazione 4). I trip con punteggio più basso sono classificati come potenzialmente anomali.

3.7 Tecnologie utilizzate

L'intera pipeline è implementata in **Python 3**, organizzata in file Jupyter Notebook separati. I parametri di configurazione sono centralizzati in un unico file “.py” a cui hanno accesso tutti i Notebook Jupyter.

Le librerie principali utilizzate sono:

- **Polars**: per sfruttare il multithreading durante l'importazione dei file CSV giornalieri e il filtraggio geografico iniziale;
- **Pandas**: per la manipolazione del dataset nelle fasi successive all'importazione;
- **NumPy**: per i calcoli vettoriali e le operazioni sulle serie temporali;

- **scikit-learn**: per l'implementazione di DBSCAN;
- **hdbscan**: libreria per H-DBSCAN, scelta per le sue prestazioni superiori rispetto all'implementazione scikit-learn nella gestione di cluster di densità variabile;
- **SciPy**: per il calcolo dei convex hull (`scipy.spatial.ConvexHull`), la Kernel Density Estimation (`scipy.stats.gaussian_kde`) e il fitting della distribuzione di Weibull (`scipy.stats.weibull_min`);
- **Shapely**: per le operazioni geometriche sui poligoni waypoint (verifica di contenimento punto-poligono);
- **GeoPandas**: per la visualizzazione rapida dei poligoni waypoint per verifiche qualitative;
- **Plotly**: per la visualizzazione interattiva dei risultati su mappa geografica.

La scelta di Python è motivata dalla disponibilità di un ecosistema maturo per l'analisi di dati anche geospaziali.

3.8 Limiti della metodologia

La metodologia presentata in questo capitolo presenta alcuni limiti che è opportuno dichiarare esplicitamente. Un primo limite riguarda la copertura geografica: il dataset del NOAA è limitato alle aree costiere statunitensi, e la tesi si concentra sulle Hawaii, un arcipelago con un traffico relativamente contenuto rispetto ad aree come lo Stretto di Gibilterra o l'Adriatico settentrionale studiate nell'articolo originale di Pallotta et al. [6]. I risultati ottenuti potrebbero quindi non generalizzarsi ad aree con densità di traffico diverse.

Un secondo limite è di natura computazionale: l'implementazione scikit-learn di DBSCAN ha un costo in memoria $O(n^2)$ rispetto al numero di punti in input (si veda il Paragrafo 3.5.2 per i dettagli). La RAM disponibile sulla macchina utilizzata non era sufficiente per eseguire l'algoritmo direttamente sui punti grezzi del dataset, rendendo necessaria una fase di pre-aggregazione per coordinate GPS e, per H-DBSCAN, un'ulteriore espansione della tabella dei pesi. Questo livello aggiuntivo di elaborazione non comporta una perdita di informazione sul dataset nel suo complesso ma rappresenta comunque un vincolo imposto dall'hardware, che con risorse maggiori non sarebbe stato necessario.

Un ulteriore limite, intrinseco alla tecnologia AIS stessa e già discusso nel Capitolo 2, riguarda la natura dei dati alla fonte. Il sistema AIS traccia esclusivamente le imbarcazioni che montano e utilizzano attivamente il transponder: l'obbligo di installazione, imposto dalla convenzione SOLAS, si applica infatti solo alle navi con stazza lorda superiore a una certa soglia e alle navi passeggeri [1]. Il naviglio minore (imbarcazioni da diporto, pescherecci di piccole dimensioni, mezzi non commerciali) non è quindi soggetto a tale obbligo e risulta nella maggior parte dei casi del tutto assente dal dataset. Ne consegue che il modello di traffico appreso descrive esclusivamente il comportamento delle imbarcazioni di maggiori dimensioni, mentre eventuali pattern di traffico generati dal naviglio minore restano completamente invisibili. A questo si aggiungono i limiti di qualità del dato già discussi nel Capitolo 2, quali le lacune di copertura dei ricevitori terrestri e la possibilità di manipolazione dei messaggi tramite spoofing o spegnimento volontario del transponder [8], fattori che, seppur non specificamente analizzati in questa tesi, contribuiscono al divario tra il traffico realmente presente nell'area e quello effettivamente osservabile tramite AIS.

3.9 Sintesi e anticipazione dei risultati

Il capitolo ha descritto la metodologia adottata per replicare, adattare e estendere il framework TREAD di Pallotta et al. su dati AIS reali relativi alle Hawaii. La pipeline comprende una fase di pre-processing (importazione, pulizia e ottimizzazione, calcolo della velocità media e classificazione degli stati), la fase di Knowledge Discovery con il doppio utilizzo di DBSCAN e H-DBSCAN per l'identificazione dei waypoint e la successiva assegnazione delle rotte, e infine una fase di anomaly detection basata su KDE e distribuzione di Weibull.

Le principali differenze rispetto all'algoritmo originale sono: l'adozione di H-DBSCAN al posto di DBSCAN incrementale, motivata dalla necessità di gestire cluster a densità variabile; l'approccio batch in luogo di quello incrementale, imposto dai vincoli hardware; l'introduzione della normalizzazione per lunghezza del trip nel calcolo del punteggio di anomalia, non presente nell'originale.

Il Capitolo 4 presenterà i risultati ottenuti: i waypoint identificati, le rotte estratte, i parametri del modello Weibull stimati e il ranking di anomalia dei trip sulla rotta selezionata.

Capitolo 4

Results

Illustrazione dei risultati con grafici, tabelle, mappe e quanto necessario.

4.1 Sezione 1 - Dataset utilizzati

Presentazione dei dataset effettivamente utilizzati (dimensioni, struttura, qualità dei dati contenuti ecc...)

4.2 Sezione 2 - Risultati qualitativi

Mostrare gli output visivi prodotti dall'algoritmo (far vedere che funziona)

4.3 Sezione 3 - Risultati quantitativi

Metriche da stabilire

4.4 Sezione 4 - Interpretazione risultati ottenuti

Implicazioni pratiche

4.5 Sezione 5 - Conclusione

Sintesi di quanto descritto e anticipazione capitolo 5

Capitolo 5

Conclusions

Conclusioni, in cui indico in che modo il mio lavoro ha portato delle migliorie ed eventualmente quali aspetti possono/devono essere ancora esplorati/approfonditi

5.1 Sezione 1 - Sintesi dei contributi principali

Testo Sezione 1

5.2 Sezione 2 - Migliorie ottenute

Testo sezione 2

5.3 Sezione 3 - Limititazioni/difetti

Testo sezione 3

5.4 Sezione 4 - Sviluppi futuri

Testo Sezione 4

5.5 Sezione 5 - Conclusione finale

Bibliografia

- [1] International Maritime Organization. Regulations for carriage of ais, 2000. Disponibile: <https://www.imo.org/en/ourwork/safety/pages/ais.aspx>. Accessed: 2026-04-12.
- [2] International Telecommunication Union. Recommendation ITU-R M.1371-6: Technical characteristics for VHF automatic identification system using time division multiple access in the maritime mobile service. ITU-R Recommendation M.1371-6, ITU Radiocommunication Sector, 2 2026. URL <https://www.itu.int/rec/R-REC-M.1371/en>.
- [3] Kira Kowalska and L. Peel. Maritime anomaly detection using gaussian process active learning. pages 1164–1171, 01 2012. ISBN 978-1-4673-0417-7.
- [4] Richard Lane, David Nevell, Steve Hayward, and T.W. Beaney. Maritime anomaly detection and threat assessment. pages 1 – 8, 08 2010. doi: 10.1109/ICIF.2010.5711998.
- [5] Steven Mascaro, Ann E. Nicholso, and Kevin B. Korb. Anomaly detection in vessel tracks using bayesian networks. *International Journal of Approximate Reasoning*, 55:84–98, 2014. doi: 10.1016/j.ijar.2013.03.012. URL <https://doi.org/10.1016/j.ijar.2013.03.012>.
- [6] Giuliana Pallotta, Michele Vespe, and Karna Bryan. Vessel pattern knowledge discovery from ais data: A framework for anomaly detection and route prediction. *Entropy*, 15(6):2218–2245, Jun 2013. doi: 10.3390/e15062218.
- [7] Wikipedia. National oceanic and atmospheric administration. https://it.wikipedia.org/wiki/National_Oceanic_and_Atmospheric_Administration, 2026. Ultimo accesso: 02/06/2026.
- [8] Konrad Wolsing, Linus Roepert, Jan Bauer, and Klaus Wehrle. Anomaly detection in maritime ais tracks: A review of recent approaches. *Journal of Marine Science and Engineering*, 10, 01 2022. doi: 10.3390/jmse10010112.